

设计报告 · Optic-SpaceNet 光学 CNN 在轨加速系统（决赛）

决赛作品 CICC 1003564 · 曦智科技 Gazelle 光计算平台命题

从'仿真迁移'进入'真机部署'阶段：以 EuroSAT（10 类遥感，64×64 RGB）为任务，将模型族（Model 1/4/5/6/7/8/9/10）迁移到 **Gazelle 光计算真机**（8×2 光学矩阵乘法器，8a8w12o）完成全量验证与精度评测。

目录

- [项目背景与目标](#)
- [硬件平台与部署架构](#)
- [模型族设计（M1/M4-M10）](#)
- [量化与噪声鲁棒训练（v8 QAT）](#)
- [校准与部署链路设计](#)
- [运行调度与器件保护](#)

1. 项目背景与目标

1.1 背景

复赛完成了 EuroSAT CNN → Gazelle 光计算的 **osimulator 仿真迁移**（三模型，gap ≤2%）。决赛目标：在 **Gazelle 真机**上完成模型族的端到端部署与**全量（5400 张 test）精度验证**，并回答三个工程问题：

- 架构-硬件匹配**：何种结构（全 1×1 / 3×3 / 窄通道 / conv3s2 下采样）在真实器件噪声下表现最优；
- 校准体系**：per-column 仿射校准 vs 逐列（per-channel）最小二乘校准（calibrate_col）的真实收益；
- 器件热稳定性**：激光器/器件连续工作窗口与冷却策略（已实证：连续 ~2h 后热崩溃，0% 输出）。

1.2 设计目标

维度	目标
真机全量验证	每个部署模型在 EuroSAT test 5400 张上完成全量评测

维度	目标
真机 vs 干净参考 gap	主模型 (M4/M6/M10) $\leq 3\text{pt}$
校准有效性	逐列校准相对标量真实收益 +1~2pt (C1 ABA, c3d, n=1000/配置: 94.60 vs 92.60)
器件保护	单次调用 (含校准) < 30min、调用间 $\geq 5\text{min}$ 冷却、热崩溃可恢复
可复现性	全程日志/校准/权重/错误明细入库, 判据与 SOP 文档化

1.3 核心设计思想：架构 × 硬件噪声联合设计（Round X0）

决赛模型族沿用 X0 轮结论：**v8 漂移鲁棒 QAT**（训练注入真机 probe 实测三组分噪声 $\times 1.5$ 余量）+ **1×1 光算层优先**（3×3 层 δW 结构误差不可校准）+ **宽度保证 SNR**（C0=12 超窄通道实测崩溃 77%，同架构全宽 C0=16 正常 92-96%）。

2. 硬件平台与部署架构

2.1 Gazelle 真机

项	数值	工程影响
物理计算 tile	8×2	im2col 展平长度尽量被 8 整除
原生精度	8a8w12o	int8 权重 + uint8 激活 + 12bit 输出
输入约束	非负、仅 MAC（无 bias）	bias=False + zero-point 反量化
校准基准	compass_cali 后 EBR ≥ 8	放行判据之一
噪声结构	per-column 偏移/增益 + per-element δW + iid	校准修正列结构、REP 平均降 iid、 δW 需训练鲁棒

2.2 两套部署路径

	路径 A：HTTP 远程客户端	路径 B：板端 numpy runner
适用模型	M1/M4/M5/M6/M7/M8	M9/M10（ds3 系，conv3s2）
架构	本地 torch（OpticConv2d/OpticLinear）+ 板上 server_gazelle.py（HTTP :8000）	板上直接 compass_matmul（Python 3.6，无 torch）
校准	analyze_layers per-column affine npz（权重 md5 索引）	probe_dump_ds3 → calibrate_col.py 逐列 json
tiling	m≤1024 chunk	m≤2（FPGA 行回绕 bug）
传输	base64 二进制（2026-08-09 优化，~3× 提速）	本地直连

3. 模型族设计 (M1/M4-M10)

3.1 总览

模型	架构	参数量	MACs/张	v8 训练 test	真机全量 5400	角色
M1	Baseline VGG (flat+BN, 6×3×3 + fc1/fc2)	2.39M	156.6M	变体 A: 97.98 val / 97.87 (QAT int8 val, 部署参考)	20/20 = 100% (板端抽样 n=20)	大参数/大计算量基准 (真机全量不可行, 抽样流程验证完成)
M4	MiniVGG-GAP (全 3×3 7 光算层 + GAP)	260K	17.03M	96.17 (v4....	94.19%	复赛主力延续
M5	J1-RF+ (stem k5 + stage2 3×3×2)	100,250	5.31M	96.65	90.17%	3×3 系代表
M6	纯 J1 (全 1×1 (1,2,2))	50,330	1.38M	95.22	92.78%	≤2M 预算
M7	J1-w075 (C0=12 + MaxPool)	32,246	0.86M	94.98	81.72% (板端 [0:1800], 架构不匹配)	微型档 (MaxPool 噪声偏传播, 暂停)
M8	rf_stem5 (J1 + stem k5)	51,098	2.16M	96.26	87.78%	中间档
M9	J1-w075ds3 (w0.75 + conv3s2)	54,886	1.52M	95.87/95.69	94.43%	≤2M 冠军 (最终交付)
M10	ds3pool3 (conv3s2 + stem max3)	96,602	2.56M	96.76/96.56	95.33% (SOTA)	v8 总冠军 (X0)

3.2 设计要点

- **M4**: 7 光计算层 (6×3×3 conv + head FC), stem FP32 电算 (对齐率 84.4% 低、电算更高效);
- **M5**: 唯一在 8×8 低分辨率放 3×3 的模型 (RF 49px) ——决赛真机证明 3×3 层 δW 误差不可校准 (全量 gap -6.3pt);
- **M6**: 全 1×1 光算层 + head/stem 电算——真机表现稳健 (gap -2.7pt);

- **M7**: C0=12 + MaxPool 下采样——路径 A 77.3% / 板端 81.72% (深诊断后暂停); 与 M9 (同 C0=12、conv3s2) 差 12.1pt (M9 94.43% vs M7 修复校准后最佳 82.33%; 三段累计 [0:1800] 81.72% → 差 12.7pt), **最终判定为架构特性: MaxPool 取 max 对加性噪声有偏传播 (选择噪声尖峰), 卷积光层平滑噪声;**
- **M9/M10**: conv3s2 下采样 (一份 MACs 同时答'下采样+RF+通道混合'), X0 B1 效率 0.55pt/M; 路径 B + 逐列校准, 真机全量 **M9 94.43% / M10 95.33%** (全模型 SOTA) ——**最终交付模型**; M1 以板端 20 张抽样 100% 完成流程验证。

3.3 部署语义

- 光计算层: M5-M8 = 5×1×1 conv (stem/head FP32 电算, 与 v8 训练 head_fp32 对齐);
- M9/M10 = 7 光算 conv (s1a/s1ds/s2a/s2b/s2ds/s3a/s3b) + h1/h2 光算 (bias 反量化后加);
- M4 = stem 电算 + 6×3×3 conv + head FC 光算 (head bias 保留, C2 部署 bug 教训)。

4. 量化与噪声鲁棒训练 (v8 QAT)

- **误差归因** (round5/X0): hw 误差 95% 为 run 间可复现的**结构化分量**: per-column 偏移 (4-23% 方差) + per-column 增益 (1-3%) + per-element δW (21-50%);
- **v8 配方**: 训练时 per-batch 重采样三组分噪声 + iid $\sigma=260$, 幅度取板上 probe 实测 × **1.5** 余量; 60ep 从 clean ckpt 续训 (M5-M8) 或单阶段 160ep 从零 (M9/M10);
- **M5-M10 全部 v8 权重入库** (eurosat_research/weights/, git 强制跟踪), MD5 可校验。

5. 校准与部署链路设计

5.1 两套校准体系

	路径 A: analyze_layers	路径 B: calibrate_col (C1 SOTA)
形式	per-column affine (a_j, b_j), 权重 md5 索引	逐列 α_c/β_c , 折叠进反量化
自检	无	SE + 结构 SNR + 50/50 留出验证 (方差改善 4.5-25.2%)
纪律	同窗口背靠背	calib json 不可跨窗口复用 (实证 -24.4%→-7.8%)

5.2 传输优化

- server_gazelle.py 支持 act_b64/weight_b64 (base64, JSON 回退保留): 校准 503s→141s、跑批提速 ~3×;
- 客户端 gazelle_engine.py _b64_body 配套; run_eval.py REF 段修复 (原硬编码 model2)。

6. 运行调度与器件保护

(2026-08-14 用户指令固化, AGENTS.md 第 9 条)

1. **单次调用 (含校准) < 30min**: 校准 ~10min, 跑批 = 30 - 校准耗时;
2. **两次调用间 $\geq 5\text{min}$ 空余** (激光器冷却);
3. **准确率比预期低 >5% $\rightarrow$ 冷却升级** (5min $\rightarrow$ 15-30min) 并及时汇报;
4. **器件连续工作窗口 ~2h** (两次独立复现 0% 热崩溃) $\rightarrow$ 窗口化跑批 (每窗口 1-2 段 + 窗口间长冷却);
5. **热崩溃恢复**: 长冷却 $\geq 1\text{h}$ + fresh compass_cali (EBR ≥ 8 判据)。

共享板 SOP: 开窗前四判据 (EBR ≥ 8 / error_std $\leq \pm 2\%$ (10% 宽限) / MNIST canary $< 0.5\text{pt}$ / EuroSAT 200 mini-run) + who/ps 侦测 + 板上台账 BOARD_USAGE.md 登记。