

# 三模型光计算迁移实验 · 总结报告

本文档由 EXPERIMENTS.md 浓缩而成，面向报告/答辩使用。

主线：三个 EuroSAT (10 类遥感, 64×64) CNN → **Gazelle 光计算硬件 (8×2 光学矩阵乘法器)** 的量化迁移。

聚焦维度：**实现方式 / 参数量 / 参数精度 / 准确率 / 运行速率**。

数据基准：Bug #11 (test⊂train 泄漏) 修复后的**干净三分 split** (train 16200 / val 5400 / test 5400)；历史 leaky 数字一律标注作废。

📁 **目录重构 (2026-07-16)**: 代码 → src/{core,qat,data,training,scripts}/，权重 → weights/，本文档及图表 → docs/( docs/figures/ )。从仓库根运行: python src/<子目录>/<脚本>.py。完整结构见根目录 README.md。

## 1. 一句话结论

- **Model 1 (VGG)**: 参数量最大 (~2.39M)、精度最高，但计算量是另两个模型的 **~150×**，真机全量不可行 (~9 天)。
- **Model 2/3 (SpaceNet)**: 参数量仅 ~268K，真机 int8 全量 5400 张 ≈ **90.4% / 90.3%**，单张 ~2.5s，是可落地部署的轻量主力。
- **量化配方定型**: stem 首层 FP32 (电计算) + 其余 Conv/Linear int8 + Gazelle 噪声训练，与 osimulator 8a8w 推理路径天然对齐，真机 gap 仅 ~1.6 点。
- **KD 不带来真机增益**: Model 2 (无 KD) 与 Model 3 (KD) 真机精度打平 (90.43% vs 90.28%)、硬件 gap 基本相等 (~1.6 点)。

## 2. 硬件平台 (Gazelle, 2026-07-09 逆向确认)

| 参数       | 值                                         | 影响                  |
|----------|-------------------------------------------|---------------------|
| 物理 tile  | 8×2 (k=8, n=2)                            | im2col 展平长度须被 8 整除  |
| 原生精度     | 8a8w12o (8-bit 激活 / 8-bit 权重 / 12-bit 输出) | 硬件支持 int8，不必退守 int4 |
| DAC ENOB | 7.5 bits                                  | 训练噪声匹配项             |
| TIA 噪声 σ | ≈5.3e-4 (MSE 2.85e-7)                     | 训练噪声匹配项             |

| 参数    | 值                 | 影响               |
|-------|-------------------|------------------|
| 硬件线性度 | 99.4% (相对误差 0.6%) | 硬件近乎理想，量化精度是唯一瓶颈 |

**关键认知：**硬件本身几乎理想（线性度 99.4%），所有精度损失来自量化与噪声建模，而非硬件缺陷。

### 3. 三模型架构与实现方式（横向总览）

|          | Model 1                     | Model 2                         | Model 3                                 |
|----------|-----------------------------|---------------------------------|-----------------------------------------|
| 名称       | Baseline VGG                | OpticSpaceNet V1                | OpticSpaceNet V2                        |
| 设计思路     | 标准 CNN 基线                   | 硬件对齐 (2×2 conv)                 | 硬件对齐 + 知识蒸馏 (KD)                        |
| 结构       | 6× Conv2d (3×3) + 2× Linear | 4× Conv2d (1×1/2×2) + 2× Linear | 同 Model 2                               |
| 参数量      | ~2.39M                      | ~268K                           | ~268K                                   |
| 训练方式     | 标准分类                        | 标准分类                            | KD (教师 ResNet-18, 97.83%; T=4.0, α=0.7) |
| bias     | False (Phase4+)             | False                           | False                                   |
| BN       | 保留 (FP32 运行)                | 保留                              | 保留                                      |
| 硬件对齐率    | 99.8% (首层 84.4%)            | 99.6% (stem 37.5%)              | 99.6% (同 M2)                            |
| 总 MOPs/张 | 156.63M                     | 1.05M                           | 1.05M                                   |

**架构差异本质：**Model 1 是大而精的通用基线；Model 2/3 为硬件量身定做（2×2 conv 使展开长度完美对齐 8×2 tile），用 ~1/9 的参数换 ~1/150 的计算量。

### 4. 纵向发展：各模型量化精度演进

横轴为量化方案迭代，纵轴为精度。val = 干净验证集；标注「作废」者为 Bug #11 leaky 数据。

#### 4.1 Model 1 (Baseline VGG, FP32 基准 97.17%)

| Phase | 实现方式                                      | 参数精度 | 精度                     | vs FP32       | 判定 |
|-------|-------------------------------------------|------|------------------------|---------------|----|
| 0     | FP32 基准                                   | fp32 | 97.17%                 | —             | —  |
| 1     | QAT 微调 (FP32→低比特)                         | int4 | 85.91%                 | -11.26%       | ✗  |
| 2     | 从零 QAT                                    | int4 | 91.17%                 | -6.00%        | △  |
| 3     | LSQ+ (旧版有 bug)                            | int4 | 61.72%                 | -35.45%       | ✗  |
| 4     | STE + 噪声注入                                | int4 | 96.46%                 | -0.71%        | ✓  |
| 5     | <b>Mixed</b> (Conv int4 / Linear fp32)    | 混合   | <b>98.26%</b>          | <b>+1.09%</b> | ★★ |
| 6     | v3 Gazelle 匹配 (变体 A, conv1_1 电计算)         | int8 | <b>97.87%</b><br>(val) | +0.70%        | ★  |
| 6     | v3 Gazelle 匹配 (变体 B, conv1_1+conv3_2 电计算) | int8 | <b>98.02%</b><br>(val) | +0.85%        | ★  |

**Model 1 轨迹要点：**微调路线 (Phase 1) 彻底失败；从零 QAT (Phase 2) 有效但仍差 6%；STE (Phase 4) 把 int4 损失压到 0.71%；Mixed (Phase 5) 与 int8 v3 (Phase 6) **双双反超 FP32 基准**。变体 A/B 统计打平 (Δ 0.15%)，B 多回退一层到电计算、精度不降反微升、osim 提速 ~24% → **性价比更高**。

## 4.2 Model 2 (SpaceNet V1，FP32 基准 90.15%)

| Phase | 实现方式                                       | 参数精度                    | 精度                     | vs FP32       | 判定 |
|-------|--------------------------------------------|-------------------------|------------------------|---------------|----|
| 0     | FP32 基准                                    | fp32                    | 90.15%                 | —             | —  |
| 1     | QAT 微调                                     | int4                    | 73.63%                 | -16.52%       | ✗  |
| 2     | 从零 QAT                                     | int4                    | 81.20%                 | -8.95%        | △  |
| 4     | STE (Conv QAT 全关 bug)                      | int4                    | 74.35%                 | -15.80%       | ✗  |
| 5     | Mixed                                      | Conv int4 / Linear fp32 | 91.26%                 | +1.11%        | ★  |
| 6 v2  | Phase4 修复 (QAT 全开)                         | int4                    | 91.06%                 | +0.91%        | ★  |
| 6 v3  | <b>Gazelle 匹配</b> (stem FP32 + Gazelle 噪声) | int8                    | <b>92.06%</b> (干净 val) | +1.91%        | ★★ |
| LSQ+  | LSQ+ 修复 (可学习 scale/zp)                     | int8                    | 92.80%                 | +2.65%        | ★  |
| —     | <b>osimulator 真机 (全量 5400, 干净)</b>         | int8 (stem 电计算)         | <b>90.43%</b>          | <b>+0.28%</b> | ★  |

**Model 2 轨迹要点：**int4 路线天花板 ~91%（受 stem 训练/推理不一致 + int4→int8 网格不对齐三重限制，详见 EXPERIMENTS §16）；切换到 **int8 + stem-FP32 + Gazelle 噪声**后 val 升至 92.06%；真机全量 **90.43%**，反超原 FP32 基准 +0.28%。

4.3 Model 3 (SpaceNet V2 + KD, FP32 基准 91.44%)

| Phase | 实现方式                               | 参数精度                    | 精度                     | vs FP32 | 判定 |
|-------|------------------------------------|-------------------------|------------------------|---------|----|
| 0     | FP32 KD 基准 (ResNet-18 教师 97.83%)   | fp32                    | 91.44%                 | —       | —  |
| 1     | QAT 微调                             | int4                    | 73.22%                 | -18.22% | X  |
| 2     | 从零 KD+QAT                          | int4                    | 83.26%                 | -8.18%  | △  |
| 4     | KD+STE (Conv QAT 全关 bug)           | int4                    | 78.26%                 | -13.18% | X  |
| 5     | KD+Mixed                           | Conv int4 / Linear fp32 | 91.13%                 | -0.31%  | ★  |
| 6 v2  | KD+Phase4 修复                       | int4                    | 91.50%                 | +0.06%  | ★  |
| 6 v3  | <b>KD+Gazelle 匹配</b>               | int8                    | <b>91.83%</b> (干净 val) | +0.39%  | ★★ |
| —     | <b>osimulator 真机 (全量 5400, 干净)</b> | int8 (stem 电计算)         | <b>90.28%</b>          | -1.16%  | ★  |

**Model 3 轨迹要点：**与 Model 2 同架构，全程叠加 KD（ResNet-18 教师）。v3 int8+KD val 91.83%；真机全量 90.28%，略低于其 KD 基准（因 KD 基准 91.44% 本就高于 M2 的 FP32 基准）。

4.4 三模型共同的方法论拐点

| 拐点           | 失败方案                                | 成功方案                                   | 根因                                     |
|--------------|-------------------------------------|----------------------------------------|----------------------------------------|
| 微调 vs 从零     | FP32→int4 微调 (Phase 1, 全员 -11~-18%) | 从零 QAT (Phase 2)                       | FP32 权重依赖精细精度，突变量化破坏特征                 |
| int4 vs int8 | int4 (16 级) 上限 ~91%                 | int8 (256 级, 匹配硬件原生)                   | int4→int8 网格不对齐 (max/7 vs max/127)，非无损 |
| stem 量化      | stem QAT (训练/推理分布不一致)               | <b>stem 保留 FP32 电计算</b>                | stem 对齐率仅 37.5%，电计算更划算且消除 BN 偏移        |
| 噪声建模         | STE 通用高斯噪声                          | <b>Gazelle 噪声 (DAC ENOB 7.5 + TIA)</b> | 训练噪声匹配真实硬件 → 真机 gap 收敛到 ~1.6 点         |

## 5. 横向对比：五大维度同台对比

以下全部基于**干净 split**的最终可部署配置（Model 2/3 = v3 int8；Model 1 = int8 v3 变体 A/B）。

### 5.1 参数量

| 模型      | 参数量          | 结构                         | 相对规模 |
|---------|--------------|----------------------------|------|
| Model 1 | <b>2.39M</b> | 6×Conv(3×3) + 2×Linear     | 8.9× |
| Model 2 | <b>268K</b>  | 4×Conv(1×1/2×2) + 2×Linear | 1×   |
| Model 3 | <b>268K</b>  | 同 Model 2                  | 1×   |

### 5.2 参数精度（部署配置）

| 模型        | 权重精度        | 激活精度 | 首层                                | 备注                   |
|-----------|-------------|------|-----------------------------------|----------------------|
| Model 1 A | int8        | int8 | conv1_1 <b>FP32 电计算</b>           | 光计算占比 97.74%         |
| Model 1 B | int8        | int8 | conv1_1 + conv3_2 <b>FP32 电计算</b> | 光计算占比 73.64%，提速 ~24% |
| Model 2   | <b>int8</b> | int8 | stem <b>FP32 电计算</b>              | 匹配硬件原生 8a8w          |
| Model 3   | <b>int8</b> | int8 | stem <b>FP32 电计算</b>              | 同 M2，外加 KD 训练        |

统一原则：**stem 首层 FP32 电计算（对齐率低） + 其余层 int8 光计算**。所有 int8 权重均匹配 Gazelle 原生 8-bit，避免 int4→int8 重网格损失。

### 5.3 准确率

| 模型             | FP32 基准 | int8 val (干净) | int8 test (干净) | osim 真机 (全量/抽样)         | 真机 vs FP32    |
|----------------|---------|---------------|----------------|-------------------------|---------------|
| Model 1 A      | 97.17%  | 97.87%        | 97.89%         | 98.00% (q50 抽样)         | +0.83%        |
| Model 1 B      | 97.17%  | 98.02%        | 97.96%         | 100.00% (q50 抽样)        | +2.83% (抽样)   |
| <b>Model 2</b> | 90.15%  | 92.06%        | 92.20%         | <b>90.43% (全量 5400)</b> | <b>+0.28%</b> |

| 模型      | FP32 基准 | int8 val (干净) | int8 test (干净)                | osim 真机 (全量/抽样)         | 真机 vs FP32 |
|---------|---------|---------------|-------------------------------|-------------------------|------------|
| Model 3 | 91.44%  | 91.83%        | fp32 test 92.13% <sup>1</sup> | <b>90.28% (全量 5400)</b> | -1.16%     |

<sup>1</sup> Model 3 的 --qat 推理路径走 int4 (84.59%)，给不了 int8 test 数；其 int8 test 数由 osimulator 真机取得 = 90.28%。

**真机 hardware gap**（osim 真机 – 干净 int8 QAT，同 test 集）：

| 模型      | int8 QAT test             | osim 真机 | 纯硬件噪声 gap     |
|---------|---------------------------|---------|---------------|
| Model 2 | 92.20%                    | 90.43%  | <b>-1.77%</b> |
| Model 3 | (缺, 以 fp32 test 92.13% 推) | 90.28%  | ~-1.6~1.8%    |

→ 两模型真机 gap **基本相等 (~1.6 点)**，源自 osim 物理噪声 (DAC ENOB 7.5 + TIA  $\sigma$ =5.31)；Gazelle 噪声训练已吸收大部分，残留 ~1.6 点。

**精度目标达成情况：**

| 模型      | int8 目标 | int8 实际 (val)   | 达成 |
|---------|---------|-----------------|----|
| Model 1 | ≥ 96%   | 97.87% / 98.02% | ✓  |
| Model 2 | ≥ 90%   | 92.06%          | ✓  |
| Model 3 | ≥ 91%   | 91.83%          | ✓  |

## 5.4 运行速率与计算开销

| 模型             | 总 MOPs/张       | 光计算占比  | 电计算层            | osim 单张耗时          | osim 全量 5400           | 训练耗时     |
|----------------|----------------|--------|-----------------|--------------------|------------------------|----------|
| Model 1 A      | <b>156.63M</b> | 97.74% | conv1_1         | ~150s 量级 (q50 抽样)  | <b>~9 天 (不可行, 仅抽样)</b> | 280 min  |
| Model 1 B      | 156.63M        | 73.64% | conv1_1+conv3_2 | ~150s 量级 (提速 ~24%) | 同上                     | 276 min  |
| <b>Model 2</b> | <b>1.05M</b>   | 90.65% | stem            | <b>~2.5s</b>       | <b>13357s (~3.7h)</b>  | 72.8 min |
| <b>Model 3</b> | <b>1.05M</b>   | 90.65% | stem            | <b>~2.5s</b>       | <b>13370s (~3.7h)</b>  | 90.4 min |

**Model 2/3 真机全量统计：**引擎各调用 27000 次（5 光计算层 × 5400 张），总运算量 5.15e+09 MACs，硬件对齐率 99.6%。

**速率结论：**

- **Model 2/3 ≈ 0.4 张/秒（~24 张/分）**，全量 5400 张 ~3.7h 可一次跑完 → **可落地部署**。
- **Model 1 计算量是 Model 2/3 的 ~150×**（156.6M vs 1.05M），单张慢 ~60×（~150s vs ~2.5s），全量 ~9 天不可行 → 只能抽样验证（q50：A 98% / B 100%）。
- 光计算占比均 ≥ 90%（Model 1 A 97.7% / Model 2-3 90.65%），满足部署阈值。

注：osim 耗时为光计算硬件**物理仿真**时间（Python 模拟光学矩阵乘 + 补零对齐 + 物理噪声），反映模型→硬件映射的开销结构，并非最终芯片上墙钟时间。

**5.5 五维横向对比总表**

| 维度       | Model 1                 | Model 2                  | Model 3                              |
|----------|-------------------------|--------------------------|--------------------------------------|
| 实现方式     | 标准 VGG + Mixed/int8 QAT | 硬件对齐 SpaceNet + int8 QAT | 硬件对齐 SpaceNet + <b>KD</b> + int8 QAT |
| 参数量      | 2.39M                   | 268K                     | 268K                                 |
| 参数精度     | int8 (首层 fp32)          | int8 (stem fp32)         | int8 (stem fp32)                     |
| 准确率 (真机) | 98.0/100.0% (q50 抽样)    | <b>90.43%</b> (全量)       | <b>90.28%</b> (全量)                   |
| 运行速率     | ~150s/张, 全量不可行          | <b>~2.5s/张, 3.7h 全量</b>  | <b>~2.5s/张, 3.7h 全量</b>              |
| 光计算占比    | 97.7% (A) / 73.6% (B)   | 90.65%                   | 90.65%                               |
| 可部署性     | △ (仅抽样)                 | ★★★                      | ★★★                                  |

**6. 部署推荐**

| 场景               | 推荐                     | 理由                                                       |
|------------------|------------------------|----------------------------------------------------------|
| 轻量落地（首选）         | <b>Model 2 v3 int8</b> | 268K 参数、真机 90.43%、 <b>反超 FP32 基准 +0.28%</b> 、全量 3.7h 可验证 |
| 同等轻量 + <b>KD</b> | Model 3 v3 int8+KD     | 与 M2 真机打平 (90.28%)，若需 KD 故事线可选                           |
| 最高精度（受算力）        | Model 1 int8 变体 B      | val 98.02%、q50 真机 100%，但 2.39M 参数 + ~150s/张，仅适合算力充裕场景    |

**统一部署配置：** stem FP32 电计算 + 其余 Conv/Linear int8 光计算 + Gazelle 噪声训练权重，光计算占比 ≥ 90%，硬件对齐率 99.6%。

## 7. 关键技术要点（报告 Takeaways）

- 1. **硬件先于模型：**先逆向 Gazelle (8×2 / 8a8w / 线性度 99.4%)，再据此设计模型 (2×2 conv 对齐 tile) 与训练 (int8 + Gazelle 噪声)，而非训练后再迁就硬件。
- 2. **int8 > int4：**硬件原生 8-bit，int4 路线存在不可消除的网格不对齐损失 (~6%)；int8 配方让真机 gap 收敛到 ~1.6 点。
- 3. **首层 FP32 是关键：**stem 对齐率仅 37.5%，保留电计算既高效又消除 BN 训练/推理分布偏移。
- 4. **从零 QAT > 微调：**低比特量化必须从零训练，让模型从未见过 fp32；微调路线全员失败。
- 5. **噪声匹配决定真机 gap：**训练时注入 Gazelle 物理噪声 (DAC ENOB 7.5 + TIA  $\sigma=5.3e-4$ )，真机精度基本保住。
- 6. **KD 未带来真机增益：**Model 2 (无 KD) 与 Model 3 (KD) 真机精度/gap 基本相等 → KD 提升噪声鲁棒性的假设**不被全量数据支持**。
- 7. **数据洁净性是底线：**Bug #11 (test⊂train 泄漏) 曾让 osim 虚高 ~3 点 (93.28% / 93.26% 作废)；干净 split 后真值 90.43% / 90.28%。

## 附：数据来源与可信度

| 数据类型                         | 来源                         | 可信度                                                |
|------------------------------|----------------------------|----------------------------------------------------|
| 训练 val / test (QAT)          | PyTorch 伪量化，干净 split       | ✓ 干净泛化数                                            |
| osim 真机 (Model 2/3)          | 全量 5400，COMPASS 8a8w12o 仿真 | ✓ 真值 (log_optic_int8_new.md / log_optic_kd_new.md) |
| osim 真机 (Model 1)            | q50 抽样 (全量 ~9 天不可行)        | △ 小样本，仅作机制验证                                       |
| 历史 leaky osim (93.28/93.26%) | Bug #11 前                  | X 作废                                               |



完整实验轨迹、Bug 记录、int4 困境分析见 EXPERIMENTS.md (§11.13 为 Model 2/3 全量真机定稿)。