

面向光学矩阵计算硬件的遥感图像分类网络真机部署与噪声鲁棒优化

Optic-SpaceNet: EuroSAT CNN 在 Gazelle 光计算真机上的全量验证

队伍 CICC 1003564 · “曦智杯”光计算 EDA 决赛 · 2026-08

摘要

卫星在轨遥感计算要求在严苛的功耗与算力约束下完成海量图像的星上实时分类。光学矩阵计算（光计算）以模拟物理过程完成矩阵乘，天然具备低功耗、高并行与抗单粒子翻转的潜力，但其器件噪声（列偏移、列增益、权重扰动）与热稳定性构成了 CNN 部署的核心挑战。本文以 EuroSAT 遥感图像分类（10 类，64×64 RGB，test 5400 张）为任务，系统研究了 CNN 在 Gazelle 光计算真机（8×2 光学 tile，8a8w12o）上的部署与优化，提出并验证了三项关键技术：**(1) 架构-硬件噪声联合设计**——基于真机 probe 实测的误差分解（per-column 偏移 4-23% 方差、per-column 增益 1-3%、per-element δW 21-50%）指导架构选择，证明全 1×1 光计算层显著优于 3×3 层（同流程 +2.6pt）、超窄通道（C0=12）因信噪比不足在 HTTP 部署路径上崩溃；**(2) v8 漂移鲁棒量化感知训练**——训练时按批重采样三组分结构化噪声（幅度取实测 ×1.5 余量），使模型对器件漂移天然鲁棒；**(3) 逐列校准与窗口化调度**——逐列最小二乘校准（留出验证）较标量校准真实提升 +1.0~2.0pt，配合“单次调用 <30 min、调用间冷却 ≥5 min、连续工作 ≤2 h”的器件保护调度，实现 24 段全量跑批零崩溃。最终在真机上完成 6 个模型的全量 5400 张验证：**最优模型 M10（ds3pool3，2.56M MACs/张）达到 95.33%（相对 GPU QAT 干净参考 gap -1.43pt），M9（1.52M MACs/张）94.43%（gap -1.44pt），M4（17M MACs/张）94.19%（gap -1.55pt）**；并通过同宽度对照实验（M7 vs M9，唯一差异为 MaxPool 与 conv3s2 下采样）定位了 MaxPool 对加性噪声有偏传播的失效机理（M9 94.43% vs M7 修复校准后最佳 82.33%，差 12.1pt）；同时给出了 20 分钟校准窗口（超窗精度 -12.5pt）与器件热崩溃（连续 ~2 h 后输出归零）的量化实证。上述结果验证了光学 CNN 在轨加速路线在真实器件上的可行性。

关键词：光计算；量化感知训练；器件噪声校准；遥感图像分类；边缘部署

1 引言

1.1 背景与动机

星载遥感平台每天产生海量对地观测数据，而星地下行带宽受限，土地监测、灾害评估等应用要求在星上完成实时分类。星载平台的功耗、重量与抗辐射约束使传统 GPU/ASIC 方案难以兼顾。光学矩阵计算核心（Optical Processing Unit, OPU）利用光的调制/衍射/探测过程以物

理方式完成矩阵-向量乘法（MVM），具有光速并行、低功耗、无 SEU（单粒子翻转）敏感电荷存储的天然优势，是“在轨智能”的候选加速器。

然而，真实光计算器件远非理想：权重加载单元（DAC）、跨阻放大器（TIA）与 ADC 引入复合噪声；器件随连续工作发热导致输出漂移甚至崩溃。将为电子芯片设计的 CNN 直接迁移到光计算硬件，精度损失可达两位数百分点。如何在真实光计算器件上保精度地部署 CNN，是从仿真走向在轨应用必须回答的问题。

1.2 挑战

本文目标硬件 Gazelle 为 8×2 光学 tile 原型（激活 8-bit 无符号、权重 8-bit、输出 12-bit，仅支持 MAC、不支持 bias），通过 HTTP 服务或板端 SDK 调用。部署面临四重挑战：

- 1. **结构化器件噪声**：实测输出误差可分解为 per-column 偏移（残差方差的 4-23%）、per-column 增益（1-3%）与 per-element 权重扰动 δW （21-50%），iid 分量占比小——传统 iid 噪声模型过悲观或过乐观均不可靠；
- 2. **时间漂移**：校准参数在 ~20 min 尺度显著漂移（实测超窗精度 -12.5pt），且器件连续工作 ~2 h 后发生热崩溃（输出归零）；
- 3. **算力与对齐约束**：单次 MVM 规模受限（im2col 展平长度须被 8 整除， $m \geq 3$ 行存在 FPGA 回绕 bug），激活计算量（MACs）直接决定耗时；
- 4. **共享环境**：真机为多队共享，使用需侦测、登记与冷却协议。

1.3 贡献

- 1. 提出并实证**架构-硬件噪声联合设计**准则：1×1 光计算层优先（3×3 层 δW 误差不可校准）、可学习 conv3s2 下采样严格优于 MaxPool（真机决定性实验差 12.1pt：M9 94.43% vs M7 修复校准后最佳 82.33%——MaxPool 对加性噪声有偏传播）并兼得感受野与通道混合、通道宽度决定 SNR 下限；
- 2. 提出 **v8 漂移鲁棒 QAT**：按批重采样三组分结构化噪声（实测 ×1.5 余量），在 c3d/J1/ds3 三个架构族上验证有效；
- 3. 建立**逐列校准 + 窗口化调度**的真机验证流水线：逐列校准 +1.0~2.0pt（同窗 ABA），调度规则实现 M10 全量 24 段零崩溃；
- 4. 完成 **6 个模型 × 5400 张全量真机评测**，给出精度-算力-鲁棒性的完整实证：M10 95.33%（gap -1.43pt, vs GPU QAT 96.76）为全模型真机最优。

2 硬件平台与误差分析

2.1 Gazelle 平台

属性	参数	工程影响
计算 tile	8×2	展平长度须被 8 整除
数值格式	8a (uint8 非负) / 8w (int8) / 12o	激活非对称量化 + zero-point 反量化

属性	参数	工程影响
运算	仅 MAC（无 bias）	全层 bias=False；head bias 反量化后电加
物理校准	compass_cali，EBR ≥8 放行	器件级 LUT 校准
访问方式	板端 SDK（Python 3.6） / HTTP 服务	两条部署路径

2.2 真机误差分解（probe 实测）

对每层注入真实激活并以理想整数矩阵乘为参考，对输出误差做逐列回归分解：

- **per-column 偏移 β_c** ：跨列 std 264-872 raw counts（占残差方差 4-23%），随校准窗口漂移（实测 β 最大漂移 ~200 counts，跨窗口留出改善从 -24.4% 衰减到 -7.8%）；
- **per-column 增益 α_c** ：跨列 std 1.2-2.5%（占 1-3%）；
- **per-element δW** ：绝对扰动 3.7-7.2 int8 counts（占 21-50%），**run 间可复现**（确定性结构分量，REP 平均无效）；
- iid 分量：占比小，REP 平均可抑制。

该分解直接指导第 3 节的三项设计： α/β 由校准消除， δW 由训练鲁棒吸收，iid 由 REP 平均抑制。

3 方法

3.1 架构-硬件噪声联合设计（X0）

基于误差分解与 13 个架构臂（X0 B1）的 160ep v8 单阶段对照，得到三条架构准则：

1. **下采样算子**：MaxPool（零 MACs）与 3×3 conv s2（可学习）之间，conv3s2 全面胜出——真机决定性实验（M7 vs M9，同宽同形唯一差异下采样）实测差 12.1pt（M9 94.43% vs M7 修复校准后最佳 82.33%；三段累计 81.72% → 12.7pt），机理为 **MaxPool 取 max 对加性噪声有偏传播（选择噪声尖峰），卷积光层线性平滑噪声**；conv3s2 另以 0.55pt/M 的效率兼得感受野与通道混合（pool3 中性、blurpool/pool4 负收益）；rf_s2k3 被 ds3pool3 严格支配；
2. **卷积核尺寸**：光计算层宜 1×1。3×3 层 im2col 后权重矩阵更宽， δW 绝对扰动造成的相对误差更大且**不可校准**（M5 vs M6 同流程 -2.6pt）；
3. **通道宽度与下采样算子的耦合**：宽度是 δW 的天然平均器（层输出幅度决定 SNR 底线），但 C0=12 超窄模型（M7）的板端复跑（81.72%，FAKE/md5/probe-SNR 三重验证部署正确）证明其失效主因是 **MaxPool 下采样的噪声有偏传播**——同宽度的 M9（conv3s2）达 94.43%。窄通道需搭配可学习下采样才可用。

3.2 v8 漂移鲁棒量化感知训练

量化：权重 per-channel 对称 int8、激活 per-tensor 非对称 uint8（zero-point 反量化），与硬件语义逐位对齐。噪声注入（v8 配方）：每批重采样

- per-column 偏移（幅度 = probe 实测 $\times$ 1.5 余量）；
- per-column 增益（同上）；
- per-element δW (rms 5.6-10.9 counts $\times$ 1.5)；
- iid $\sigma=260$ counts。

两种协议均验证有效：两阶段（clean 160ep $\rightarrow$ v8 60ep 续训，M5-M8）与单阶段（v8 160ep 从零，M9/M10）。v8 口径整体比 clean 低 0.3-0.9pt，但换来对真机漂移的鲁棒性（M5 两阶段 v8 仅比 clean -0.16pt）。

3.3 双路径部署与逐列校准

路径 A (HTTP)：本地 PyTorch 逐层前向，光计算层 im2col 后经隧道 POST 到板上服务（base64 传输较 JSON 提速 $\sim 3\times$ ）；权重以 md5 缓存。校准用 analyze_layers：对每层记录 (ideal, hw) 对，逐列拟合仿射 (a_j, b_j)，按权重 md5 索引存 npz。

路径 B (板端)：权重导出为 int8 npy + per-channel scale，板上 numpy runner 直接调 compass_matmul ($m \leq 2$ tiling 规避 FPGA 行回绕 bug)。校准用 probe_dump 采集 pairs $\rightarrow$ calibrate_col 逐列最小二乘，输出 α_c/β_c 折叠进反量化（零额外算子），并带 SE、结构 SNR 与 50/50 留出验证。

校准纪律：probe $\rightarrow$ calibrate $\rightarrow$ 跑批必须同窗口背靠背；calib json 不可跨窗口复用。同窗 ABA 实验给出逐列 vs 标量收益 +1.0~2.0pt (C1, c3d, 每配置 $n=1000$: 94.60 vs 92.60, 修复/新增错误比 $\sim 3:1$)。

3.4 器件保护调度

实测发现两个时间尺度：**校准漂移** (~ 20 min, 超窗精度 -12.5pt) 与**热崩溃** (连续 ~ 2 h 输出归零, ValueError 空数组 14 秒内出现; 30 min 冷却不足, ≥ 1 h 冷却 + fresh compass_cali 可恢复)。据此固化调度规则：单次调用 (含校准) < 30 min (校准 ~ 10 min, 跑批 = 30 - 校准耗时)；两次调用间 ≥ 5 min；段精度低于预期 5pt 以上时冷却升级至 15-30 min 并告警；窗口化跑批 (每窗 1-2 段, 窗间长冷却)。该规则下 M10 全量 24 段零崩溃。

4 实验

4.1 设置

- 数据：EuroSAT 27000 张 (train 16200 / val 5400 / test 5400, 严格三分)；
- 真机：Gazelle 8 $\times$ 2 (compass_sdk 1.0.2)；放行判据 EBR ≥ 8 、error_std 基线 $\pm 2\%$ (10% 宽限)、MNIST canary < 0.5 pt、200 张 mini-run 正常；
- 全量评测：test 5400 张分段 (200/240/400 张/段) 真机推理，逐段 fresh 校准；错误明细 (global_idx/true/pred) 入库。

4.2 全量结果

模型	架构要点	MACs/张	训练 test	真机全量 5400	干净参考	gap
M1	大参数基准 VGG	156.6M	97.98 (v4.1 va...	20/20 = 100% (板端抽样 n=20, 全量不可...	97.87 (QAT int8 val)	+2.1
M4	全 3×3 + GAP	17.0M	96.17	94.19% (5086/5400)	95.74 (同量化 numpy, 5170/5400)	-1.55
M5	含 3×3 双卷积	5.31M	96.65	90.17% (4869/5400)	~96.5 (同量化 numpy)	-6.3
M6	全 1×1	1.38M	95.22	92.78% (5010/5400)	~95.5 (同量化 numpy)	-2.7
M7	超窄 C0=12 + MaxPool	0.86M	94.98	81.72% (板端 [0:1800], 架构不匹配 暂停)	~95.0 (v8 test)	-13.3
M8	1×1 + stem k5	2.16M	96.26	87.78%* (4740/5400...)	~95.8 (同量化 numpy)	-8.0
M9	w0.75 + conv3s2	1.52M	95.87/95.69 (双 see...	94.43% (5099/5400)	95.87 (GPU QAT, 部署 seed42)	-1.44
M10	conv3s2 + stem max3	2.56M	96.76/96.56 (双 see...	95.33% (5148/5400 错)	96.76 (GPU QAT, 部署 seed42)	-1.43

*M8 跑批位于器件连续使用 20 h 后的窗口缓降时段，为冷启动复核保留占位。

gap 口径：gap = 真机 - 干净参考。M4–M8 的干净参考为同量化路径 numpy 部署参考 (M4 为全量精确值 95.74%，M5/M6/M8 为分段聚合近似)；M9/M10 为部署权重 (seed 42) 的 GPU QAT test (95.87%/96.76%)。M9/M10 的 C2 同窗口 1000 张抽样为 94.90%/96.40% (gap -0.97/-0.36)，非全量口径，以全量 5400 为准。M1 为板端 20 张抽样，+2.1 = 100% - 97.87 (QAT int8 val)，仅作流程与精度指示。

精度-算力前沿：M10 以 1/61 于 M1 的 MACs 取得 95.33%；M9 以 1/103 的 MACs 取得 94.43%，且 M9/M10 (conv3s2 家族) 构成 v8 噪声口径下的帕累托前沿 (1.5-2.6M 甜点区间)。

4.3 消融与异常分析

- 核尺寸消融 (M5 vs M6)：**同流程下 3×3 层引入 -2.6pt (90.17 vs 92.78)，与 δW 不可校准的机理一致；

2. **下采样算子消融 (M7 vs M9, 决定性实验)**: 同为 C0=12、同通道、同层形状, 唯一差异为 MaxPool vs conv3s2 光下采样——M9 94.43% / M7 82.33% (M7 修复校准管线后最佳 [0:600], 差 12.1pt; 三段累计 [0:1800] 81.72%, 差 12.7pt)。三重验证 (板端 FAKE 对拍 95.04% corr 0.9998、权重 md5 逐文件一致、probe v2 深层 SNR 10-25) 确认部署链正确, 误差在光通路: **MaxPool 取 max 对加性噪声产生有偏传播 (系统性选择噪声尖峰)**, 而卷积光层对噪声做线性平滑; 修复校准管线 (512 图 probe + 深层 8192 行) 仅回升 +0.5pt, 确认非校准问题;
3. **校准时效 (M4, [0:200])**: stale 校准 82.5% → fresh 校准同批 92.5% (+10pt), 确立 20 min 重校准纪律;
4. **校准方法 (C1 ABA, c3d, 每配置 n=1000)**: 标量 92.60 → 逐列 94.60 (+2.0pt), 第三次标量重复 93.60 (窗口内漂移 +1.0pt);
5. **热崩溃 (两次复现)**: 连续 ~2 h 后输出全错; 窗口化调度后 M10 24 段零崩溃;
6. **错误结构**: M4 全量错误 477 条中类 2→6 (22 次)、0→8 (13 次) 等混淆对集中, 与类别光谱相近性一致 (详见错误明细 npz)。

5 结论

本文在真实光计算硬件上完成了遥感 CNN 的系统性部署验证, 证明: **(1)** 架构选择必须以真机噪声结构为先验—— 1×1 光计算层、可学习 conv3s2 下采样与足够的通道宽度构成当前硬件上的最优设计空间; **(2)** 以实测噪声驱动的 v8 QAT 与逐列校准相结合, 可将真机与干净参考的差距压缩到 -1.43pt (M10 95.33% vs GPU QAT 96.76); **(3)** 器件级调度 (30 min 调用预算、冷却协议、窗口化跑批) 是长时程全量验证的必要条件。上述流水线已在多模型、多天的真机实验中复现, 为光学加速器上的在轨智能提供了完整的工程参照。

后续工作: M7 以可学习下采样替代 MaxPool 的再训练 (机理已定位)、错误样本的对抗式难例挖掘、以及基于 v10 噪声模型 (tile 块相关 + 低秩) 的再训练。

参考文献

- [1] 曦智科技. Gazelle 光子计算评估板产品手册 v1.0.1. 2026.
- [2] 曦智科技. Gazelle 光计算硬件平台远程访问操作指南 V1.1. 2026.
- [3] Helber P, et al. EuroSAT: A Novel Dataset and Deep Learning Benchmark for Land Use and Land Cover Classification. IEEE IGARSS, 2019.
- [4] Jacob B, et al. Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference. CVPR, 2018.
- [5] 本队. Optic-SpaceNet 设计报告 / 验证报告 / 技术数据 (初赛、复赛、决赛) . 2026.