

Optic-SpaceNet 光计算迁移实验记录

三个 CNN 模型向 Gazelle 光计算硬件 (8×2 光学矩阵乘法器) 迁移的完整实验轨迹

目录

- [1. 实验目标与硬件约束](#)
- [2. 模型架构演进](#)
- [3. 完整实验路线图](#)
- [4. Phase 0: FP32 基准训练](#)
- [5. Phase 1: QAT 微调 \(FP32→int4\)](#)
- [6. Phase 2: 从零 QAT 训练](#)
- [7. Phase 3: LSQ + 混合精度](#)
- [8. Phase 4: STE + 噪声注入 + 非对称量化](#)
- [9. Phase 5: Mixed Precision \(Conv=int4, Linear=fp32\)](#)
- [10. Phase 6: Gazelle 硬件匹配训练](#)
- [11. 光计算容器迁移](#)
- [12. 关键 Bug 记录](#)
- [13. 精度演进总表](#)
- [14. 文件清单](#)
- [15. 后续方向](#)

1. 实验目标与硬件约束

1.1 目标

将三个 EuroSAT (10 类遥感图像, 64×64) CNN 模型迁移到 Gazelle 光计算硬件上运行, 最大化 int4/int8 量化精度, 保持硬件利用率 >95%。

1.2 Gazelle 硬件参数 (2026-07-09 逆向分析确认)

参数	值	来源
物理 tile	8×2 (k=8, n=2)	GAZELLE_ARCHITECTURE.md
原生激活精度	8-bit	模型名 8a8w12o

参数	值	来源
原生权重精度	8-bit	同上
输出精度	12-bit	—
DAC ENOB	7.5 bits	calibration_params.json
TIA noise MSE	2.85×10^{-7}	同上
硬件线性度	99.4% (相对误差 0.6%)	behavioral_char.json
对齐要求	im2col 展平长度被 8 整除	tile k=8

1.3 精度目标

模型	FP32 基准	int4 目标	int8 目标
Model 1 (VGG)	97.17%	≥ 95%	≥ 96%
Model 2 (SN V1)	90.15%	≥ 88%	≥ 90%
Model 3 (SN V2 KD)	91.44%	≥ 89%	≥ 91%

2. 模型架构演进

2.1 三个模型

	Model 1	Model 2	Model 3
名称	Baseline VGG	OpticSpaceNet V1	OpticSpaceNet V2
设计思路	标准 CNN 基线	硬件对齐 (2×2 conv)	硬件对齐 + KD
Conv 层	6× Conv2d (3×3)	4× Conv2d (1×1/2×2)	同 Model 2
Linear 层	2×	2×	2×
参数量	~2.39M	~268K	~268K
训练方式	标准分类	标准分类	KD (ResNet-18, 97.83%)
硬件对齐率	99.8% (首层 84.4%)	99.6% (stem 37.5%)	同 Model 2

2.2 架构变体演进

Phase 0-3 (原始):
Model 1: Sequential blocks, bias=True, 无 BN

Model 2/3: Sequential blocks, bias=False (Conv), bias=True (Linear)

Phase 4+ (新版, 匹配光计算硬件):

Model 1: Flat arch (conv1_1/bn1_1/...), bias=False (所有层)

Model 2/3: Sequential + BN, bias=False (所有层)

关键变化:

- bias=False: 光计算硬件不支持 bias 加法
- BN 保留: float32 运行, 稳定 QAT 训练
- Flat arch: 首层可独立控制 FP32/QAT

3. 完整实验路线图

Phase 0: FP32 基准训练 (2026-07-05)

└─ Model 1: 97.17% ✓ | Model 2: 90.15% ✓ | Model 3: 91.44% ✓

Phase 1: QAT 微调 (FP32→int4) (2026-07-05)

└─ Model 1: 85.91% ✗ | Model 2: 73.63% ✗ | Model 3: 73.22% ✗

└─ 结论: 微调路线完全失败

Phase 2: 从零 QAT 训练 (2026-07-05 ~ 06)

└─ Model 1: 91.17% △ | Model 2: 81.20% △ | Model 3: 83.26% △

└─ 结论: 有效但差距仍大 (6-9%)

Phase 3: LSQ + 混合精度 (2026-07-06)

└─ 结论: LSQ+ 失败 (61.72%), STE 方案被选定

Phase 4: STE + 非对称量化 + 噪声 (2026-07-06 ~ 07)

└─ Model 1: 96.46% int4 ✓ (optic_qat_v3, flat arch + BN)

└─ Model 2: 74.35% int4 ✗ (bug: Conv QAT 全关)

└─ Model 3: 78.26% int4 ✗ (bug: Conv QAT 全关)

Phase 5: Mixed Precision (Conv=int4, Linear=fp32) (2026-07-07)

└─ Model 1: 98.26% int4 ★★ | Model 2: 91.26% int4 ★

└─ Model 3: 91.13% int4 ★

Phase 6: Gazelle 硬件匹配训练 (2026-07-09) ← NEW

└─ Model 2 v2 (int4, QAT 全开): 91.06% ★ 超越 FP32 基准!

└─ Model 2 v3 (int8, Gazelle 噪声): 93.11% ★★ 最佳!

└─ Model 3 v2 (KD+int4, QAT 全开): 91.50% ★ 超 FP32 KD 基准!

容器迁移 (2026-07-09)

└─ optic_inference_phase4.py, optic_inference_mixed.py
└─ QAT eval 模式：精度与训练一致，Optic 模式：osimulator 硬件仿真

4. Phase 0: FP32 基准训练

	Model 1	Model 2	Model 3
脚本	model1_baseline.py	model2_spacenet_v1.py	model3_spacenet_v2.py
权重	baseline_vgg.pth	spacenet_v1.pth	spacenet_v2_distilled.pth
Epochs	60	80	100 + KD
最佳准确率	97.17%	90.15%	91.44%
教师准确率	—	—	97.83% (ResNet-18)
硬件对齐率	99.8%	96.3%	96.3%

结论: FP32 基准确立，Model 1 最强，Model 2/3 受限于参数量但有硬件对齐优势。

5. Phase 1: QAT 微调 (FP32→int4)

方案: 加载 FP32 权重 → BN 融合 → QAT 层替换 → 低 lr 微调 15-20 epochs

模型	FP32	QAT 微调	损失	判定
Model 1	97.17%	85.91%	-11.26%	X
Model 2	90.15%	73.63%	-16.52%	X
Model 3	91.44%	73.22%	-18.22%	X

根因: FP32 权重依赖精细精度，突然 int4 量化破坏特征。15-20 epoch + 低 lr 无法逃逸坏局部最小值。

6. Phase 2: 从零 QAT 训练

方案: 随机初始化 → epoch 1 起全程 int4 伪量化 → 模型从未见过 float32

模型	FP32 基准	Phase 1	Phase 2	vs Phase 1	与 FP32 差距
Model 1	97.17%	85.91%	91.17%	+5.26%	-6.00%
Model 2	90.15%	73.63%	81.20%	+7.57%	-8.95%
Model 3	91.44%	73.23%	83.26%	+10.03%	-8.18%

结论: 从零 QAT 比微调提升 5-10%，验证了"从零学 int4 兼容特征"策略。但仍有 6-9% 差距。
问题: 动态 scale 不稳定、首/末层信息损失、Model 1 过拟合、Model 2/3 收敛慢。

7. Phase 3: LSQ + 混合精度

方案: LSQ 可学习 scale + 首层/末层 FP32

模型	模式	结果	问题
Model 1	LSQ+	61.72%	LSQ+ input_scale 初始化错误 + uint4 激活损失大
Model 1	STE	98.07% (训练中 FP32 模式最佳)	成功, 但 int4 eval 仅 96.46%

结论: LSQ+ 方案废弃。STE（动态 scale + 噪声注入）被选定为后续方向。

8. Phase 4: STE + 噪声注入 + 非对称量化

方案设计

- **QAT 模块:** optic_qat_v2.py (初版), optic_qat_v3.py (修复版)
- **量化:** 激活 uint4 [0,15] → 修复为 int8; 权重 int4 [-8,7]
- **噪声:** STE 训练时向权重注入高斯噪声 (std=0.05scale → 0.02scale)
- **架构:** bias=False (匹配光硬件), BN 保留 (float32)
- **训练器:** train_phase4_runner.py (Phase4Trainer)

8.1 原始版 (optic_qat_v2, Sequential arch)

模型	脚本	Int4	Float32	问题
Model 1 LSQ+	model1_baseline_phase4.py --mode lsqplus	61.72%	—	LSQ+ 失败
Model 2 STE	model2_spacenet_v1_phase4.py	—	—	未完成 (训练中 bug)

Bug: first_layer_fp32=True 在 Sequential 架构中把所有 Conv 层都关了 (QAT Conv: 0)

8.2 修复版 (optic_qat_v3, flat+BN arch)

模型	Int4 (eval)	Float32	训练最佳 (FP32 模式)	备注
Model 1 STE	96.46%	98.06%	98.07%	✓ 成功, 量化损失仅 1.6%
Model 2 STE	74.35%	92.81%	92.87%	X Conv QAT 全关 (bug 未修复)
Model 3 KD STE	78.26%	93.15%	93.22%	X Conv QAT 全关 (bug 未修复)

关键发现: Model 2/3 的 QAT Conv: 0 — 训练时 Conv 在 FP32 模式, eval 时 enable_qat() 才打开。模型从未在训练中见过 int4 Conv 量化。

9. Phase 5: Mixed Precision (Conv=int4, Linear=fp32)

方案

- **QAT 模块:** optic_qat_v3.py (Conv→int4 QAT, Linear→fp32)
- **训练器:** train_mixed_runner.py (MixedPrecisionTrainer)
- **策略:** Conv 在光计算 (int4), Linear 在电计算 (fp32)
- **架构:** Flat+BN (Model 1), Sequential+BN (Model 2/3), Conv=bias=False, Linear=bias=True

结果

模型	脚本	Int4	Float32	FP32 基准	判定
Model 1	model1_baseline_mixed.py	98.26%	97.91%	97.17%	★★ 超越 FP32!

模型	脚本	Int4	Float32	FP32 基准	判定
Model 2	model2_spacenet_v1_mixed.py	91.26%	84.33%	90.15%	★ 超越 FP32!
Model 3 KD	model3_spacenet_v2_mixed.py	91.13%	86.33%	91.44%	★ 接近 FP32 KD

关键发现: Mixed 策略让所有 Conv 层 QAT 全开（无 first_layer_fp32 bug），模型真正学会了 int4 量化。Model 1/2 的 int4 精度甚至超过了 FP32 基准（QAT 正则化效应）。

10. Phase 6: Gazelle 硬件匹配训练

10.1 硬件逆向分析 (2026-07-09)

基于 osimulator/GAZELLE_ARCHITECTURE.md 逆向报告的关键发现:

发现	影响
硬件线性度 99.4% (误差 0.6%)	硬件几乎理想，量化精度是唯一瓶颈
原生精度 8a8w12o	硬件支持 int8 权重！我们一直用 int4 太保守
DAC ENOB= 7.5 , TIA noise= 5.3e-4	训练噪声 std=0.02*scale 是实际的 12 倍
tile 8×2	Model 2/3 的 2×2 conv (patch=32/64) 完美对齐 8 的倍数

10.2 修复方案

Phase 4 v2 (修复 Conv QAT 全关 bug):

- 使用 optic_qat_v3 的 prepare_model_v3（无 first_layer_fp32 参数）
- Conv+Linear 全 int4 QAT, bias=False
- 脚本: model2_spacenet_v1_phase4_v2.py , model3_spacenet_v2_phase4_v2.py

Phase 4 v3 (int8 权重 + Gazelle 硬件噪声):

- 使用新模块 optic_qat_v4.py
- int8 权重匹配硬件原生精度 (256 级 vs int4 的 16 级)
- GazelleNoiseInjector: DAC ENOB=7.5 + TIA noise
- 首层 stem FP32 (对齐率仅 37.5%, 电计算更划算)

- 其余 Conv+Linear 全 int8 QAT
- 脚本: `model2_spacenet_v1_phase4_v3.py`

10.3 结果

#	脚本	模型	配置	Int 精度	FP32 精度	耗时	判
1	<code>model2_..._phase4_v2.py</code>	Model 2	int4, QAT 全开	91.06%	87.54%	75min	★ F 基
2	<code>model3_..._phase4_v2.py</code>	Model 3	int4+KD, QAT 全开	91.50%	80.98%	119min	★ F K 准
3	<code>model2_..._phase4_v3.py</code>	Model 2	int8+Gazelle, 修复	93.11%	93.02%	81min	★ 最

10.4 分析

- **v2 int4 (91.06%)**: 修复后比旧版 (74.35%) 提升 **+16.71%**, 超过 FP32 基准 (90.15%)
- **v3 int8 (93.11%)**: 匹配硬件原生 8-bit, 量化损失仅 0.09%, **比 FP32 基准高 2.96%**
- **QAT 正则化效应**: int4/int8 精度 > float32 模式精度, 量化噪声充当了有益正则化
- **int4 vs int8**: int8 比 int4 高 2.05%, 代价是 2× 权重存储 (光计算中可接受)

10.5 v3 开发中的 Bug

`optic_qat_v4._convert_to_v4` 的 `_first` 标志使用 Python 不可变 bool 参数, 嵌套递归时子级修改不传播到父级, 导致所有 Sequential 块内的 Conv 都被当作"首层"关闭 QAT。已修复: 改用单元素列表 `[_first]` 传递可变引用。

11. 光计算容器迁移

11.1 容器代码

文件	用途	模式
<code>optic_layers.py</code>	光计算核心库 (OpticalEngine, OpticConv2d, OpticLinear)	推理
<code>optic_inference.py</code>	FP32 基准模型容器 (Part A)	Native + Optic

文件	用途	模式
noise_robustness.py	FP32 模型噪声鲁棒性 (Part B)	噪声扫描
noise_robustness_v2.py	int4 模型噪声鲁棒性	QAT eval
optic_inference_phase4.py	Phase 4 模型容器 (NEW)	QAT(默认) + Optic(--optic)
optic_inference_mixed.py	Mixed 模型容器 (NEW)	QAT(默认) + Optic(--optic)

11.2 容器评估模式

QAT 模式 (默认) — 匹配训练精度:

```
python optic_inference_phase4.py # 全量 QAT eval
python optic_inference_phase4.py --quick 50 # 快速测试
```

- 加载模型 + prepare_model_v3/v4 → enable_qat() → int4/int8 伪量化
- 精度与训练日志完全一致
- batch=1 默认, 秒级出结果

Optic 模式 (--optic) — 硬件级仿真:

```
python optic_inference_phase4.py --optic --quick 5
```

- build_optical_model() → OpticConv2d + OpticalEngine → osimulator
- 真实硬件仿真 (im2col 展开, 补零对齐, 物理噪声)
- 慢 (每 batch ~3-8 分钟), 建议 --batch 1 --quick 5

11.3 容器 osimulator 兼容性修复

问题	修复
_matmul_real 返回 Tensor 非 numpy	isinstance(raw_result, torch.Tensor) 兼容
输入量化 signed=False + zero_point 未补偿	反量化公式: $scale * result_int + in_zp * w_scale * col_sum_w$
print_interval 逐 batch 过于密集	默认每 10% 打印一次, Optic 模式保持逐 batch
默认 batch=32 产生 131K 行 im2col 矩阵	改为 batch=1, --batch N 可选

11.4 容器验证结果 (Phase4 QAT 模式, 全量 5400 张)

模型	训练 Int4/Int8	容器 Int4/Int8	误差
Model 1 Phase4 STE	96.46%	96.44%	-0.02% ✓
Model 2 Phase4 STE	74.35%	74.70%	+0.35% ✓
Model 3 Phase4 KD STE	78.26%	78.06%	-0.20% ✓

容器精度与训练完全一致。Model 2/3 偏低是因为旧版训练的 Conv QAT bug，不是容器问题。

12. 关键 Bug 记录

Bug #1: QAT eval 模式未施加量化

- `if self._qat_enabled and self.training:` → `model.eval()` 时跳过量化
- 修复: `if self._qat_enabled:`

Bug #2: first_layer_fp32 在 Sequential 中禁用所有 Conv

- `_first` 是不可变 bool, 嵌套递归不更新父级
- 影响: Phase 4 original, Phase 4 fixed Model 2/3, Phase 6 v3 (初版)
- 修复: Phase 4 v2 直接用新版 `prepare_model_v3` (无此参数); Phase 6 v3 使用 `[_first]` 列表

Bug #3: _matmul_real 输入 unsigned 量化 zero_point 未补偿

- `quantize_to_int(signed=False)` 产生 `in_zp ≠ 0`, 但反量化只用 `result * scale`
- 修复: `result = scale * result_int + in_zp * w_scale * col_sum_w`

Bug #4: osimulator 不接受负数输入索引

- `signed=True` 量化产生负值 → `osimulator index -105 out of bounds`
- 修复: 输入用 `uint4` (unsigned), 硬件只接受非负

Bug #5: LSQ+ input_scale 初始化导致训练停滞

- `input_scale=1.0` → 激活量化到 3-4 级别 → 梯度消失
 - 修复: 输入改动态 scale, 权重保留 LSQ
-

13. 精度演进总表

Model 1 (Baseline VGG, ~2.39M params, FP32=97.17%)

Phase	方案	量化	Int 精度	vs FP32	状态
1	QAT 微调	int4	85.91%	-11.26%	×
2	从零 QAT	int4	91.17%	-6.00%	△
3	LSQ+	int4	61.72%	-35.45%	×
4	STE (修复)	int4	96.46%	-0.71%	✓
5	Mixed	Conv=int4, Linear=fp32	98.26%	+1.09%	★★

Model 1 结论: Mixed 策略最佳 (98.26%), 已达成目标。

Model 2 (SpaceNet V1, ~268K params, FP32=90.15%)

Phase	方案	量化	Int 精度	vs FP32	状态
1	QAT 微调	int4	73.63%	-16.52%	×
2	从零 QAT	int4	81.20%	-8.95%	△
4	STE (bug)	int4	74.35%	-15.80%	×
5	Mixed	Conv=int4, Linear=fp32	91.26%	+1.11%	★
6 v2	Phase4 修复	int4, QAT 全开	91.06%	+0.91%	★
6 v3	Gazelle 匹配	int8, 首层 FP32	93.11%	+2.96%	★★

Model 2 结论: v3 int8 (93.11%) 最佳。从旧版 74.35% 到 93.11%，提升 **+18.76%**。

Model 3 (SpaceNet V2 KD, ~268K params, FP32=91.44%)

Phase	方案	量化	Int 精度	vs FP32	状态
1	QAT 微调	int4	73.22%	-18.22%	×
2	从零 KD+QAT	int4	83.26%	-8.18%	△
4	KD+STE (bug)	int4	78.26%	-13.18%	×
5	KD+Mixed	Conv=int4, Linear=fp32	91.13%	-0.31%	★
6 v2	KD+Phase4 修复	int4, QAT 全开	91.50%	+0.06%	★

Model 3 结论: v2 int4+KD (91.50%) 最佳，已超越 FP32 KD 基准。待做 int8+KD 版本。

总体最佳精度

模型	最佳方案	最佳 Int 精度	FP32 基准	提升
Model 1	Mixed (Conv=int4, Linear=fp32)	98.26%	97.17%	+1.09%
Model 2	Phase4 v3 int8 + Gazelle	93.11%	90.15%	+2.96%
Model 3	Phase4 v2 int4 + KD	91.50%	91.44%	+0.06%

14. 文件清单

训练脚本

文件	Phase	用途	产出权重
model1_baseline.py	0	FP32 训练	baseline_vgg.pth
model2_spacenet_v1.py	0	FP32 训练	spacenet_v1.pth
model3_spacenet_v2.py	0	FP32 KD 训练	spacenet_v2_distilled.pth teacher_resnet18.pth
model1_baseline_qat.py	1	QAT 微调	baseline_vgg_qat.pth
model2_spacenet_v1_qat.py	1	QAT 微调	spacenet_v1_qat.pth
model3_spacenet_v2_qat.py	1	QAT 微调	spacenet_v2_qat.pth
model1_baseline_int4.py	2/3	从零 QAT/LSQ	baseline_vgg_int4.pth
model2_spacenet_v1_int4.py	2/3	从零 QAT/LSQ	spacenet_v1_int4.pth
model3_spacenet_v2_int4.py	2/3	从零 KD+QAT/LSQ	spacenet_v2_int4.pth
model1_baseline_phase4.py	4	Phase4 STE/LSQ+	baseline_vgg_phase4_ste.p _lsqplus.pth
model2_spacenet_v1_phase4.py	4	Phase4 (bug)	spacenet_v1_phase4_ste.pt
model3_spacenet_v2_phase4.py	4	Phase4 KD (bug)	spacenet_v2_phase4_ste.pt
model1_baseline_mixed.py	5	Mixed	baseline_vgg_mixed_ste.pt
model2_spacenet_v1_mixed.py	5	Mixed	spacenet_v1_mixed_ste.pth
model3_spacenet_v2_mixed.py	5	Mixed KD	spacenet_v2_mixed_ste.pth

文件	Phase	用途	产出权重
model2_spacenet_v1_phase4_v2.py	6	Phase4 v2 int4 (修复)	spacenet_v1_phase4_v2_ste
model3_spacenet_v2_phase4_v2.py	6	Phase4 v2 KD+int4 (修复)	spacenet_v2_phase4_v2_ste
model2_spacenet_v1_phase4_v3.py	6	Phase4 v3 int8+Gazelle	spacenet_v1_phase4_v3_int

核心库

文件	版本	用途
optic_layers.py	v1	光计算推理核心 (OpticalEngine, OpticConv2d, 噪声注入器)
optic_qat.py	v1	QAT 初版: fake_int4, LSQ, QATConv2d, BN 融合
optic_qat_v2.py	v2	QAT Phase4 初版: uint4/int4 非对称, LSQ+, QATConv2d_v2
optic_qat_v3.py	v3	QAT 修复版: int8 激活, BN 保留, 无 first_layer_fp32
optic_qat_v4.py	v4	Gazelle 硬件匹配: int8 权重, GazelleNoiseInjector, 首层 FP32
train_phase4_runner.py	—	Phase4 训练器 (Phase4Trainer)
train_mixed_runner.py	—	Mixed 训练器 (MixedPrecisionTrainer)

容器代码

文件	用途
optic_inference.py	FP32 基准模型容器
noise_robustness.py	FP32 噪声鲁棒性
noise_robustness_v2.py	int4 噪声鲁棒性
optic_inference_phase4.py	Phase4 模型容器 (QAT + Optic 双模式)
optic_inference_mixed.py	Mixed 模型容器 (QAT + Optic 双模式)

文档

文件	用途
EXPERIMENTS.md	本文件: 完整实验记录
PHASE4_DESIGN.md	Phase 4 设计文档
OPTIC_QAT_README.md	QAT 技术文档
复赛-test.md	竞赛设计文档
log.md	原始训练日志 (所有 console 输出)
log_mixed.md	Mixed 训练日志
log_phase4_fixed.md	Phase4 修复版日志
osimulator/GAZELLE_ARCHITECTURE.md	Gazelle 硬件逆向报告

15. 后续方向

15.1 短期 (本周)

1. **Model 3 int8+KD 训练**: 将 v3 int8 方案移植到 Model 3 (KD), 预期 92-93%
2. **Model 1 int8 训练**: Phase4 v3 方案移植到 Model 1, 预期 97-98%
3. **容器 Optic 模式全量验证**: 用 `--optic` 模式对最佳模型跑完整 osimulator 评估

15.2 中期 (容器部署)

1. **选取最佳模型部署**:
 - Model 1 Mixed (98.26% int4) — 精度最高, 但模型较大 (2.39M)
 - **Model 2 v3 int8 (93.11%) — 推荐首选**: 精度高, 模型小 (268K), 硬件对齐率 99.6%
 - Model 3 v2 int4+KD (91.50%) — 有 KD 加持

2. **容器内完整验证**:

```
# 全量 QAT 验证
python optic_inference_phase4.py
python optic_inference_mixed.py

# Optic 模式硬件仿真 (需 osimulator license)
python optic_inference_phase4.py --optic --quick 50
```

3. **导出 ONNX/量化为实际 int8 整数**: 将 QAT 权重导出为可直接部署的 int8 格式

15.3 长期 (持续优化)

1. **更大模型**: 扩宽 SpaceNet 通道 (16→32→64→32) 补偿量化损失

2. **渐进式量化**: 训练前半段 int8, 后半段 int4, 平滑过渡
3. **Distillation from FP32 teacher to int4 student**: 用 FP32 Model 1 做教师引导 int4 Model 2/3
4. **硬件在环训练**: 将 osimulator 实际输出作为训练信号, 端到端优化

15.4 精度路线图

当前最佳 → 短期目标 → 长期目标

Model 1: 98.26% (int4 Mixed) → 98.5% (int8) → 98.5%+

Model 2: 93.11% (int8 v3) → 93.5% (int8+KD) → 94%

Model 3: 91.50% (int4+KD v2) → 92.5% (int8+KD) → 93%

文档版本: v2.0 | 最后更新: 2026-07-09 | 新增 Phase 4-6 + 容器迁移 + Gazelle 硬件分析