

三模型光计算迁移实验 · 总结报告

本文档由 EXPERIMENTS.md 浓缩而成，面向报告/答辩使用。

主线：三个 EuroSAT (10 类遥感, 64×64) CNN → **Gazelle 光计算硬件 (8×2 光学矩阵乘法器)** 的量化迁移。

聚焦维度：**实现方式 / 参数量 / 参数精度 / 准确率 / 运行速率**。

数据基准：Bug #11 (test⊂train 泄漏) 修复后的**干净三分 split** (train 16200 / val 5400 / test 5400)；历史 leaky 数字一律标注作废。

1. 一句话结论

- Model 1 (VGG)**：参数量最大 (~2.39M)、精度最高，但计算量是另两个模型的 **~150×**，真机全量不可行 (~9 天)。
- Model 2/3 (SpaceNet)**：参数量仅 ~268K，**真机 int8 全量 5400 张 ≈ 90.4% / 90.3%，单张 ~2.5s**，是可落地部署的轻量主力。
- 量化配方定型**：stem 首层 FP32 (电计算) + 其余 Conv/Linear int8 + Gazelle 噪声训练，与 osimulator 8a8w 推理路径天然对齐，真机 gap 仅 ~1.6 点。
- KD 不带来真机增益**：Model 2 (无 KD) 与 Model 3 (KD) 真机精度打平 (90.43% vs 90.28%)、硬件 gap 基本相等 (~1.6 点)。

2. 硬件平台 (Gazelle, 2026-07-09 逆向确认)

参数	值	影响
物理 tile	8×2 (k=8, n=2)	im2col 展平长度须被 8 整除
原生精度	8a8w12o (8-bit 激活 / 8-bit 权重 / 12-bit 输出)	硬件支持 int8，不必退守 int4
DAC ENOB	7.5 bits	训练噪声匹配项
TIA 噪声 σ	≈5.3e-4 (MSE 2.85e-7)	训练噪声匹配项
硬件线性度	99.4% (相对误差 0.6%)	硬件近乎理想，量化精度是唯一瓶颈

关键认知：硬件本身几乎理想（线性度 99.4%），所有精度损失来自量化与噪声建模，而非硬件缺陷。

3. 三模型架构与实现方式（横向总览）

	Model 1	Model 2	Model 3
名称	Baseline VGG	OpticSpaceNet V1	OpticSpaceNet V2
设计思路	标准 CNN 基线	硬件对齐 (2×2 conv)	硬件对齐 + 知识蒸馏 (KD)
结构	6× Conv2d (3×3) + 2× Linear	4× Conv2d (1×1/2×2) + 2× Linear	同 Model 2
参数量	~2.39M	~268K	~268K
训练方式	标准分类	标准分类	KD (教师 ResNet-18, 97.83%; T=4.0, α=0.7)
bias	False (Phase4+)	False	False
BN	保留 (FP32 运行)	保留	保留
硬件对齐率	99.8% (首层 84.4%)	99.6% (stem 37.5%)	99.6% (同 M2)
总 MOPs/张	156.63M	1.05M	1.05M

架构差异本质：Model 1 是大而精的通用基线；Model 2/3 为硬件量身定做（2×2 conv 使展平长度完美对齐 8×2 tile），用 ~1/9 的参数换 ~1/150 的计算量。

4. 纵向发展：各模型量化精度演进

横轴为量化方案迭代，纵轴为精度。val = 干净验证集；标注「作废」者为 Bug #11 leaky 数据。

4.1 Model 1 (Baseline VGG, FP32 基准 97.17%)

Phase	实现方式	参数精度	精度	vs FP32	判定
0	FP32 基准	fp32	97.17%	—	—
1	QAT 微调 (FP32→低比特)	int4	85.91%	-11.26%	X

Phase	实现方式	参数精度	精度	vs FP32	判定
2	从零 QAT	int4	91.17%	-6.00%	△
3	LSQ+ (旧版有 bug)	int4	61.72%	-35.45%	✗
4	STE + 噪声注入	int4	96.46%	-0.71%	✓
5	Mixed (Conv int4 / Linear fp32)	混合	98.26%	+1.09%	★★
6	v3 Gazelle 匹配 (变体 A, conv1_1 电计算)	int8	97.87% (val)	+0.70%	★
6	v3 Gazelle 匹配 (变体 B, conv1_1+conv3_2 电计算)	int8	98.02% (val)	+0.85%	★

Model 1 轨迹要点：微调路线 (Phase 1) 彻底失败；从零 QAT (Phase 2) 有效但仍差 6%；STE (Phase 4) 把 int4 损失压到 0.71%；Mixed (Phase 5) 与 int8 v3 (Phase 6) **双双反超 FP32 基准**。变体 A/B 统计打平 (Δ 0.15%)，B 多回退一层到电计算、精度不降反微升、osim 提速 ~24% → **性价比更高**。

4.2 Model 2 (SpaceNet V1，FP32 基准 90.15%)

Phase	实现方式	参数精度	精度	vs FP32	判定
0	FP32 基准	fp32	90.15%	—	—
1	QAT 微调	int4	73.63%	-16.52%	✗
2	从零 QAT	int4	81.20%	-8.95%	△
4	STE (Conv QAT 全关 bug)	int4	74.35%	-15.80%	✗
5	Mixed	Conv int4 / Linear fp32	91.26%	+1.11%	★
6 v2	Phase4 修复 (QAT 全开)	int4	91.06%	+0.91%	★
6 v3	Gazelle 匹配 (stem FP32 + Gazelle 噪声)	int8	92.06% (干净 val)	+1.91%	★★
LSQ+	LSQ+ 修复 (可学习 scale/zp)	int8	92.80%	+2.65%	★
—	osimulator 真机 (全量 5400, 干净)	int8 (stem 电计算)	90.43%	+0.28%	★

Model 2 轨迹要点：int4 路线天花板 ~91%（受 stem 训练/推理不一致 + int4→int8 网格不对齐三重限制，详见 EXPERIMENTS §16）；切换到 **int8 + stem-FP32 + Gazelle 噪声**后 val 升至 92.06%；**真机全量 90.43%，反超原 FP32 基准 +0.28%**。

4.3 Model 3 (SpaceNet V2 + KD，FP32 基准 91.44%)

Phase	实现方式	参数精度	精度	vs FP32	判定
0	FP32 KD 基准 (ResNet-18 教师 97.83%)	fp32	91.44%	—	—
1	QAT 微调	int4	73.22%	-18.22%	X
2	从零 KD+QAT	int4	83.26%	-8.18%	△
4	KD+STE (Conv QAT 全关 bug)	int4	78.26%	-13.18%	X
5	KD+Mixed	Conv int4 / Linear fp32	91.13%	-0.31%	★
6 v2	KD+Phase4 修复	int4	91.50%	+0.06%	★
6 v3	KD+Gazelle 匹配	int8	91.83% (干净 val)	+0.39%	★★
—	osimulator 真机 (全量 5400, 干净)	int8 (stem 电计算)	90.28%	-1.16%	★

Model 3 轨迹要点：与 Model 2 同架构，全程叠加 KD（ResNet-18 教师）。v3 int8+KD val 91.83%；真机全量 90.28%，略低于其 KD 基准（因 KD 基准 91.44% 本就高于 M2 的 FP32 基准）。

4.4 三模型共同的方法论拐点

拐点	失败方案	成功方案	根因
微调 vs 从零	FP32→int4 微调 (Phase 1, 全员 -11~-18%)	从零 QAT (Phase 2)	FP32 权重依赖精细精度，突变量化破坏特征
int4 vs int8	int4 (16 级) 上限 ~91%	int8 (256 级, 匹配硬件原生)	int4→int8 网格不对齐 (max/7 vs max/127)，非无损
stem 量化	stem QAT (训练/推理分布不一致)	stem 保留 FP32 电计算	stem 对齐率仅 37.5%，电计算更划算且消除 BN 偏移
噪声建模	STE 通用高斯噪声	Gazelle 噪声 (DAC ENOB 7.5 + TIA)	训练噪声匹配真实硬件 → 真机 gap 收敛到 ~1.6 点

5. 横向对比：五大维度同台对比

以下全部基于**干净 split**的最终可部署配置（Model 2/3 = v3 int8；Model 1 = int8 v3 变体 A/B）。

5.1 参数量

模型	参数量	结构	相对规模
Model 1	2.39M	6×Conv(3×3) + 2×Linear	8.9×
Model 2	268K	4×Conv(1×1/2×2) + 2×Linear	1×
Model 3	268K	同 Model 2	1×

5.2 参数精度（部署配置）

模型	权重精度	激活精度	首层	备注
Model 1 A	int8	int8	conv1_1 FP32 电计算	光计算占比 97.74%
Model 1 B	int8	int8	conv1_1 + conv3_2 FP32 电计算	光计算占比 73.64%，提速 ~24%
Model 2	int8	int8	stem FP32 电计算	匹配硬件原生 8a8w
Model 3	int8	int8	stem FP32 电计算	同 M2，外加 KD 训练

统一原则：**stem 首层 FP32 电计算（对齐率低） + 其余层 int8 光计算**。所有 int8 权重均匹配 Gazelle 原生 8-bit，避免 int4→int8 重网格损失。

5.3 准确率

模型	FP32 基准	int8 val (干净)	int8 test (干净)	osim 真机 (全量/抽样)	真机 vs FP32
Model 1 A	97.17%	97.87%	97.89%	98.00% (q50 抽样)	+0.83%
Model 1 B	97.17%	98.02%	97.96%	100.00% (q50 抽样)	+2.83% (抽样)
Model 2	90.15%	92.06%	92.20%	90.43% (全量 5400)	+0.28%
Model 3	91.44%	91.83%	fp32 test 92.13% ¹	90.28% (全量 5400)	-1.16%

¹ Model 3 的 --qat 推理路径走 int4 (84.59%)，给不了 int8 test 数；其 int8 test 数由 osimulator 真机取得 = 90.28%。

真机 hardware gap (osim 真机 – 干净 int8 QAT，同 test 集)：

模型	int8 QAT test	osim 真机	纯硬件噪声 gap
Model 2	92.20%	90.43%	-1.77%
Model 3	(缺, 以 fp32 test 92.13% 推)	90.28%	~-1.6~1.8%

→ 两模型真机 gap 基本相等 (~1.6 点)，源自 osim 物理噪声 (DAC ENOB 7.5 + TIA $\sigma=5.31$)；Gazelle 噪声训练已吸收大部分，残留 ~1.6 点。

精度目标达成情况：

模型	int8 目标	int8 实际 (val)	达成
Model 1	≥ 96%	97.87% / 98.02%	✓
Model 2	≥ 90%	92.06%	✓
Model 3	≥ 91%	91.83%	✓

5.4 运行速率与计算开销

模型	总 MOPs/张	光计算占比	电计算层	osim 单张耗时	osim 全量 5400	训练耗时
Model 1 A	156.63M	97.74%	conv1_1	~150s 量级 (q50 抽样)	~9 天 (不可行, 仅抽样)	280 min
Model 1 B	156.63M	73.64%	conv1_1+conv3_2	~150s 量级 (提速 ~24%)	同上	276 min
Model 2	1.05M	90.65%	stem	~2.5s	13357s (~3.7h)	72.8 min
Model 3	1.05M	90.65%	stem	~2.5s	13370s (~3.7h)	90.4 min

Model 2/3 真机全量统计：引擎各调用 27000 次 (5 光计算层 × 5400 张)，总运算量 5.15e+09 MACs，硬件对齐率 99.6%。

速率结论：

- Model 2/3 ≈ 0.4 张/秒 (~24 张/分)，全量 5400 张 ~3.7h 可一次跑完 → 可落地部署。
- Model 1 计算量是 Model 2/3 的 ~150× (156.6M vs 1.05M)，单张慢 ~60× (~150s vs ~2.5s)，全量 ~9 天不可行 → 只能抽样验证 (q50：A 98% / B 100%)。

- 光计算占比均 $\geq 90\%$ (Model 1 A 97.7% / Model 2-3 90.65%)，满足部署阈值。

注：osim 耗时为光计算硬件**物理仿真**时间 (Python 模拟光学矩阵乘 + 补零对齐 + 物理噪声)，反映模型→硬件映射的开销结构，并非最终芯片上墙钟时间。

5.5 五维横向对比总表

维度	Model 1	Model 2	Model 3
实现方式	标准 VGG + Mixed/int8 QAT	硬件对齐 SpaceNet + int8 QAT	硬件对齐 SpaceNet + KD + int8 QAT
参数量	2.39M	268K	268K
参数精度	int8 (首层 fp32)	int8 (stem fp32)	int8 (stem fp32)
准确率 (真机)	98.0/100.0% (q50 抽样)	90.43% (全量)	90.28% (全量)
运行速率	~150s/张, 全量不可行	~2.5s/张, 3.7h 全量	~2.5s/张, 3.7h 全量
光计算占比	97.7% (A) / 73.6% (B)	90.65%	90.65%
可部署性	△ (仅抽样)	★★★★	★★★★

6. 部署推荐

场景	推荐	理由
轻量落地 (首选)	Model 2 v3 int8	268K 参数、真机 90.43%、 反超 FP32 基准 +0.28% 、全量 3.7h 可验证
同等轻量 + KD	Model 3 v3 int8+KD	与 M2 真机打平 (90.28%)，若需 KD 故事线可选
最高精度 (受算力)	Model 1 int8 变体 B	val 98.02%、q50 真机 100%，但 2.39M 参数 + ~150s/张，仅适合算力充裕场景

统一部署配置： stem FP32 电计算 + 其余 Conv/Linear int8 光计算 + Gazelle 噪声训练权重，光计算占比 $\geq 90\%$ ，硬件对齐率 99.6%。

7. 关键技术要点 (报告 Takeaways)

- 1. **硬件先于模型**：先逆向 Gazelle (8×2 / 8a8w / 线性度 99.4%)，再据此设计模型 (2×2 conv 对齐 tile) 与训练 (int8 + Gazelle 噪声)，而非训练后再迁就硬件。
- 2. **int8 > int4**：硬件原生 8-bit，int4 路线存在不可消除的网格不对齐损失 (~6%)；int8 配方让真机 gap 收敛到 ~1.6 点。
- 3. **首层 FP32 是关键**：stem 对齐率仅 37.5%，保留电计算既高效又消除 BN 训练/推理分布偏移。
- 4. **从零 QAT > 微调**：低比特量化必须从零训练，让模型从未见过 fp32；微调路线全员失败。
- 5. **噪声匹配决定真机 gap**：训练时注入 Gazelle 物理噪声 (DAC ENOB 7.5 + TIA $\sigma=5.3e-4$)，真机精度基本保住。
- 6. **KD 未带来真机增益**：Model 2 (无 KD) 与 Model 3 (KD) 真机精度/gap 基本相等 → KD 提升噪声鲁棒性的假设**不被全量数据支持**。
- 7. **数据洁净性是底线**：Bug #11 (test⊂train 泄漏) 曾让 osim 虚高 ~3 点 (93.28% / 93.26% 作废)；干净 split 后真值 90.43% / 90.28%。

附：数据来源与可信度

数据类型	来源	可信度
训练 val / test (QAT)	PyTorch 伪量化，干净 split	✓ 干净泛化数
osim 真机 (Model 2/3)	全量 5400 ，COMPASS 8a8w12o 仿真	✓ 真值 (log_optic_int8_new.md / log_optic_kd_new.md)
osim 真机 (Model 1)	q50 抽样 (全量 ~9 天不可行)	△ 小样本，仅作机制验证
历史 leaky osim (93.28/93.26%)	Bug #11 前	X 作废

完整实验轨迹、Bug 记录、int4 困境分析见 EXPERIMENTS.md (§11.13 为 Model 2/3 全量真机定稿)。