



集创赛


# 面向航空航天在轨计算的 光学 CNN 加速系统 —— Optic-SpaceNet

多模型架构量化迁移 × 曦智 Gazelle 光计算平台

曦智科技 命题

CICC 1003564


# 在轨遥感计算的结构性困境



| 评价指标           | 电子计算<br>(GPU/ASIC) | 光学计算核<br>(Gazelle) |
|----------------|--------------------|--------------------|
| 功耗与散热          | 极高 (散热设计庞大)        | 极低 (超高能量效率)        |
| 单粒子翻转<br>(SEU) | 高发 (需复杂冗余纠错)       | 天然免疫 (模拟物理过程)      |
| 计算延迟           | 受寄存器、总线带宽限制        | 光速波分/并行相干运算        |
| 太空退化寿命         | 电学老化、寿命5-10年       | 无电偏置老化、寿命>10年      |

光计算核心芯片抗 SEU 辐射能力强，但外围的 DAC/ADC、FPGA 等电气模块仍需辅以常规宇航加固措施。

# 遥感数据集与十类地物分类任务



EuroSAT 数据集 · 10 类地物样例 (Sentinel-2 卫星遥感, 64×64 RGB)



| 类别名         | 地物含义  | 样本张数  | 类别名            | 地物含义  | 样本张数  |
|-------------|-------|-------|----------------|-------|-------|
| Annual Crop | 一年生农田 | 3,000 | Pasture        | 开阔牧场  | 2,000 |
| Forest      | 森林/林地 | 3,000 | Permanent Crop | 常年作物  | 2,500 |
| Herbaceous  | 草本植被  | 3,000 | Residential    | 住宅建筑  | 3,000 |
| Highway     | 普通公路  | 2,500 | River          | 天然河流  | 2,500 |
| Industrial  | 工业区厂房 | 2,500 | Sea Lake       | 海、淡水湖 | 3,000 |

总样本集大小: 27,000 张 | 验证 / 测试集规模: 各 5,400 张

数据集见: [卫星图像多分类数据集 · modelscope](#)




# 硬件模拟平台 Gazelle 环境

## 结论：

分块约束：tile  $8 \times 2$ ，输入长度须被8整除  
物理线性度 99.4%，偏差可忽略  
精度损失源于量化噪声及激活量化精度  
模型需要减少计算量，并避免误差积累

## $8 \times 2$ 光学 Tile 结构示意图

输入光  $\rightarrow$  DAC 调制  $\rightarrow$  光学 MAC 阵列  $\rightarrow$  TIA 探测  $\rightarrow$  ADC



| 物理属性      | 数值                          | 物理约束 / 工程学影响                         |
|-----------|-----------------------------|--------------------------------------|
| 物理计算 Tile | $8 \times 2$ ( $k=8, n=2$ ) | 卷积乘加展平后长度必须被 8 整除，否则硬件必须补零闲置         |
| 原生支持精度    | 8-bit 激活 / 8-bit 权重         | 支持 INT8 GEMM，无需为了适配降低精度至 INT4        |
| 运算速率      | 2.6MOPs                     | 算力总容量极其有限，要求工程上必须采用极度轻量化的网络结构以避免大量计算 |
| 存在物理噪声    | -                           | 深网络可能会导致准确率明显下降                      |



# 三模型设计：极简硬件感知架构

| 评估对比维度    | Model 1 (基准 VGG)      | Model 2 (SpaceNet V1)     | Model 3 (SpaceNet V2)                                                                                 |
|-----------|-----------------------|---------------------------|-------------------------------------------------------------------------------------------------------|
| 架构定义      | 6×Conv (3×3) + 2×FC   | 4×Conv (1×1 / 2×2) + 2×FC | 同 Model 2 (引入知识蒸馏)                                                                                    |
| 模型参数量     | 2.39 M                | 268 K (降低至 1/9)           | 268 K (降低至 1/9)                                                                                       |
| 首层对齐/硬件处理 | 27 (对齐率 84.4%) / 光学计算 | 3 (对齐率 37.5%) / 留电计算      | 3 (对齐率 37.5%) / 留电计算                                                                                  |
| 综合对齐对位率   | 99.8%                 | 99.6%                     | 99.6%                                                                                                 |
| 单图有效计算复杂度 | 156.6M MOPs           | 1.05M MOPs (轻量)           | 1.05M MOPs (轻量)                                                                                       |
| QAT 与训练策略 | 监督分类训练 (FP32)         | 硬件适配定标从零 QAT              | ResNet-18 蒸馏辅导训练<br>(教师: 97.83%)<br>$L_{KD} = (1 - \alpha)L_{CE} + \alpha T^2 L_{KL}$ T = 4.0, α= 0.7 |

用 1/9 的参数量 实现 1/150 的在轨推算负担。

# 七阶段量化演进


褐色为model1 变体A    深绿色为model1 变体B    q650表示测试集跑了650张

| 阶段                | 内容               | 核心技术要素                                                            | M1 (VGG)                             | M2 (SN V1)          | M3 (SN V2+KD)       |
|-------------------|------------------|-------------------------------------------------------------------|--------------------------------------|---------------------|---------------------|
| ① FP32 基准         | 标准全精度训练          | 标准CNN训练, 无量化, M1 bias=True; M2/M3 Conv bias=False                 | 97.17%                               | 90.15%              | 91.44%              |
| ② QAT 微调          | FP32→int4 直接微调   | BN融合→QAT层替换→低lr微调15-20 epoch                                      | 85.91%                               | 73.63%              | 73.22%              |
| ③ 从零 QAT          | 从头学习 int4 特征     | 随机初始化, epoch-1起全int4伪量化, STE                                      | 91.17%                               | 81.20%              | 83.26%              |
| ④ 非对称量化+噪声        | 非对称量化 + 噪声正则化    | uint8激活/int4权重, Gaussian噪声, bias=False, BN保留 (M2/M3 为 bug 修复后重跑值) | 96.46%                               | 91.06% *            | 91.50% *            |
| ⑤ 混合精度            | 光电异构部署           | Conv=int4(光计算), Linear=fp32(电计算)                                  | 98.26%                               | 91.26%              | 91.13%              |
| ⑥ Gazelle QAT     | int8 原生精度 + 硬件噪声 | int8权重(256级), DAC ENOB=7.5+TIA 噪声, stem FP32                      | 97.87%<br>98.02%                     | 92.06%              | 91.83%              |
| ⑦ osimulator 真机实测 | 真实光计算硬件仿真        | COMPASS 8a8w12o, DAC ENOB=7.5, TIA $\sigma$ =5.31                 | 98.15%<br>(q650)<br>97.54%<br>(q650) | 90.43%<br>(全量 5400) | 90.28%<br>(全量 5400) |



# 七阶段精度曲线

不同模型在各技术阶段的准确率走势对比



FP32 权重依赖精细精度，突变量化破坏特征，低 lr 逃不出坏局部最小  
QAT Conv 全关

技术演进阶段

# 核心创新：

| 核心技术               | 关键做法                                                                          | 核心成果                                                                    |
|--------------------|-------------------------------------------------------------------------------|-------------------------------------------------------------------------|
| ① 物理噪声训练           | <b>DAC 量化噪声与 TIA 加性高斯噪声写入 QAT 前向传播</b>                                        | 物理仿真与真机相契合，推理 <b>Gap</b> 只有 ~1.6%                                       |
| ② 首层异构计算           | 首层 3 通道卷积（宽度未对齐 8×2）强制执行 <b>FP32/FPGA</b> 电算，避免 62.5% 空算开销                    | 避免零填充噪声对 <b>BN</b> 统计值的系统性偏移                                            |
| ③ <b>INT8</b> 全程对齐 | 摒弃离线 <b>INT4→INT8</b> 映射（ <b>Scale</b> 不对齐引入 ~6% 截断损失），直接在 <b>INT8</b> 原生网格训练 | 学出最佳量化分阶（ <b>LSQ+</b> ），消除系统级截断误差                                       |
| ④ 硬件感知结构           | 内部通道取 8 的倍数，使内部卷积层逐层均 100% 对齐 8×2 tile                                        | 综合对齐率 <b>99.6%</b> ，光计算层零补零浪费 → 有效算力 = 名义算力（仅 <b>RGB</b> 首层例外，已置电计算，见②） |



# 量化感知训练 (QAT)

## STE 直通估计器

前向流中的量化算子（如 round）不可导，导致反向梯度中断。  
前向嵌入伪量化，反向传播时使用直通估计器（STE），将量化节点近似为恒等映射。

### 前向动态 Scale 计算

$$s = \frac{\text{abs\_max}(x)}{q_{\max}}$$

### 反向恒等直通 (STE)

$$\frac{\partial L}{\partial x} \approx \frac{\partial L}{\partial x_{\text{dq}}}$$

### PyTorch 梯度截断实现

# 前向走量化，反向走连续梯度流  
`x_dq = x + (x_dq - x).detach()`

## LSQ+ 可学习步长

将量化尺度（s）与非对称零点（zp）设为可学习参数，结合梯度信息自适应优化动态截断范围。

### 可学习步长量化前向

$$x_{\text{dq}} = \left[ \text{round} \left( \frac{x}{s} + \text{zp} \right) \right] \cdot s$$

### 梯度尺度缩放 (G-Scale)

$$g_{\text{scale}} \propto \frac{1}{\sqrt{N \cdot n_{\text{levels}}}}$$

STE 简单稳定、scale 不可学  
LSQ+ 上限更高、能学最优量化范围

激活用 STE 动态 scale  
权重用 LSQ+

## 硬件噪声匹配训练

拒绝纯仿真假设，将物理噪声（光电混合通道）注入训练流，实现“所训即所得”Gazelle 物理噪声注入前向链。

### 前向噪声链



### 标定校准


废弃经验主义“0.02×s”粗扰动，  
依据真机标准，换算为精确物理  
偏差 0.0016×s

### 部署差距

~1.6%  
真机部署精度  
Gap

5~10%  
传统强扰动  
Gap

# 自动闭环工具链：全流程端到端打通




**工程代码量证明：** 系统化闭环。本项目自主设计了 47 个 python 文件（包括 core/qat/data/training/scripts 等分层结构），并稳定通过 11 个核心 QAT bug 的跟踪及修复，健壮性极高。

# 光计算占比：突破 90%



Model 2/3 (遥感特征图 64×64) 逐层物理相干计算量分布

Model 2/3 光电计算系统分析

A. 模型光电计算占比



B. 逐层计算量分布 (补零浪费 = 0)



| 网络层    | 物理属性            | 展平长度 | 硬件对齐率  | 算力负荷 (MOPs) | 运行器件空间                 |
|--------|-----------------|------|--------|-------------|------------------------|
| stem   | Conv 3→8, 1×1   | 3    | 37.5%  | 0.098 MOPs  | 电计算 (FP32)             |
| stage1 | Conv 8→16, 2×2  | 32   | 100.0% | 0.524 MOPs  | 光子核心 (int8)            |
| stage2 | Conv 16→32, 2×2 | 64   | 100.0% | 0.131 MOPs  | 光子核心 (int8)            |
| stage3 | Conv 32→16, 1×1 | 32   | 100.0% | 0.033 MOPs  | 光子核心 (int8)            |
| fc1    | Linear 1024→256 | 1024 | 100.0% | 0.262 MOPs  | 光子核心 (int8)            |
| fc2    | Linear 256→10   | 256  | 100.0% | 0.003 MOPs  | 光子核心 (int8)            |
| 整机合并   | -               | -    | 99.6%  | 1.051 MOPs  | 光: 0.953M<br>电: 0.098M |

光子MOPs 占比 **90.65%**



# 验证闭环

## 可视化前端

### 验证机制（双级闭环）

秒级QAT仿真  $\rightleftharpoons$  数小时真机实测

### 抗噪精度

预注入标定噪声，真机较QAT回撤极小  
(M2  $\downarrow$  1.63%, M3  $\downarrow$  1.55%)

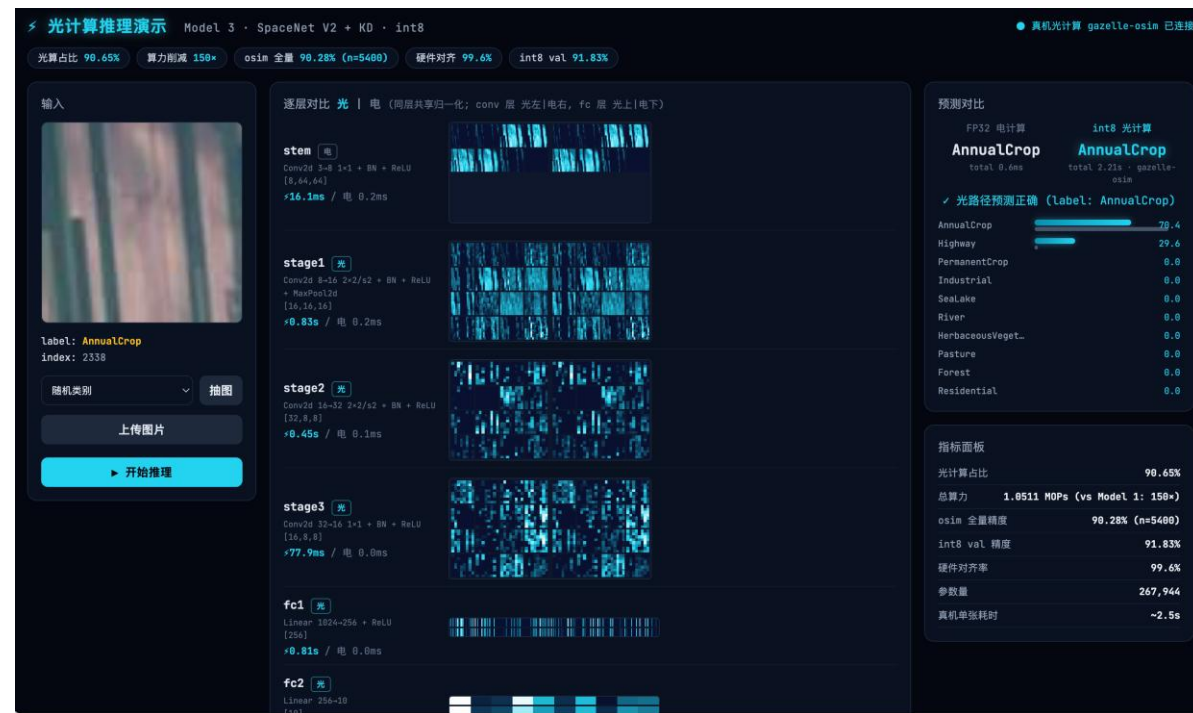
### 消融对比

蒸馏M3 (90.28%) vs 无蒸馏M2 (90.43%)

→ 无统计显著性差异

### 根本归因

鲁棒性源于训练中适应物理噪声，而非  
高维教师网络拟合





# 计算效率与在轨部署决策分析

Compute vs. Accuracy — EuroSAT on Optical Computing (int8, Gazelle osimulator)

轻量化降维打击：破除卫星上电能瓶颈

MODEL 2/3 推理开销

**1.05 MOPs**

参数量仅 **268K**，高度适应低负荷在轨载荷


按 2.6 MOPs 计算的理论上板运行速度

理论上推理一张图片 **0.4s**

全量模拟耗时

**~3.7 小时**

累积调用物理芯片引擎 27,000 次  
(5 光计算层 × 5400 张)



osim = real optical-hardware simulation; Model 2/3 n=5400 (full test set), Model 1 n=650 (sampled). Source: EXPERIMENTS.md

Model 1 (VGG Baseline) 无在轨实际可行性：

单张图像耗算高达 156.6M MOPs (约 Model 2 的 150 倍)。仿真推理单张高达 150 秒，跑完测试集累计需要 9 天！其功耗与时延远超在轨资源上限，根本无法搭载上天。

# 系统成果总结与未来在轨展望

| 指标       | Model 1                              | Model 2            | Model 3            |
|----------|--------------------------------------|--------------------|--------------------|
| 光计算占比    | 97.74%<br>73.64%                     | 90.65%             | 90.65%             |
| 真机精度     | 98.15%<br>(q650)<br>97.54%<br>(q650) | 90.43%<br>(全量5400) | 90.28%<br>(全量5400) |
| 参数量      | 2.39M                                | 268K               | 268K               |
| 总 MOPs/张 | 156.6M                               | 1.05M              | 1.05M              |

未来在轨展望中，我们将以多阶段混合分割策略为核心，动态权衡光电计算配比；结合硬件在环闭环训练持续降低物理偏差；最终实现星载光学遥感数据的端到端实时语义分割，打通从地面训练到太空推理的全链路闭环，为高时效、低功耗的星上智能感知提供可靠支撑。

褐色为model1 变体A    深绿色为model1 变体B    q650表示测试集跑了650张



# THANKS



CICC 1003564