



集创赛

面向航空航天在轨计算的 光学 CNN 加速系统

—— Optic-SpaceNet

多模型架构量化迁移 × 曦智 Gazelle 光计算平台

曦智科技 命题

CICC 1003564

快速预览 (1/2)

作品概况

作品名称:

Optic-SpaceNet · 光学CNN在轨加速系统

应用场景:

卫星在轨遥感图像计算

(数据集: EuroSAT 10类地物分类)

核心痛点解决: 充分利用光计算优势

- 极低功耗
- 天然免疫单粒子翻转(SEU)
- 长寿命

核心技术与创新

光计算精度有限、噪声大: 基于 STE、LSQ+ 等方案进行**量化感知微调**, 在训练时模拟**注入光计算噪音**, 增强模型鲁棒性

光计算对输入 Shape 有要求: **算法-硬件联合设计**, 基于 8x2 Tiling 选取模型超参数, 消除补零浪费

首层精度敏感、Padding 损耗大: 首层执行 FP32 电运算, 规避 62.5% 空算开销, 同时消除零填充对 BN 统计值的影响


端到端闭环工具链: 自主研发涵盖“数据-训练-量化-转化-部署”全流程自动闭环 (47个Python文件), **代码健壮性极高**且全程可追溯

快速预览 (2/2)

重要性能指标

- 模型轻量化：模型参数仅 268K；单图计算负荷 10^{-3} GOPs，单图理论推理速度 **0.4s**。
- 光计算占比达 **90.65%**，最大化释放光计算高能效优势。
- Sim-to-Real 误差小：依托物理噪声QAT训练，训练指标与实际仿真误差缩减至仅 **~1.6%**（传统方法约为5-10%）。
- 优异的分类准确率：经历7阶段量化演进后，包含完整硬件噪声的 Gazelle 仿真结果(全量5400张测试集)依然保持 **90.43%**和**90.28%** 的高准确率。


在轨遥感计算的结构性困境



评价指标	电子计算 (GPU/ASIC)	光学计算核 (Gazelle)
功耗与散热	极高 (散热设计庞大)	极低 (超高能量效率)
单粒子翻转 (SEU)	高发 (需复杂冗余纠错)	天然免疫 (模拟物理过程)
计算延迟	受寄存器、总线带宽限制	光速波分/并行相干运算
太空退化寿命	电学老化、寿命5-10年	无电偏置老化、寿命>10年

* 光计算核心芯片抗 SEU 辐射能力强，但外围的 DAC/ADC、FPGA 等电气模块仍需辅以常规宇航加固措施。

遥感数据集与十类地物分类任务



EuroSAT 数据集 · 10 类地物样例 (Sentinel-2 卫星遥感, 64×64 RGB)



类别名	地物含义	样本张数	类别名	地物含义	样本张数
Annual Crop	一年生农田	3,000	Pasture	开阔牧场	2,000
Forest	森林/林地	3,000	Permanent Crop	常年作物	2,500
Herbaceous	草本植被	3,000	Residential	住宅建筑	3,000
Highway	普通公路	2,500	River	天然河流	2,500
Industrial	工业区厂房	2,500	Sea Lake	海、淡水湖	3,000

总样本集大小: 27,000 张 | 验证 / 测试集规模: 各 5,400 张


数据集: https://www.modelscope.cn/datasets/lhh010/EuroSAT_RGB

硬件模拟平台 Gazelle 环境


- 分块约束: tile 8×2 , 输入长度须被8整除
- 物理线性度 99.4%, 偏差可忽略
- 精度损失源于量化噪声及激活量化精度
- 模型需要减少计算量, 并避免误差积累

8×2 光学 Tile 结构示意图

输入光 $\rightarrow$ DAC 调制 $\rightarrow$ 光学 MAC 阵列 $\rightarrow$ TIA 探测 $\rightarrow$ ADC



物理属性	数值	物理约束 / 工程学影响
物理计算 Tile	8×2 ($k=8, n=2$)	卷积乘加展平后长度必须被 8 整除, 否则硬件必须补零闲置
原生支持精度	8-bit 激活 / 8-bit 权重	支持 INT8 GEMM
运算速率	2.6MOPs	算力总容量极其有限, 要求工程上必须采用极度轻量化的网络结构以避免大量计算
存在物理噪声	-	深网络可能会导致准确率明显下降



模型设计：硬件感知架构

评估对比维度	Model 1 (基准 VGG)	Model 2 (SpaceNet V1)	Model 3 (SpaceNet V2)
架构定义	6×Conv (3×3) + 2×FC	4×Conv (1×1 / 2×2) + 2×FC	同 Model 2 (引入知识蒸馏)
模型参数量	2.39 M	268 K (降低至 1/9)	268 K (降低至 1/9)
首层对齐/硬件处理	27 (对齐率 84.4%) / 光学计算	3 (对齐率 37.5%) / 留电计算	3 (对齐率 37.5%) / 留电计算
综合对齐对位率	99.8%	99.6%	99.6%
单图有效计算复杂度	156.6M MOPs	1.05M MOPs (轻量)	1.05M MOPs (轻量)
QAT 与训练策略	监督分类训练 (FP32)	硬件适配定标从零 QAT	ResNet-18 蒸馏辅导训练 (教师: 97.83%) $L_{KD} = (1 - \alpha)L_{CE} + \alpha T^2 L_{KL}$ T = 4.0, α= 0.7

用 1/9 的参数量 实现 1/150 的在轨推算负担。

七阶段量化演进


褐色为model1 变体A 深绿色为model1 变体B q650表示测试集跑了650张

阶段	内容	核心技术要素	M1 (VGG)	M2 (SN V1)	M3 (SN V2+KD)
① FP32 基准	标准全精度训练	标准CNN训练, 无量化, M1 bias=True; M2/M3 Conv bias=False	97.17%	90.15%	91.44%
② QAT 微调	FP32→int4, STE 微调	BN融合→QAT层替换→低lr微调15-20 epoch	85.91%	73.63%	73.22%
③ QAT 预训练	从头学习 int4 特征	随机初始化, epoch-1起全int4伪量化, STE	91.17%	81.20%	83.26%
④ 非对称量化 + 噪声	非对称量化 + 噪声正则化	uint8激活/int4权重, Gaussian噪声, bias=False, BN保留	96.46%	91.06% *	91.50% *
⑤ 混合精度	探索多种精度混合方案	测试首层 FP32、Linear FP32 等不同策略	98.26%	91.26%	91.13%
⑥ Gazelle QAT	int8 原生精度 + 硬件噪声	改用 int8权重, 尝试模拟插入多种 DAC 噪声, stem FP32	97.87% 98.02%	92.06%	91.83%
⑦ osimulator真机实测	真实光计算硬件仿真	COMPASS 8a8w12o	98.15% (q650) 97.54% (q650)	90.43% (全量 5400)	90.28% (全量 5400)



七阶段精度曲线

不同模型在各技术阶段的准确率走势对比



INT4 STE 限制模型学习能力、
首末层信息损失

FP32 权重依赖精细精度，突变量化破坏特征，低 lr 逃不出坏的局部最优
QAT Conv 相关 Bug

核心创新：

核心技术	关键做法	核心成果
① 训练引入物理噪声	在 QAT 训练中模拟硬件噪声，让模型提前适应光计算高噪环境	实际仿真结果接近训练指标，光计算迁移损失仅 ~1.6%
② QAT 量化感知训练	INT8 QAT 预训练，模型全程感知硬件量化精度	学出最佳量化分阶 (LSQ+)，消除系统级截断误差
③ 首层异构计算	首层 3 通道卷积 （宽度未对齐 8×2 ）强制执行 FP32/FPGA 电算	避免 62.5% 空算开销；避免零填充噪声对 BN 统计值的影响
④ 硬件感知结构	内部通道取 8 的倍数，使内部卷积层逐层对齐 8×2 tile	综合对齐率 99.6% ，光计算层零补零浪费 → 有效算力 = 名义算力 *

* 仅 RGB 首层例外，已置电计算，见③

量化感知训练 (QAT)

STE 直通估计器

前向动态 Scale 计算

$$s = \frac{\text{abs_max}(x)}{q_{\max}}$$

反向恒等直通 (STE)

$$\frac{\partial L}{\partial x} \approx \frac{\partial L}{\partial x_{\text{dq}}}$$

PyTorch 梯度截断实现

```
# 前向走量化, 反向走连续梯度流
x_dq = x + (x_dq - x).detach()
```

STE 简单稳定、scale 不可学
LSQ+ 上限更高、能学最优量化范围

LSQ+ 可学习步长

将量化尺度 (s) 与非对称零点 (zp) 设为可学习参数, 结合梯度信息自适应优化动态截断范围。

可学习步长量化前向

$$x_{\text{dq}} = \left[\text{round} \left(\frac{x}{s} + zp \right) \right] \cdot s$$

梯度尺度缩放 (G-Scale)

$$g_{\text{scale}} \propto \frac{1}{\sqrt{N \cdot n_{\text{levels}}}}$$

激活用 STE 动态 scale
权重用 LSQ+

硬件噪声匹配训练

将物理噪声注入训练, 降低光计算迁移损失。

Gazelle 物理噪声注入前向链。
前向噪声链




部署差距

~1.6%
真机部署精度
Gap

5~10%
传统强扰动
Gap

自动闭环工具链：全流程端到端打通




工程代码量证明： 系统化闭环。本项目自主设计了 47 个 python 文件（包括 core/qat/data/training/scripts 等分层结构），并稳定通过 11 个核心 QAT bug 的跟踪及修复，健壮性极高。

光计算占比：突破 90%



Model 2/3 (遥感特征图 64×64) 逐层物理相干计算量分布

Model 2/3 光电计算系统分析

A. 模型光电计算占比



B. 逐层计算量分布 (补零浪费 = 0)



网络层	物理属性	展平长度	硬件对齐率	算力负荷 (MOPs)	运行器件空间
stem	Conv 3→8, 1×1	3	37.5%	0.098 MOPs	电计算 (FP32)
stage1	Conv 8→16, 2×2	32	100.0%	0.524 MOPs	光子核心 (int8)
stage2	Conv 16→32, 2×2	64	100.0%	0.131 MOPs	光子核心 (int8)
stage3	Conv 32→16, 1×1	32	100.0%	0.033 MOPs	光子核心 (int8)
fc1	Linear 1024→256	1024	100.0%	0.262 MOPs	光子核心 (int8)
fc2	Linear 256→10	256	100.0%	0.003 MOPs	光子核心 (int8)
整机合并	-	-	99.6%	1.051 MOPs	光: 0.953M 电: 0.098M

光子MOPs 占比 90.65%

验证闭环

验证机制（双级闭环）

秒级QAT仿真 $\rightleftharpoons$ 数小时模拟器实测

抗噪精度

预注入标定噪声，实际光计算较QAT回撤极小（M2 $\downarrow$ 1.63%，M3 $\downarrow$ 1.55%）

消融对比

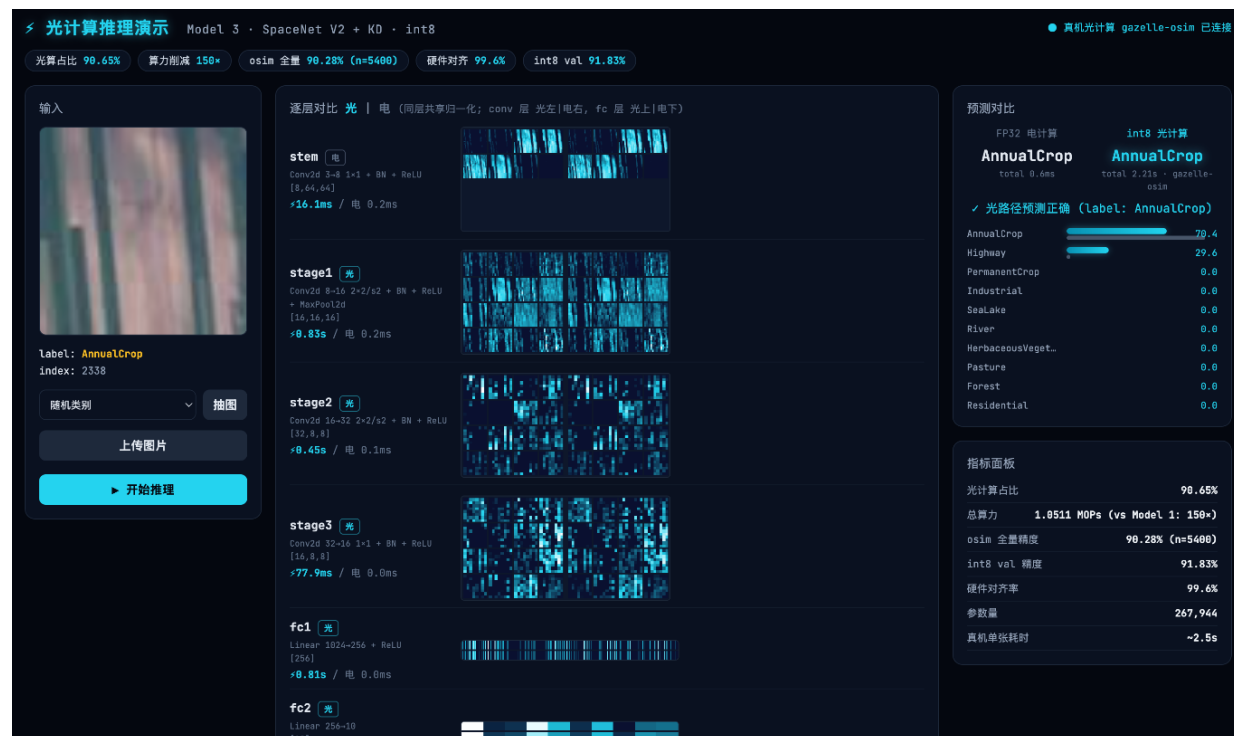
蒸馏M3（90.28%） vs 无蒸馏M2（90.43%）

→ 无统计显著性差异

根本归因

鲁棒性源于训练中适应物理噪声，而非高维教师网络拟合

可视化前端



计算效率与在轨部署决策分析

Compute vs. Accuracy — EuroSAT on Optical Computing (int8, Gazelle osimulator)

轻量化降维打击：破除卫星上电能瓶颈

MODEL 2/3 推理开销

1.05 MOPs $\approx 10^{-3}$ GOPs

参数量仅 **268K**，高度适应低负荷在轨载荷


按 2.6 MOPs 计算的理论上板运行速度

理论上推理一张图片 **0.4s**

全量模拟耗时

~3.7 小时

累积调用物理芯片引擎 27,000 次
(5 光计算层 $\times$ 5400 张)



osim = real optical-hardware simulation; Model 2/3 n=5400 (full test set), Model 1 n=650 (sampled). Source: EXPERIMENTS.md

Model 1 (VGG Baseline) 无在轨实际可行性：

单张图像耗算高达 156.6M MOPs (上板约 60s)。仿真推理单张高达 150 秒，跑完测试集累计需要 9 天！其功耗与时延远超在轨资源上限，根本无法搭载上天。

系统成果总结与未来在轨展望

指标	Model 1	Model 2	Model 3
光计算占比	97.74% 73.64%	90.65%	90.65%
光计算精度	98.15% (q650) 97.54% (q650)	90.43% (全量5400)	90.28% (全量5400)
参数量	2.39M	268K	268K
总 MOPs/张	156.6M	1.05M	1.05M

未来在轨展望中，我们将以多阶段**混合分割策略**为核心，动态权衡光电计算配比；结合硬件在环闭环训练持续**降低物理偏差**；最终实现星载光学遥感数据的**端到端实时语义分割**，打通从地面训练到太空推理的全链路闭环，为高时效、低功耗的星上智能感知提供可靠支撑。

褐色为model1 变体A 深绿色为model1 变体B q650表示测试集跑了650张

总结：模型极致轻量化，充分适配光计算，具备在轨应用可行性



THANKS



CICC 1003564