

答辩准备文档 · Optic-SpaceNet 光学 CNN 加速系统

按评分标准七大项组织，覆盖评委可能提问的方向。每条含 问题 → 核心答 → 支撑数据。

答辩原则：先给结论，再用数据支撑；不懂不装，把局限说成边界条件；把 bug 说成科学诚信。

一、方案设计（15 分：创新 5 / 实用 5 / 平台 5）

Q1. 你们的作品创新性体现在哪里？（创新性 5 分）

核心答：四个创新点，最核心是“硬件匹配训练”。

1. **硬件匹配训练**：训练阶段就注入 Gazelle 真实物理噪声（DAC 量化噪声 + TIA 探测噪声），让模型提前适应硬件 → 仿真精度 gap 仅 ~1.6 点（业界常见 5–10 点）。
2. **stem 首层 FP32 电计算策略**：对齐率仅 37.5% 的首层保留电计算，既高效又消除 BN 训练/推理分布偏移。
3. **int8 全流程对齐**：训练用 int8 权重 = 硬件原生 8a8w，从根上避免 int4→int8 网格不对齐损失。
4. **硬件感知架构**：2×2 卷积让展平长度完美被 8 整除，综合对齐率 99.6%。

差异化：多数队伍是“训练完再量化部署”，我们是“训练时就匹配硬件”——这是仿真近无损的关键。

Q2. 这个系统有什么实际应用价值？（实用性 5 分）

核心答：面向卫星在轨遥感计算——星上下行带宽受限，必须在星上实时分类。

- 场景：遥感地物分类（EuroSAT 10 类：农田/森林/河流/工业区等），可直接用于土地监测、灾害评估、目标识别。
- 优势：光计算**低功耗、低重量、抗辐射**，正好匹配卫星平台约束；Model 2/3 仅 268K 参数、1M 运算量、单张 ~2.5s，是可落地的星上轻量推理单元。
- 精度：仿真 90%+，满足遥感粗分类需求。

Q3. 你们怎么使用光子计算平台资源的？（平台使用 5 分）

核心答：深度使用 Gazelle 平台 + osimulator 仿真器。

- 用 osimulator（COMPASS 8a8w12o）做了**全量 5400 张仿真验证**，不是抽样糊弄。

- 光计算占比 $\geq 90\%$ ，5/6 层走光计算，引擎调用 27000 次、总运算量 $5.15e+09$ MACs。
- 深入分析了硬件参数（线性度 99.4%、DAC/TIA 噪声），并把它们嵌入训练循环——真正"用透"了平台。

二、方案实现（40 分：基础要求 20 / AI 工具链 10 / 功能性能 10）

Q4. 光计算占比 90% 是怎么算出来的？（基础要求 20 分 ★ 最重）

核心答：按每层乘加运算量（MACs）加权计算。

- 光计算占比 = 光计算层 MOPs / (光计算 + 电计算 MOPs)。
- Model 2/3：光计算 0.9528M / 总 1.0511M = **90.65%**；Model 1 变体 A：153.09M / 156.63M = **97.74%**。
- 逐层分布：stem(电) 0.098M、stage1(光) 0.524M、stage2 0.131M、stage3 0.033M、fc1 0.262M、fc2 0.003M。
- 这是**有效 MOPs**（已含补零对齐开销），不是名义值；因为对齐率 99.6%，补零浪费为 0。

Q5. 为什么 stem 首层不量化、放电计算？这样还算"光计算"吗？

核心答：stem 展平长度=3，对齐率仅 37.5%，硬走光计算要补零到 8，**电计算反而更高效**。

- 这正是"硬件感知"的体现：不是机械追求 100% 光计算，而是每层选最优计算位置。
- 即便如此，光计算占比仍达 90.65%（5/6 层），远超阈值。
- 附带好处：消除 BN 训练/推理分布偏移（stem 训练和推理都是 FP32，统计量一致）。

Q6. AI 工具链完整吗？数据处理、训练、量化、编译、部署都做了吗？（AI 工具链 10 分）

核心答：全闭环，五阶段都做了。

1. **数据**：EuroSAT 27000 张，干净三分 split，统一数据源 `eurosat_split.py` (seed=42)。
 2. **训练**：QAT (STE / LSQ+ 两套)，100 epoch，Warmup+Cosine，Gazelle 噪声注入，per-channel 量化。
 3. **量化**：int8 权重 + int8 激活，可导出为整数。
 4. **编译**：经 osimulator 8a8w 原生编译路径。
 5. **部署**：OpticConv2d/OpticLinear 封装，im2col 展开 → 补零对齐 → 光学矩阵乘 → col2im 还原。
- 工具链脚本：47 个 Python 文件，分 core/qat/training/scripts 分层组织。

Q7. 你们做了哪些软硬件优化？技术复杂度/工作量如何？（功能及性能 10 分）

核心答：

- **软件优化**：per-channel 权重量化（KD 通道差异大时关键）、im2col 补零对齐、双引擎（真实 osim + Fake fallback）。
 - **硬件优化**：2×2 卷积对齐 tile、stem 电计算、Gazelle 噪声匹配。
 - **工作量**：6 个 Phase 迭代、3 模型 × 6+ 量化方案、修复 11 个关键 bug（含数据泄漏、双重量化、per-tensor 退化等）、仿真全量复测。
 - **难度**：从硬件特性分析 → 架构设计 → 量化训练 → 仿真验证，全链路自主完成。
-

三、进阶指标（20 分）

Q8. 你们的进阶要求实现了什么？（进阶 20 分）

核心答：在光子计算平台上完成了多项进阶级工作（具体进阶题目以官方为准，以下为本项目已达成的进阶能力）：

1. **int8 全流程仿真部署**：不止跑通 demo，而是在 osimulator 上**全量 5400 张**端到端验证，Model 2 仿真 90.43%、Model 3 90.28%。
2. **Gazelle 噪声匹配训练**：把硬件物理噪声（DAC 量化噪声 + TIA 探测噪声）嵌入训练，实现**近无损仿真推理**（gap ~1.6 点）。
3. **完整消融研究**：3 模型 × 6 量化方案 × 仿真验证，给出可复现的量化迁移方法论。
4. **在轨遥感应用闭环**：从卫星场景出发，落到轻量可部署模型。

若评委追问具体进阶指标（如更高精度/更低延迟/特定模型），可结合 Model 1 高精度路线（98%）、Model 2/3 低算力路线、H1/H2/H3 光电混合提速方案回应。

Q9. 还能进一步提升精度/算力吗？（进阶延展）

核心答：有清晰路线。

- **精度**：扩宽 SpaceNet 通道（16→32→64→32）、渐进式量化（先 int8 后 int4）、用 FP32 Model 1 做教师蒸馏 int4 Model 2/3。
 - **速度**：光电混合提速（H1/H2/H3 方案，已搭建脚本 `optic_inference_h{1,2,3}.py`），把部分层切回电计算换取吞吐。
 - **终极**：硬件在环训练——把 osim 真实输出作为训练信号，端到端优化。
-

四、技术深度（评委常追问）

Q10. int8 和 int4 你们都试了，为什么最终选 int8？

核心答：硬件原生就是 8a8w，int8 是"顺势而为"。

- int4 路线（Phase 2–5）天花板 ~91%，且 int4→int8 网格不对齐（scale max/7 vs max/127）造成 ~6% 不可消除损失（详见我们的 §16 分析）。
- int8 匹配硬件原生精度，仿真 gap 收敛到 ~1.6 点，精度更高、部署更顺。
- int4 的价值在于更低权重位宽（省存储/带宽），但本平台原生支持 int8，int4 无优势。

Q11. 知识蒸馏（KD）有用吗？为什么 Model 3 仿真没赢 Model 2？

核心答：KD 在训练阶段有用，但仿真噪声鲁棒性主要来自 Gazelle 噪声训练。

- KD 让 Model 3 val（91.83%）训练更稳、收敛更好；教师 ResNet-18（97.83%）的软标签提供了正则化。
- 但仿真上 M2 90.43% vs M3 90.28%，**统计上打平**（差 0.15%， $z \approx 0.27$ 不显著）。
- 结论：仿真 gap 的主导因素是 osim 物理噪声，Gazelle 噪声训练已吸收大部分；KD 增益被噪声掩盖。这是**诚实的科学发现**，不是 KD 没用。

Q12. 仿真 90% 比训练 val 92% 低约 2 点，为什么？能消除吗？

核心答：这 ~1.6–1.8 点是 osim 物理噪声的上界，已接近极限。

- 来源：DAC 量化噪声 + TIA 探测噪声。
- 同一测试集上 Model 2 的 int8 QAT（无硬件噪声）= 92.20%，仿真 = 90.43%，纯硬件噪声 gap = 1.77%。
- 训练时已注入等量 Gazelle 噪声，吸收了大部分；残留 ~1.6 点是物理极限，除非硬件本身精度提升。

Q13. osimulator 是仿真器，不是真实芯片吧？你们的 2.5s/张 不慢吗？

核心答：关键澄清——osim 是物理级仿真，2.5s 是**仿真开销**，不是真实光子芯片的墙钟时间。

- osim 用 Python 精确模拟光学 MAC（调制/衍射/探测/噪声），单次调用慢是因为仿真精度高，不代表光子芯片慢。
- 真实光子芯片的矩阵乘是**光速并行**完成（一次光程），理论吞吐远高于电子芯片。
- 我们用 osim 是因为它精确建模了硬件噪声，能验证"模型在真实硬件上会怎样"——这正是题目的验证要求。
- **如果评委质疑：**强调光计算的优势是原理性的（并行、低功耗），仿真时间不是性能指标；仿真精度才是。

Q14. 为什么 Model 1 不直接部署？它精度最高（98%）。

核心答：Model 1 精度最高但算力/功耗不适合在轨。

- Model 1 = 156M MOPs/张，是 Model 2/3 的 **150 倍**；单张 ~150s，功耗/延迟在卫星上不可接受。
- 全量 5400 张要跑 ~9 天（仅能抽样验证）。
- Model 1 的价值是**对照基线**：证明“不顾硬件约束的大模型”在光计算平台上不划算，反衬 Model 2/3 硬件感知设计的优势。
- Model 1 也证明了我们的方法在大模型上同样有效（int8 量化无损、仿真抽样 98–100%）。

Q15. 你们的模型太小（268K），会不会精度不够？

核心答：268K 是有意为之的硬件感知轻量化，精度足够。

- 在 EuroSAT 10 类上仿真 90%+，满足遥感粗分类。
- 小模型 = 低功耗、低延迟、低存储，正是卫星场景所需。
- 若需更高精度，有明确扩宽通道路线（见 Q9），但要在精度和算力间权衡——我们选择了适合在轨的平衡点。

Q16. bias=False、BN 保留，为什么这么设计？

核心答：完全匹配光计算硬件约束。

- **bias=False**：光计算硬件不支持 bias 加法，去掉 bias 让模型原生兼容。
- **BN 保留（FP32 运行）**：BN 在训练时稳定 QAT，推理时可融合或保留 FP32，不增加光计算负担。
- 这是光计算迁移的标配设计。

五、数据可信度（评委可能质疑诚信）

Q17. 你们的测试数据可信吗？有没有过拟合测试集？

核心答：这是我们最值得讲的一点——我们主动发现并修复了数据泄漏（Bug [#11](#)）。

- **问题**：早期 split 里测试集整段落在了训练集内（ $\text{test} \subset \text{train}$ ），导致 osim 数字虚高（93.28%/93.26%）。
- **修复**：改成严格三分 split（train 16200 / val 5400 / test 5400，三者零重叠），empirical 验证。
- **复测**：三模型全部干净重训 + 仿真全量复测，旧虚高数字全部标注作废。
- **现在的数**： $\text{test} \approx \text{val}$ （M2 test 92.20% vs val 92.06%， $\Delta 0.14\%$ ），证明无泄漏、泛化良好。

这是科学诚信的加分项，主动暴露问题比被评委抓到强百倍。

Q18. 仿真只跑了 Model 2/3 全量，Model 1 只抽样，会不会不严谨？

核心答：Model 1 抽样是算力所限的诚实选择，且不影响结论。

- Model 1 全量需 ~9 天 (150× 计算量)，不可行；用 quick 50 抽样 (A 98%、B 100%)。
- Model 2/3 全量 5400 已给出可信真值 (90.43%/90.28%)。
- 我们在文档里明确标注了哪些是抽样、哪些是全量，不混为一谈。

Q19. q500 抽样和全量 5400 数不一样 (89% vs 90.43%)，哪个对？

核心答：全量 5400 是真值，q500 是抽样参考。

- q500 (500 张) 有抽样噪声，Model 2 的 q500=89.00% 恰落 ~1 SE 低处 (SE≈1.4%)。
- 全量 5400 = 90.43% 才是可信数，文档里已用全量取代 q500。
- 这也说明我们对统计显著性有严格意识 (报告了 z 值、置信区间)。

六、可能的"刁钻"问题与应对

Q20. 你们的工作和直接用 PyTorch 量化有什么本质区别？

核心答：区别在目标硬件是光子芯片，不是 GPU/CPU。

- PyTorch 量化面向电子芯片 (int8 在 CPU/GPU 跑)；我们面向 8×2 光学 MAC，要处理 im2col 对齐、光学噪声、补零、bias 不支持等光计算特有问題。
- 我们封装了 OpticConv2d/OpticLinear，把光计算路径接入 PyTorch 训练-推理闭环——这是光计算专属工程。

Q21. 光计算占比 90%，那剩下 10% 电计算是不是短板？

核心答：不是短板，是最优分层。

- 10% 电计算在 stem 首层 (对齐率 37.5%)，硬走光计算反而更慢更浪费。
- 光电混合正是现实部署的合理形态 (光电协同处理器)。
- 我们后续的 H1/H2/H3 方案就是在探索更优的光电切分。

Q22. 如果硬件参数变了 (比如换一代光子芯片)，你们的方法还成立吗？

核心答：方法论完全可迁移，只需更新噪声参数。

- 硬件匹配训练的框架不变，把 GazelleNoiseInjector 的 DAC/TIA 参数换成新硬件的即可。

- 这正是"硬件先于模型"方法论的鲁棒性——参数可换，方法通用。

Q23. 你们怎么保证量化模型部署后行为和训练一致？

核心答：训练-推理配置严格对齐（我们的 §16.8 checklist）。

- stem：训练 `first_conv_fp32=True` ↔ 推理 `keep_first_conv_electronic=True` ✓
- 权重：训练 `int8` ↔ 推理 `int8` (osim 原生) ✓
- 噪声：训练 Gazelle 噪声 ↔ 推理 osim 物理噪声 ✓
- 三项对齐 → 仿真 gap 最小。这正是 `int4` 模型失败、`int8` 模型成功的根因。

Q24. 为什么不用更先进的量化方法（如 AWQ、GPTQ）？

核心答：QAT 更适合本场景，且我们做了 LSQ+ 对比。

- AWQ/GPTQ 是训练后量化（PTQ），适合大模型；我们是量化感知训练（QAT），从零训练，对小模型更准。
- 我们实现了 LSQ+（可学习 scale/zp）作为对比，达 92.80% (val)，接近 STE。
- 选择 QAT 是基于实证，不是没考虑其他方法。

Q25. 光计算评估板的能效比（TOPS/W）比 GPU 还低，上天有什么意义？（★ 高频刁钻题）

完整版见 演示PPT文字稿.md 附录 C2。与 Q13（osim 是仿真器、2.5s 慢吗）互补：Q13 答"延迟/仿真"，此题答"能效"。

核心答：不在绝对算力/能效上和 GPU 硬刚（必输）；光计算的优势是抗辐射特殊优势 + $O(1)$ 规模潜力 + 线性任务低延迟。

- **本质**：评估板（PoC）光阵列规模极小（本项目 8×2 tile）；系统功耗 >99% 消耗在外围 ADC/DAC、TIA、激光器温控、FPGA 的光电转换（O-E-O，"光电墙"）上，光本身只耗毫/微瓦级。
- **三段式应对话术**：
 1. **降维（商业 vs 航天）**：Jetson Orin ~ 1.6 TOPS/W 是地面商业芯片；上天需航天级抗辐射加固，体积/重量/功耗膨胀、能效大降。光计算核心天然抗 SEU → 应比"抗辐射成本下的综合能效"。
 2. **规模效应（ $O(1)$ 复杂度）**：电子算 $N \times N$ 矩阵乘功耗/时延随规模 $O(N^2) \sim O(N^3)$ ；光计算无论 16×16 还是 1024×1024 都是一次光程（皮秒级），计算功耗 $O(1)$ 。硅光集成（共封装光学 CPO）成熟、阵列扩到千级后理论能效可反超 GPU——本项目是面向未来 5–10 年的前沿探索。

- 3. **特定任务优势**：模拟域线性运算（矩阵乘/卷积/FFT/滤波）可省部分 ADC、极低延迟，是 GPU 难替代的赛道，正是 CNN 推理核心算子。
 - **话术底线**：把"评估板规模小"自圆其说为我们选 **268K 轻量、追求高光计算占比（90.65%）而非绝对 TOPS** 的前提，化被动为主动。
 - **严谨边界**：不要说"光计算完全免疫辐射"；准确表述是——核心对 SEU 不敏感、外围电子（DAC/ADC/FPGA）仍需常规加固。
-

七、团队协作（5 分）

Q26. 团队怎么分工的？每个人贡献？

核心答：（按实际填写，建议突出能力互补）

- 成员 A：硬件特性分析 + 光计算核心库（`optic_layers` / `OpticalEngine`）
 - 成员 B：量化训练框架（QAT v1-v4 / LSQ+）+ 训练脚本
 - 成员 C：模型架构设计（SpaceNet V1/V2）+ 知识蒸馏
 - 成员 D：容器推理 + `osimulator` 仿真验证 + 实验记录与文档
 - 协作体现：统一的 `eurosat_split` 数据源、共享训练 runner、交叉验证彼此的精度数。
-

八、通用应答技巧

1. **先结论后细节**：评委时间有限，先一句话结论，再给数据。
 2. **数据张口就来**：关键数字背熟——光计算占比 90.65%、仿真 90.43%/90.28%、对齐率 99.6%、MOPs 1.05M vs 156M（150×）、仿真 gap ~1.6 点。
 3. **把局限说成边界**：Model 1 慢 → "算力约束下我们选了轻量路线"；KD 没赢 → "科学发现，鲁棒性来自噪声训练"。
 4. **主动谈 Bug #11**：科学诚信，加分项，别等评委发现。
 5. **不懂不装**：若问到硬件底层细节不清楚，坦诚说"这部分基于曦智提供的仿真器和技术文档，我们聚焦在上层算法适配"。
 6. **回扣评分项**：回答时自然带出对应评分点（光计算占比 / 工具链 / 创新 / 进阶）。
-

附：必须背熟的关键数据速查表

指标	数值
光计算占比	M1 97.74% / M2 90.65% / M3 90.65%
硬件对齐率	99.6%
仿真精度（全量 5400）	M2 90.43% / M3 90.28%
int8 val（干净）	M1 97.87/98.02% / M2 92.06% / M3 91.83%
FP32 基准	M1 97.17% / M2 90.15% / M3 91.44%
仿真 gap（vs val）	~1.6 点
参数量	M1 2.39M / M2、M3 268K
总 MOPs/张	M1 156.6M / M2、M3 1.05M（150×）
单张推理	M2、M3 ~2.5s（osim 仿真）；M1 ~150s
硬件	Gazelle 8×2 tile，8a8w12o，线性度 99.4%
KD 教师	ResNet-18，97.83%
数据	EuroSAT 27000 张，三分 16200/5400/5400