

答辩准备文档 · Optic-SpaceNet 光学 CNN 加速系统 (CICC1003564)

按评分标准七大项组织，覆盖评委可能提问的方向。每条含 问题 → 核心答 → 支撑数据。
答辩原则：先给结论，再给证据，最后说明边界；不懂不装，把局限说成边界条件，把 bug 说成科学诚信。
核验日期：2026-07-21。材料冲突时以技术数据包和原始日志为准。

〇、答辩前必须统一的口径

1. 一句话定义项目

我们针对 Gazelle 光计算平台的 8×2 tile、8a8w12o 位宽 和模拟非理想性，联合设计轻量 CNN、int8 量化感知训练和光电混合映射，并在官方 osimulator 硬件级仿真路径上完成 EuroSAT 独立测试集验证。

2. 30 秒版本

卫星遥感图像量大、下行带宽有限，因此适合在星上先做分类和筛选。普通 CNN 不能直接高效搬到光计算平台：模型可能太大、矩阵尺寸可能不适配 tile、量化位宽和模拟误差也会造成精度下降。我们先分析 Gazelle 的 8×2、8a8w12o 等约束，再设计 SpaceNet、从零进行 int8 QAT，并把低对齐的首层留在电子侧。最终 Model 2/3 只有约 26.8 万参数、每张约 1.051M MAC，其中 90.65% 的 Conv/Linear MAC 映射到光侧，在 5400 张独立测试图像的 osimulator 硬件级仿真中取得 90%多的 Top-1。

3. 术语与结论红线（全组必须照此说）

材料里的旧说法	现场统一说法	原因
"真机""真机实测"	osimulator 硬件级/物理行为仿真	没有物理板卡或流片芯片实测
"硬件在环训练"	硬件感知 QAT + 仿真闭环验证	osimulator 没有进入反向传播
"天然抗辐射"	光学计算核心辐照敏感机制不同于数字存储逻辑，具备研究潜力	本项目未做辐照实验，外围电子仍需加固
"低功耗、比 GPU 快"	应用动机和潜在优势	没有板卡功耗、TOPS/W 或真实芯片时延实测

材料里的旧说法	现场统一说法	原因
"量化反超 FP32"	最终部署结果在数值上未低于原 FP32 参考	M2 只高 0.28 个百分点，训练配方也不完全相同
"约 1.6 点全由物理噪声造成"	QAT 参考到 osim 路径的总 gap 约 1.6–1.8 点	缺少只开/关噪声的同配置全量消融，不能单因子归因
"int8 全部达标"	M1、M2 达到各自目标；M3 val 达 91%，osim 90.28% 接近但未达原定 91% 真机目标	防止评委直接对表反驳
"2×2 才能对齐 8×2 tile"	2×2 在保持 K 维对齐的同时进一步降算力	输入通道为 8 的倍数时，3×3 的 K 维也能被 8 整除
"训练完整注入 DAC/TIA/ADC 噪声"	最终 v4 前向实际对量化权重注入基于 DAC ENOB 的噪声；TIA/ADC 函数已定义，但当前 Conv/Linear 前向没有调用	与代码一致
"47 个 Python 文件"	不主动报文件数（不是核心成绩）；如要报，按当前提交包实口径	文件数随版本变动，且不是评分点

4. Model 2 / Model 3 统一叙事

Model 2 是我们第一版稳定的硬件感知轻量架构；Model 3 是在 Model 2 基础上的继续探索分支，希望通扑过局部结构调整和训练策略变化进一步提高轻量模型精度。实验中这些改动没有表现出稳定、明显的净收益，因此最终提交版的宏观骨干又收敛到与 Model 2 基本相同的结构，并保留 KD 作为训练侧尝试。这反而帮我们确认：在当前约 1M MAC、8×2 tile 和 int8 路径约束下，Model 2 已处在较好的精度—复杂度平衡点。

三个层次：① 项目意图——M3 是在 M2 上继续探索；② 最终代码事实——入选部署的 M3 与 M2 宏观拓扑基本一致，主要保留 KD 差异；③ 实验结论——探索没有明显净收益

一、方案设计（15 分：创新 5 / 实用 5 / 平台 5）

Q1. 你们的作品创新性体现在哪里？（创新性 5 分）

核心答：四个创新点（与 PPT 第 10 页"核心创新"一一对应），最核心是"训练即匹配硬件"。定位是系统协同与工程创新，不是发明新 CNN 理论或世界首创量化算法。

- 1. 训练引入物理噪声（硬件匹配训练）：**训练阶段对量化权重注入基于 DAC ENOB 的物理噪声，让模型提前适应硬件 → QAT 到 osim 路径的总 gap 约 1.6–1.8 点（不主动与"业界 5–10 点"做无来源比较）。

2. **QAT 量化感知训练**：int8 权重 = 硬件原生 8a8w，**最终主线为 STE 对称 int8**（权重 per-output-channel、首层 FP32）；LSQ+ 是实现过的对比方法，不是最终部署路线。训练位宽与引擎原生位宽一致，避免 int4→int8 网格不对齐损失。
3. **首层异构计算**：对齐率仅 37.5% 的 stem 首层放电计算（FP32），规避 62.5% 空算开销，同时避免零填充对 BN 统计值的影响。
4. **硬件感知结构**：内部通道取 8 的倍数 + 2×2 卷积，让光计算层展平长度被 8 整除，综合对齐率 99.6%、光计算层零补零浪费。

差异化：多数队伍是“训练完再量化部署”，我们是“训练时就匹配硬件”——这是仿真近无损的关键。

Q2. 这个系统有什么实际应用价值？（实用性 5 分）

核心答：面向卫星在轨遥感计算——星上下行带宽受限，适合在星上先做场景分类与筛选。

- 场景：遥感地物分类（EuroSAT 10 类），可用于土地监测、灾害评估、目标识别的**粗分类/筛选**。
- 优势（应用动机与潜在优势，**非已实测结论**）：光计算的低功耗、抗辐射是航天场景的动机；**本项目未做板卡功耗、辐照或真实芯片时延实测**。Model 2/3 仅 268K 参数、1.051M MOPs ($\approx 10^{-3}$ GOPS)，按 2.6 MOPs 速率**理论**单张推理 0.4s（理论估计，非实测）。
- 精度：osim 仿真 90%+，满足遥感粗分类原型需求。
- 边界：当前只做场景分类，没实现通信链路、检测或语义分割，也没做“减少多少下行带宽”的系统级测量；应称“面向在轨场景的原型”，不是“已经可上星”。

Q3. 你们怎么使用光子计算平台资源的？（平台使用 5 分）

核心答：不是只把平台当结果展示器，而是先逆向分析约束、再实现映射、最后全量仿真。

- 从主办方容器的配置、行为文件和接口分析出 8×2 tile、8a8w12o、速率与噪声等约束（行为/标定参数，非物理板卡自测）。
- 实现 OpticConv2d/OpticLinear，把卷积转成 im2col + GEMM，K 维不足 8 补零、输出按 n=2 分块。
- 在容器内调用 osimulator（COMPASS 8a8w12o）做了**全量 5400 张**端到端验证：M2/M3 各 27000 次光引擎调用、光侧总运算量 5.15×10^9 MAC。
- **双级闭环 + 可视化前端**（PPT 第 14 页）：秒级 QAT 仿真 $\rightleftharpoons$ 数小时 osim 仿真相互校验；并自研可视化前端（见 前端演示视频.mp4），打通“数据→训练→量化→部署→可视化”全链路。

二、方案实现（40 分：基础要求 20 / AI 工具链 10 / 功能性能 10）

Q4. 光计算占比 90% 是怎么算出来的？（基础要求 20 分 ★ 最重）

核心答：按 Conv/Linear 的 MAC 数加权：M2 总 1.0511M MAC，电子 stem 0.0983M，五个光侧层合计 0.9528M， $0.9528/1.0511 = 90.65\%$ 。

- 逐层：stem(电) 0.098M、stage1(光) 0.524M、stage2 0.131M、stage3 0.033M、fc1 0.262M、fc2 0.003M。
- Model 1 变体 A：153.09M / 156.63M = **97.74%**（变体 B 仅 73.64%，**不达标**）。
- 口径提醒：**90.65% 只统计 Conv/Linear 的 MAC 分配，**不含** BN、ReLU、池化、预处理、数据搬运、DAC/ADC 和控制开销；是**算子 MAC 占比**，不是端到端时延或能耗占比。代码把一次乘加记作一个计数（PPT 写 MOPs、日志写 MACs）；若评委把乘/加分开计，数值约翻倍，但 149× 的相对比较不变。
- 真正送入光核的五层全部 100% K 对齐，**光侧补零浪费为 0**；99.6% 是把 K=3 的电子 stem 也算进来的全模型诊断值，两者不矛盾。

Q5. 为什么 stem 首层放电计算？这样还算"光计算"吗？

核心答：stem 是电计算层——这是架构决策，不是"该量化却没量化"。

- 为什么放电计算：**stem 展平长度=3，对齐率仅 37.5%（补零到 8 浪费 62.5%），硬塞光路等于白烧 5/8 的光计算 tile；把稀缺的光计算 tile 留给对齐良好的大层更划算。这就是"硬件感知"——每层选最优执行位置，不机械追 100% 光路。
- FP32 不是额外决策：**电计算硬件本就 FP32 原生，无需"量化"；首层又直接接触原始 RGB、量化分布敏感，顺势保高精度反而最优，且训练/推理同精度 → BN 统计量一致。
- 还算"光计算"吗——是：**stem 仅 0.098M MOPs（占 9.3%），是 1×1 的 3→8 输入适配器；真正的特征提取 + 分类（stage1–3 + fc1–2，5 层、0.953M MOPs）全部走光路。光电混合输入级是光计算加速器的标准形态，按 MOPs 透明上报 90.65%，未夸大。

Q6. AI 工具链完整吗？数据处理、训练、量化、编译、部署都做了吗？（AI 工具链 10 分）

核心答：全闭环，五阶段都做了。

- 数据：**EuroSAT 27000 张，干净三分 split，统一数据源 `src/data/eurosat_split.py`（seed=42，含互斥/覆盖断言）。
- 训练：**QAT（**最终主线 STE int8**；LSQ+ 作对比），100 epoch，warmup + cosine，per-channel 权重量化，首层 FP32。
- 量化：**int8 权重 + int8 激活，对齐硬件 8a8w。
- 编译：**经 `osimulator` 8a8w 原生路径。
- 部署：**OpticConv2d/OpticLinear 封装，im2col 展开 → 补零对齐 → 光学矩阵乘 → col2im 还原。

- 工程量：分层组织（core/qat/data/training/scripts）；**不把文件数当卖点**（如需报，按当前提交包实口径：src 与 demo 合计约 76 个 .py，随版本变动）。

Q7. 你们做了哪些软硬件优化？技术复杂度/工作量如何？（功能及性能 10 分）

核心答：

- **软件优化**：per-output-channel 权重量化、im2col 补零对齐、双引擎（真实 osim + fake fallback）。
- **硬件优化**：2×2 卷积在保持 K 维对齐的同时降算力、stem 电计算、基于 DAC ENOB 的噪声匹配。
- **工作量**：七阶段实验、五个上屏里程碑（PPT 第 8 页）、3 模型多量化方案、修复 11 个关键 bug（含数据泄漏、双重量化、per-tensor 退化等）、仿真全量复测。
- **难度**：硬件特性分析 → 架构设计 → 量化训练 → 仿真验证，全链路自主完成。

三、进阶指标（20 分）

Q8. 你们的进阶要求实现了什么？（进阶 20 分）

核心答：在光计算平台上完成多项进阶级工作（具体进阶题以官方为准）：

1. **int8 全流程仿真部署**：不止跑通 demo，而是在 osimulator 上**全量 5400 张**端到端验证，M2 90.43%、M3 90.28%。
2. **硬件感知噪声训练**：训练注入基于 DAC ENOB 的权重噪声，QAT→osim 总 gap 约 1.6–1.8 点（不可单因子归因到某一噪声模块，详见 Q12）。
3. **完整消融研究**：3 模型 × 多量化方案 × 仿真验证 + 2×2/3×3 三种子核对比，给出可复现的量化迁移方法论。
4. **在轨遥感应用闭环**：从卫星场景出发，落到轻量可部署原型。

若追问更高精度/更低延迟/特定模型：M1 高精度路线（98%，抽样）、M2/3 低算力路线、H1/H2/H3 光电混合提速探索。

Q9. 还能进一步提升精度/算力吗？（进阶延展）

核心答：有清晰但待验证的路线。

- **精度**：扩宽 SpaceNet 通道、渐进式量化、用 FP32 Model 1 做教师蒸馏。
- **速度**：光电混合提速（H1/H2/H3 探索脚本），把部分层切回电计算换取吞吐。

- **终极方向（当前未实现）：**真正的**硬件在环校准/训练**——把 osim 真实输出作为训练信号端到端优化。当前 osim 只做训练后前向验证，不进反向传播，所以应称"硬件感知训练 + 仿真闭环验证"，不是"硬件在环训练"。

四、技术深度（评委常追问）

Q10. int8 和 int4 你们都试了，为什么最终选 int8？

核心答：硬件原生就是 8a8w，int8 是"顺势而为"。

- int4 路线（阶段 ②–⑤）天花板约 91%，且 int4→int8 网格不对齐（scale max/7 vs max/127）造成约 6% 不可消除损失（详见 docs/EXPERIMENTS.md §16）。
- int8 训练位宽与引擎原生位宽一致，部署一致性更好。
- int4 的价值在更低权重位宽（省存储/带宽），但本平台无原生 int4 数据路径，int4 无真实执行收益。
- **int4→int8 损失三重根因（实验定位）：**① 权重量化网格不对齐（同一浮点权重落到不同网格点）；② 激活 per-channel→per-tensor 退化；③ stem 训练 int4 / 推理 FP32 的 BN 统计量偏移。三项叠加约 6%。

Q10a. PPT 第 8/9 页的"七阶段量化演进"能讲一遍吗？为什么走了这么多阶段？

核心答：这是一条"int4 失败 → 逐项归因 → int8 成功"的科学排除路线，每阶段排掉一个假设，不是反复试错。**完整实验七阶段，PPT 上屏五个里程碑。**

- ① **FP32 基准：**M1 97.17% / M2 90.15% / M3 91.44%，确立精度上界。
- ② **QAT 微调（FP32→int4）：**全崩（-11~-18%）→ 微调路线死。
- ③ **从零 QAT：**回升但仍差 6-9% → int4 学习能力受限 + 首末层信息损失。
- ④ **非对称量化 + 噪声：**M1 救回 96.46%，但 M2/M3 卡在 Conv QAT bug → 暴露工程 bug。
- ⑤ **混合精度（Conv int4 / Linear FP32）：**绕过 bug，M1 98.26% / M2 91.26% 反超 FP32 → 验证 QAT 正则化有效。
- ⑥ **Gazelle QAT（int8 原生 + DAC ENOB 权重噪声）：**硬件逆向发现原生 8a8w，切 int8，M2 92.06% / M3 91.83% → 关键转折：训练即匹配硬件原生精度。
- ⑦ **osimulator 硬件级仿真：**全量 5400，M2 90.43% / M3 90.28%，总 gap 约 1.6-1.8 点 → 闭环验证。

一句话：用 7 个阶段排除了 int4、微调、per-tensor 等错误假设，最终靠"训练时就匹配硬件"把 sim-to-real gap 压到约 1.6 点。精度曲线见 PPT 第 9 页。

Q11. 知识蒸馏 (KD) 有用吗？为什么 Model 3 仿真没赢 Model 2？

核心答：现有证据不能证明 KD 或 M3 探索在部署端有净增益，也不能把结果单因子归因到噪声。

- M2 osim 90.43% vs M3 90.28%，差 0.15 个百分点；两模型在同一 test 上属配对预测，严格显著性应做 McNemar 检验，现有简单比例 $z \approx 0.27$ 只能作近似参考。
- 结论应是“本次配置下未观察到稳定的硬件端收益”，**不要说“KD 一定无效”，也不要强行解释成“增益一定被噪声掩盖”。**

Q12. 仿真 90% 比训练 val 92% 低约 2 点，为什么？能消除吗？

核心答：这是 QAT 路径到 osim 路径的总 gap 约 1.6–1.8 点，不能单因子归因到某一噪声模块。

- 同一 test 上 M2 int8 QAT (PyTorch fake-quant) = 92.20%，osim = 90.43%，两条完整执行路径差 1.77 个百分点。
- 这个数衡量的是“fake-quant 路径”与“真实引擎路径”的总差异（含输入/权重量化、矩阵分块、接口映射、硬件行为模型），**缺少只开/关某一噪声的同配置全量消融，不能据此证明某个噪声模块的因果贡献。**
- 严谨说法：训练预注入噪声使回撤较小；残留 gap 的精确来源待补全噪声消融确认，不宣称“物理极限”。

Q13. osimulator 是仿真器，不是真实芯片吧？你们的 2.5s/张 不慢吗？

核心答：老师说得对——osim 是主办方提供的硬件级物理行为仿真，2.5s 是 Python + 物理仿真的墙钟开销，**不是真实光子芯片时延。**

- osim 用 Python 精确模拟光学 MAC（调制/衍射/探测/噪声），单次调用慢是因为仿真精度高。
- 我们用 osim 是因为它精确建模硬件行为，能验证“模型在目标引擎上会怎样”——这正是题目的验证要求。
- **边界：**本项目没有物理硬件实测，既不能用 2.5s 否定光计算，也不能据此声称真实芯片多快。能证明的是计算量、映射比例和仿真精度。

Q14. 为什么 Model 1 不直接部署？它精度最高（98%）。

核心答：Model 1 精度最高但算力/功耗不适合在轨。

- Model 1 = 156.6M MOPs/张，是 Model 2/3 的约 **149 倍**；最新 q650 日志实测软件仿真约 **45.6 s/张 (A) / 41.0 s/张 (B)**，线性外推全量 5400 张约 **2.85/2.57 天**（旧材料“150 s/张、9 天”已过时，以原始日志为准；且这只是软件仿真时间，非芯片时延）。

- 全量不可行，只能抽样验证（变体 A/B q650 = 98.15%/97.54%，n=650，SE 约 0.53/0.61 个百分点）。
- Model 1 的价值是**对照基线**：证明"不顾硬件约束的大模型"在光计算平台上不划算，反衬 M2/3 硬件感知设计的优势。

Q15. 你们的模型太小（268K），会不会精度不够？

核心答：268K 是有意为之的硬件感知轻量化；90% 的上限主要是**结构代价**，不是参数量不够。

- 在 EuroSAT 10 类上 osim 90%+，满足遥感粗分类。
- 对照实验（docs/EXPERIMENTS.md §11）：同参数量（260K）的标准 CNN（MiniVGG-GAP，全 3×3 + GAP，忽略硬件约束）FP32 即达 96.65%——距 2.39M 的 Model 1 仅差 0.52%。说明 260K 参数量本身绰绰有余，M2/3 的 90% 上限来自为对齐 8×2 tile 主动选用的" 2×2 conv + 大 FC"结构，是为换取 99.6% 对齐率 + 1/150 算力而**主动付出的精度代价**。
- 小模型 = 低功耗、低延迟、低存储，是卫星场景所需；若需更高精度有扩宽通道路线，但要在精度和算力间权衡。

Q16. bias=False、BN 保留，为什么这么设计？

核心答：匹配光计算硬件约束。

- **bias=False**：光核主要负责矩阵乘，独立 bias 加法不在其核心能力内，去掉 bias 简化映射。
- **BN 保留（FP32 运行）**：BN/ReLU/池化属电子侧小算子，BN 仿射参数可承担分布校正，训练稳 QAT、推理不增加光计算负担。
- 提醒：**BN 不要算进 90.65% 的光侧 MAC**。

Q16a. 为什么用 2×2 ，而不是更常见、精度更高的 3×3 ？

核心答： 2×2 的主要价值是**进一步降算力同时保持 K 维对齐**，不是唯一能对齐 tile 的卷积——输入通道为 8 的倍数时， 3×3 的 K 维同样可被 8 整除。

- 三种子消融： 2×2 相比 3×3 把 MAC 从约 1.870M 降到 1.051M，**减少约 43.8%**，代价是平均约 1–2 个百分点 val 精度。
- 因此 2×2 是资源受限场景的 Pareto 选择，**不是精度无损替代**（M2 的 2×2 – 3×3 为 -1.821 pp，区间跨 0；M3 为 -1.247 pp， 3×3 显著更高）。

Q16b. 训练时到底注入了哪些噪声？噪声大小怎么定？

核心答：与代码一致——**最终 v4 的 Conv/Linear 前向，在训练态、权重伪量化前调用 inject_weight_noise**，标准差按 **DAC ENOB=7.5** 计算为 $\text{scale}/(2^{\text{ENOB}} \cdot \sqrt{12})$ 。代码还定义了 TIA $\sigma \approx 5.34\text{e-}4$ 和 ADC $\text{LSB} \approx 0.00147$ 的激活噪声函数，但当前 v4 前向没有调用它们。

- 正确说法："噪声参数来自平台配置/标定信息，最终训练实际注入的是基于 DAC ENOB 的权重噪声；完整链路非理想性由 osim 末端验证。"
- 不要说"不断试噪声直到精度好"，也不要声称训练逐项复现了全部器件噪声。
- PPT 里 $0.0016 \times \text{scale}$ 是 `fake_quantize_symmetric` 未传 injector 时的备用相对噪声参数；传 injector 时按 ENOB 公式计算，**不是板卡实测拟合的独立参数**。

Q16c. 这是 hardware-in-the-loop 训练吗？

核心答：不是。当前训练用可微 fake quant + 近似权重噪声，`osimulator` 只在训练后做前向验证，**不参与每步反向传播**。应称"硬件感知训练 + osim 闭环验证"。

Q16d. 硬件只接受非负输入，怎么处理？

核心答：M2/3 光侧卷积前都有 BN+ReLU，进入光侧时是非负激活；真实引擎用 unsigned 输入映射、反量化时做偏移补偿。早期出现过 signed 预量化、负索引和双重量化问题，最终改为由**真实引擎统一执行输入量化**，避免重复处理。

Q16e. 为什么不直接用 MobileNet、ShuffleNet 等成熟轻量模型？

核心答：这些模型值得比较，但 depthwise conv 在电子处理器上高效，**不代表能高效占满以小矩阵乘 tile 为核心的光学引擎**。SpaceNet 是针对目标映射路径设计的。

- 边界：现有材料没有在同一转换器、同一训练配方下做 MobileNet 公平基线，**不能声称 SpaceNet 优于所有轻量网络**；这是后续应补的实验。

Q16f. 99.4% 线性度、16.6 μs /GEMM 是你们自己测的吗？

核心答：不是物理板卡实测，而是从比赛容器内的行为表征、标定参数和接口信息读取/交叉分析得到的，属于平台模型输入或接口参数。16.6 μs 也不能与 Python osim 的单图秒级耗时直接比较，更不能当本项目实测芯片延迟。

五、数据可信度（评委可能质疑诚信）

Q17. 你们的测试数据可信吗？有没有过拟合测试集？

核心答：这是我们最值得讲的一点——主动发现并修复了数据泄漏（Bug [#11](#)）。

- **问题：**早期 split 里 `test  $\subset$  train`，导致 osim 数字虚高（旧 93.28%/93.26%）。
- **修复：**改成严格三分 split（16200/5400/5400，两两零重叠 + 覆盖全集断言，`src/data/eurosat_split.py`）。
- **复测：**三模型干净重训 + M2/M3 全量 osim 复测，旧虚高数字全部标注作废。
- **现状：**`test  $\approx$  val`（M2 test 92.20% vs val 92.06%， Δ 0.14%），无泄漏、泛化良好。

- **边界（后续更强做法）：**保留一个从未参与任何开发判断的新 holdout，并发布逐样本预测。（划分是 seed=42 全局随机，非显式分层抽样。）

Q18. 仿真只跑了 Model 2/3 全量，Model 1 只抽样，会不会不严谨？

核心答：Model 1 抽样是算力所限的诚实选择，且不影响结论。

- Model 1 全量软件仿真约 2.85/2.57 天（149× 计算量），不可行；扩大抽样到 **q650**（A 98.15% / B 97.54%，SE 约 0.53/0.61 个百分点，远比早期 q50 可靠）。
- M2/3 全量 5400 已给可信值（90.43%/90.28%）。
- 文档明确标注哪些抽样、哪些全量，不混为一谈。

Q19. q500 抽样和全量 5400 数不一样（89% vs 90.43%），哪个对？

核心答：全量 5400 是真值，q500 是抽样参考。

- q500 有抽样噪声，M2 q500=89.00% 恰落约 1 SE 低处。
- 全量 5400 = 90.43% 才是可信数，文档已用全量取代。
- 这也说明对统计显著性有严格意识（报告 z 值/置信区间）。

Q19a. 只有一个 seed，能说明方法稳定吗？

核心答：最终主结果主要是单一 seed=42，能证明这次配置**可复现**，不能完整描述训练方差。2×2/3×3 消融已做三种子，但 int8/osim 主线尚未做多种子全量仿真。后续应先做多种子 QAT，选代表性 checkpoint，再对关键模型做 osim 验证。

Q19b. M2 QAT test 是 92.20%，osim 是 90.43%，为什么差？

核心答：QAT test 走 PyTorch fake-quant 路径；osim 还包含真实引擎的输入/权重量化、矩阵分块、接口映射和硬件行为模型，同一 test 上相差 1.77 个百分点。它衡量**两条完整执行路径的总差异**，不能仅凭它证明某一个噪声模块的因果贡献。

六、可能的"刁钻"问题与应对

Q20. 你们的工作和直接用 PyTorch 量化有什么本质区别？

核心答：区别在**目标硬件是光子芯片**，不是 GPU/CPU。

- PyTorch 量化面向电子芯片；我们面向 8×2 光学 MAC，要处理 im2col 对齐、光学噪声、补零、bias 不支持、非负输入等光计算特有**问题**。
- 封装了 OpticConv2d/OpticLinear，把光计算路径接入 PyTorch 训练-推理闭环——这是光计算**专属工程**。

Q21. 光计算占比 90%，那剩下 10% 电计算是不是短板？

核心答：不是短板，是最优分层。

- 10% 电计算在 stem 首层（对齐率 37.5%），硬走光路反而浪费 tile。
- 光电混合是现实部署的合理形态（光电协同处理器）；H1/H2/H3 探索就是在找更优光电切分。

Q22. 如果硬件参数变了（比如换一代光子芯片），方法还成立吗？

核心答：方法论可迁移，具体模型和参数不能原样照搬。

- 框架不变：重新读取 tile 形状、输入符号、支持算子、位宽、量化规则和噪声模型，再调整通道、卷积、光电切分与 QAT 参数。可迁移的是“硬件约束→模型/训练→映射→验证”的方法论。

Q23. 你们怎么保证量化模型部署后行为和训练一致？

核心答：训练-推理配置对齐（docs/EXPERIMENTS.md §16 checklist）。

- stem：训练 `first_conv_fp32=True` ↔ 推理 `keep_first_conv_electronic=True` ✓
- 权重：训练 `int8` ↔ 推理 `int8`（osim 原生）✓
- 噪声：训练注入基于 DAC ENOB 的权重噪声 ↔ 推理 osim 物理行为 ✓
- 三项对齐使总 gap 较小；但不能把 gap 单因子归因到某一项（见 Q12）。

Q24. 为什么不用更先进的量化方法（如 AWQ、GPTQ）？

核心答：QAT 更匹配本场景，且做了 LSQ+ 对比。

- AWQ/GPTQ 主要面向大模型的训练后量化（PTQ）；本任务是可从零训练的小型 CNN，且要显式适应模拟硬件行为，QAT 更直接。
- 实现了 LSQ+ 作对比；其 92.80% 来自旧划分的 val，受历史划分影响，未做干净 split 全量复测。可讲“比较过 LSQ+”，不能讲“最终结果由 STE + LSQ+ 共同得到”——最终全量结果来自 v4 STE 对称 int8 主线。

Q25. 光计算评估板的能效比（TOPS/W）比 GPU 还低，上天有什么意义？（★ 高频刁钻题）

核心答：不在绝对算力/能效上和 GPU 硬刚——本项目未测板卡功耗、TOPS/W 或真实芯片时延，不能宣称能效优势。

- 本项目能证明的是：M2 相对项目内 VGG 基线减少约 149× MAC、8.9× 参数，90.65% 的主要 MAC 可映射到光侧，并在官方硬件级仿真上稳定 90%+。

- **低功耗、抗辐射是光计算的应用动机和下一步实测假设，不是本项目已验证结论。**光学矩阵乘不依赖大量数字寄存器状态，可能对单粒子翻转呈现不同敏感性，但激光器、调制器、探测器、DAC/ADC、TIA、FPGA 和存储都可能受辐照、温漂、老化影响——正确说法是"值得面向航天进一步验证"。
- **不要用作答辩证据的宏大判断：** $O(1)$ 功耗、必然超过 GPU、"未来 5–10 年反超 GPU"等属行业展望，非本项目数据支撑。
- **话术底线：**把"评估板规模小"自圆其说为选 268K 轻量、追求高光计算占比（90.65%）而非绝对 TOPS 的前提，化被动为主动。

Q25a. ~~反编译 11 个 .pyc 是否合规?~~

核心答：技术上，是在主办方提供的本地比赛容器内、为理解接口和必要硬件行为参数做静态与行为分析，**没有绕过外部访问控制，也没有在提交物中传播主办方二进制。**但合规性必须以比赛规则和主办方授权为准。答辩前应确认规则是否允许反编译；若未确认，不要把"反编译数量"当卖点，改说"分析主办方容器的接口、配置和行为文件"。

Q25b. 项目离真正上星还有多远？

核心答：当前处于算法 + 官方硬件行为仿真验证阶段。还缺物理板卡部署、真实功耗/时延、光电接口与存储、温漂与老化、辐照与容错、航天数据域适配、类别级安全指标以及系统级链路验证。应称"面向在轨场景的原型"，不是"已经可上星"。

Q25c. 你们能证明低功耗或比 GPU 更高效吗？

核心答：不能。当前没有板卡功耗、能耗/图、TOPS/W、真实芯片时延或与同工艺 GPU/ASIC 的端到端对比。可证明的是 M2 相对项目内 VGG 基线减少约 $149\times$ MAC、约 $8.9\times$ 参数，并有 90.65% 主要 MAC 可映射到光侧。低功耗是光计算的应用动机和下一步实测假设，不是已验证结论。

七、团队协作（5 分）

Q26. 团队怎么分工的？每个人贡献？（3 人）

核心答：3 人小组，按"调研 → 双项目并行 → 聚焦合力"三阶段推进，能力互补。

推进时间线：

1. **选题调研（前期）：**分头调研多个方向——语音助手、工业探伤、光计算通信、无人驾驶等，评估技术可行性与赛题契合度。
2. **双项目并行（中期）：**筛出两个候选并行推进——Optic-SpaceNet（光计算在轨加速）与无人机避障；各自搭原型、比可行性。

3. **聚焦合力（后期）**：综合可行性、创新度与平台契合度，敲定 Optic-SpaceNet，三人全力合推。

分工（必须按真实人员填写，评委常点名让对应成员解释代码）：建议按维度组织——数据与基线训练 / 量化与训练（STE·LSQ+·KD） / 光学映射（OpticConv2d·引擎·MOPs） / 验证与审计（容器·全量日志·泄漏修复·消融） / Demo 与答辩（远程服务·前端·文档·视频）。不要背虚构分工。

答辩要点：突出"调研广 + 聚焦快 + 协作紧"。

八、Demo 与复现（评委常追问）

Q27. 现场 Demo 真的调用了 osimulator 吗？

核心答：Demo 有两条模式——远程容器连接成功时引擎标签是 gazelle-osim；网络/服务失败时降级为本地 fake-optical，并设置 meta.degraded=true、前端显示黄色状态。现场必须让评委看到状态灯或 /api/health 返回值；**降级后要明确说是 fake，不得继续称远程 osim 实时推理。**

Q28. 为什么现场不直接跑完 5400 张？

核心答：M2/3 全量约 3.7 小时，不适合答辩现场。现场可做单图或 --quick 5/10 验证链路，同时展示固定权重、命令、全量日志和最终哈希/版本。**quick 结果只证明路径能运行，不能用小样本准确率替代全量 90.43%。**

Q29. 如果 Demo 断网或容器挂了怎么办？

核心答：先说明系统会**诚实降级**为 fake-optical，再展示三类离线证据：全量日志最终行、逐层 MOPs 表、预录的远程 osim 推理过程。**不要隐藏降级状态，也不要**把历史回放伪装成实时结果。

九、Model 2 / Model 3 探索专题

Q30. Model 2 和 Model 3 到底是什么关系？

核心答：M2 是首个稳定的硬件感知轻量基线；M3 是沿 M2 继续探索的分支（结构与训练策略）。经筛选，结构改动没有稳定、明显的收益，最终提交版宏观拓扑与 M2 基本一致，主要保留 KD。两者是"基线—探索分支"关系，**不是必须逐代提升的产品代际。**

Q31. 你们对 Model 3 做过哪些结构尝试？

核心答：(只讲有代码/日志支撑的尝试。)证据最完整的是 **2×2/3×3 卷积核对比**，以及围绕量化层范围、分类头精度和光电切分的多阶段方案。若还试过通道数、深度等，只列出能出示配置和结果的部分；**不要临场补"残差、注意力、深度可分离"等无存证的结构。**

Q32. 既然最终 M3 和 M2 结构基本相同，为什么还说做了结构探索？

核心答：结构探索描述的是**研发过程**，不等于每个尝试都必须进入交付。最终结构相似恰恰说明候选经比较后又收敛回 M2 的设计点。区分"尝试过什么"和"最终保留什么"。

Q33. 为什么结构尝试没有获得明显收益？

核心答：现有实验只能确认"没有稳定收益"，**不能把原因钉死**。可能解释包括：268K 参数和 1M MAC 的容量上限、结构收益与算力/对齐代价互相抵消、单 seed 训练波动、量化和引擎路径压缩了小幅差异。这些都是待验证假设，不能说已证明是硬件噪声导致。

Q34. Model 3 没超过 Model 2，是不是失败模型？

核心答：不是失败，而是**有结论的探索分支**。它回答了"在当前算力预算和约束下，继续改结构或加 KD 是否能稳定提高部署精度"，现有答案是否定或证据不足。排除没有净收益的复杂方案，本身就是选择最终方案的依据。

Q35. 既然没有收益，为什么还把 Model 3 放进答辩？

核心答：它展示方案选择不是拍脑袋——M1 给高精度但高算力上限，M2 给硬件感知轻量解，M3 验证继续加复杂度是否值得。M3 没有明显增益，使推荐 M2 的理由更完整。展示时应称其为**探索和负结果**，不包装成"升级成功"。

Q36. M2 与 M3 的比较是严格的结构消融吗？

核心答：**不完全是**。最终 M3 同时带探索版本和 KD 训练差异，多变量一起变化时不能把差异单独归因于某一结构或 KD。严格消融应在相同 seed、数据、训练预算和量化配置下每次只改一个因素并做多种子统计。现有比较更适合作为系统候选比较，不是单因素因果结论。

Q37. Model 3 osim 只有 90.28%，低于原定 91% 目标，怎么回答？

核心答：直接承认——M3 val 91.83% 达训练侧目标，但 osim 90.28% 没达原定 91% 部署目标；M2 的 90.43% 达到自己的 90% 目标。**因此最终推荐 M2**。M3 的价值是探索边界和提供负结果，不是把每个候选都包装成达标。

Q38. 三模型的故事怎么讲，才不会让老师误以为 M1→M2→M3 必须单调变好？

核心答：说"**对照—定型—探索**"，不要说"第一代—第二代—第三代升级"：

- M1：通用高精度对照，说明不顾硬件时的上限；

- M2：硬件约束驱动的轻量定型版本，形成最终推荐；
- M3：在 M2 上继续探索，结果没有明显收益，用来验证 M2 的选择边界。

Q39. Model 3 对项目最实际的贡献是什么？

核心答：让团队得到一个比"精度多了多少"更重要的工程判断——在当前资源和硬件约束下，增加方案复杂度不一定转化为部署收益。它还暴露了候选比较必须控制变量、多种子验证，以及训练侧提升不一定保留到硬件级仿真路径。这些结论直接支撑了最终选 M2。

十、通用应答技巧 + 话术模板

1. **先结论后细节：**先一句话结论，再给数据。
2. **数据张口就来（关键数字背熟）：**光计算占比 M1-A 97.74% / M1-B 73.64% / M2·M3 90.65%；osim 精度 M1-A 98.15%、M1-B 97.54%（n=650 抽样）/ M2 90.43%、M3 90.28%（全量 5400）；对齐率 99.6%（M1 99.8%）；MOPs 1.051M vs 156.6M（约 149×）；参数 268K vs 2.39M（约 8.9×）；理论单张 0.4s（理论估计）；QAT→osim 总 gap 约 1.6–1.8 点。
3. **把局限说成边界：**M1 慢 → "算力约束下选了轻量路线"；M3 没赢 → "未观察到稳定收益，推荐更简单的 M2"。
4. **主动谈 Bug #11：**科学诚信，加分项，别等评委发现。
5. **不懂不装：**硬件底层细节不清楚时，坦诚说"基于曦智提供的仿真器和技术文档，我们聚焦上层算法适配；物理板卡值需主办方文档或实测确认"。
6. **回扣评分项：**回答时自然带出对应评分点（光计算占比 / 工具链 / 创新 / 进阶）。

话术模板：

- **面对尖锐质疑：**老师指出的是材料里的真实边界。先区分已验证证据和仍是假设的部分——已验证的是……；尚未验证的是……。因此结论限定为……，下一步需要……。
 - **不知道硬件细节时：**这个参数不是我们物理测量的，我不给未经验证的数。能确认它来自主办方容器的配置/行为模型；项目内可复现的是映射代码和 osim 结果。物理板卡值需主办方文档或实测确认。
 - **10 秒收束：**我们的价值不是把所有层强行放到光侧，而是找到可解释、可复现的光电协同点——低利用率 stem 留电子侧，90.65% 的主要 MAC 走原生 int8 光路径，在完整独立测试集的官方硬件级仿真中稳定在 90% 以上。
-

十一、AI 使用情况说明

原则：AI 是提效工具，关键决策、实验判断、数据核验全部由团队完成并负责。

使用范围：

- 1. **代码开发辅助**：用大语言模型编程助手辅助编写/调试部分脚本（QAT 量化模块、osimulator 容器封装、训练 runner、可视化前端），生成初版代码后由团队逐行审查、修改、验证。核心算法选型（int8 vs int4、STE vs LSQ+、stem 电计算策略）与所有超参均为团队自主决策。
- 2. **文档与表达**：设计/验证/技术数据报告与 PPT 的文字润色、中英翻译、排版辅助。
- 3. **资料检索与头脑风暴**：选题调研阶段（光计算、工业探伤、无人驾驶等）的资料整理与可行性讨论。
- 4. **实验记录归档**：把分散训练日志归并整理为 docs/EXPERIMENTS.md。

关键边界（团队独立完成，AI 未参与判断）：

- **科学诚信**：Bug #11 (test<train) 由团队自行发现并修复，旧 93.28%/93.26% 等作废数据全部如实标注。
- **数据可信**：所有精度数字、MAC 统计、对齐率均由团队跑实验得到并交叉验证（QAT 伪量化 $\nRightarrow$ osim 仿真）。
- **结论归因**：int4 失败根因、KD 无统计显著性差异等结论，均为团队基于实验数据的独立分析。

一句话应对："我们用 AI 提升编码和写作效率，但实验设计、数据核验和科学结论都由团队负责——比如测试集泄漏那个 Bug 就是我们自己发现、自己公开修复的。"

附：关键数据速查表 + 必背算式 + 上台前检查清单

1. 最终结果

指标	Model 1-A	Model 1-B	Model 2	Model 3
定位	VGG 高精度对照	VGG 光电切分消融	首个稳定硬件感知版	基于 M2 的结构/训练探索；最终保留 KD
参数量	2.39M	2.39M	267,944 (约 268K)	267,944 (约 268K)
单图 MAC	156.6336M	156.6336M	1.0511M	1.0511M
FP32 参考	97.17%	97.17%	90.15%	91.44% (KD 基准)
int8 val	97.87%	98.02%	92.06%	91.83%
int8 QAT test	97.89%	97.96%	92.20%	无同口径结果
osim 仿真	98.15%，n=650	97.54%，n=650	90.43%，n=5400 全量	90.28%，n=5400 全量

指标	Model 1-A	Model 1-B	Model 2	Model 3
光侧 MAC 占比	97.74%	73.64% (未达 90%)	90.65%	90.65%
osim 软件仿真耗时	29639 s/650	26681 s/650	13357 s/5400	13370 s/5400

2. 必背算式

- 计算量降低： $156.6336 / 1.0511 \approx 149\times$ 。
- 参数量降低： $2.39\text{M} / 0.268\text{M} \approx 8.9\times$ 。
- M2 光侧占比： $0.9528\text{M} / 1.0511\text{M} = 90.65\%$ 。
- M2 同 test 路径 gap： $90.43\% - 92.20\% = -1.77\text{ pp}$ 。
- M2 osim vs 原 FP32 参考： $90.43\% - 90.15\% = +0.28\text{ pp}$ （只能称数值持平或略高，不可称显著提升）。
- M2 vs M3 osim： $90.43\% - 90.28\% = 0.15\text{ pp}$ （不足以证明 KD 有收益，需 McNemar）。
- 每模型光引擎调用： $5\text{ 光计算层} \times 5400\text{ 张} = 27000\text{ 次}$ 。
- 光侧总 MAC： $0.9528\text{M} \times 5400 \approx 5.15 \times 10^9$ 。

3. 其他关键口径

- **MOPs/MAC**：项目把一次乘加记作一个计数（PPT 写 MOPs、日志写 MACs）。最稳妥说法："约 1.051 million MACs per image；按项目统一口径记为 1.051M MOPs。"乘/加分开计则约翻倍，149× 相对比较不变。
- **90.65%** 只统计 Conv/Linear MAC，**不含** BN/ReLU/池化/搬运/DAC-ADC/控制；是算子 MAC 占比，非端到端时延或能耗占比。
- **硬件**：Gazelle 8×2 tile，8a8w12o，2.6 MOPs 速率；线性度 99.4% 等为容器行为/标定参数（非自测）。
- **KD 教师**：ResNet-18，97.83%（训练时提供软标签，部署移除）。
- **数据**：EuroSAT 27000 张，三分 16200/5400/5400（Bug #11 修复后，seed=42 全局随机）。

4. 上台前检查清单

- ☐ 全组统一说" osimulator 硬件级仿真"，不说物理真机实测。
- ☐ 更新 PPT 的 M1 q50→q650，或准备主动解释版本差异。
- ☐ 修正 M1 耗时口径（q650 实测约 45.6/41.0 s/张，全量约 2.85/2.57 天），不再说 150 s/9 天。
- ☐ "int8 达标"改成分模型陈述：承认 M3 osim=90.28% 未达原 91% 目标。
- ☐ 不把 M1-B 73.64% 算作光占比≥90% 的配置。

- ☐ 能现场写出 $0.9528/1.0511=90.65\%$ ，并说明只统计 Conv/Linear MAC。
- ☐ 能解释 99.6% 对齐率与光侧补零为 0 不矛盾。
- ☐ 能说清 2×2 真实代价：省约 43.8% MAC，平均损失约 1–2 pp。
- ☐ 能说清最终全量结果来自 STE int8 主线，不是 LSQ+。
- ☐ 能说清 v4 实际注入的是基于 DAC ENOB 的权重噪声，不夸大 TIA/ADC 训练路径。
- ☐ 准备数据互斥断言、M2/M3 全量日志、M1 q650 日志、MOPs 表的快捷入口。
- ☐ Demo 显示 gazelle-osim 才称远程仿真；显示 fake-optical 时主动说明降级。
- ☐ 确认"反编译 .pyc "是否符合比赛规则；未确认则从主卖点中移除。
- ☐ 按真实情况填团队分工，每位成员能解释对应代码。
- ☐ 不宣称已测功耗、真实芯片延迟、TOPS/W、辐照性能或在轨可靠性。

5. 证据入口（项目内相对路径）

结论	证据文件
最终设计、训练与映射	复赛文档/01_设计报告.md
精度、速度、光占比与限制	复赛文档/02_验证报告.md
复现命令与脚本说明	复赛文档/03_技术数据.md
实验路线与归因	docs/EXPERIMENTS.md
M2 全量 5400	logs/log_optic_int8_new.md
M3 全量 5400	logs/log_optic_kd_new.md
M1-A/B q650	logs/osim_m1A_q650.log 、 logs/osim_m1B_q650.log
数据互斥断言	src/data/eurosat_split.py
v4 QAT 与实际噪声调用	src/qat/optic_qat_v4.py
光计算映射核心	src/core/optic_layers.py
M2 MOPs 公式	src/scripts/optic_inference_int8.py
Demo 真实/降级路径	demo/server/app.py 、 demo/docs/design.md
演示页面文字	复赛文档/演示PPT文字稿.md