

演示 PPT 文字稿 · Optic-SpaceNet 光学 CNN 加速系统

面向航空航天"在轨计算"的光学 CNN 加速系统

总时长 ≈ 10 分钟 · 共 12 页 · 每页标注：核心信息、版面内容、图表/视觉、口述讲稿

使用说明：本稿重心在**内容提炼与逻辑梳理**，不追求视觉炫技。每页先给"核心信息（一句话）"，再给上屏要点、配图（含数据/提示词）、口述讲稿。配图制作所需的**提示词与数据**统一放在文末[附录 A/B](#)。

评分重心映射：光计算占比 (20 分) → 第 9 页（讲透）；进阶 (20 分) → 第 11–12 页；AI 工具链 (10 分) → 第 7 页；功能及性能 (10 分) → 第 8、10 页；方案设计/创新 (创新 5 / 实用 5 / 平台 5) → 第 3、4、6 页。

全篇逻辑主线（一条故事线，背给评委）

在轨痛点 → 必须星上计算，电子算力吃不消
↓
先吃透硬件 → 逆向 Gazelle: 8x2 / 8a8w / 线性度 99.4% → 量化是唯一瓶颈
↓
据此设计 → 2x2 卷积对齐 tile（硬件感知架构）→ 268K 参数、1M 算力
↓
据此训练 → int8 + Gazelle 噪声注入（硬件匹配训练）→ 真机近无损
↓
结果说话 → 光计算占比 90.65%、真机 90.43%、量化反超 FP32
↓
方法论 → "硬件先于模型" + 真机验证闭环 + 科学诚信（自纠数据泄漏）

一句话总纲（开场/收尾都能用）：我们把三种 CNN 迁移到曦智 Gazelle 光计算硬件，用"硬件先于模型"的方法论，做到 **光计算占比 ≥ 90%、真机精度 90%+、量化无损甚至反超 FP32**。

第 1 页 · 封面（0:00–0:25，约 25 秒）

核心信息：作品定位——面向卫星在轨遥感计算的光学 CNN 加速系统。

版面内容

- 主标题：面向航空航天在轨计算的光学 CNN 加速系统 —— Optic-SpaceNet

- 副标题：三模型量化迁移 × 曦智 Gazelle 光计算平台 × 知识蒸馏
- 团队成员 / 指导老师 / 单位 / 日期

图表/视觉

- 背景：卫星 + 光子芯片 + 遥感地物缩略图（EuroSAT 的 AnnualCrop / Forest / River 拼贴）
- 角标一行：EuroSAT 10 类 icon —— AnnualCrop · Forest · HerbaceousVegetation · Highway · Industrial · Pasture · PermanentCrop · Residential · River · SeaLake

口述讲稿

"各位评委好，我们带来的作品是 Optic-SpaceNet——一套面向卫星在轨遥感计算的光学 CNN 加速系统。我们把三种 CNN 迁移到曦智 Gazelle 光计算硬件上，在保持 90% 以上准确率的同时，把超过 90% 的乘加运算交给了光子完成。下面用 10 分钟汇报。"

第 2 页 · 问题与动机（0:25–1:15，约 50 秒）

核心信息：在轨场景要求"星上就地推理"，而电子算力（功耗/重量/抗辐射）吃不消，光计算是结构性解。

版面内容

- **在轨计算痛点：**卫星每圈过境产生海量遥感图像，星地下行带宽严重受限 → 必须在**星上**完成实时地物分类，只下传结果。
- **电子计算瓶颈：**GPU/ASIC 功耗高、重量大、散热难、抗辐射差，不适合卫星严苛平台。
- **光子计算优势（空间 AI 视角）：**
 - **抗辐射：**光计算用光强/相位/波长等**模拟量**计算、无数字逻辑 → **光阵列核心对单粒子翻转（SEU/比特翻转）天然不敏感**，大幅降低航天抗辐射加固成本。
 - **散热/功耗：**太空无空气、只能辐射散热，传统 GPU 几百瓦极难排热；光计算功耗低、发热小，匹配在轨热约束。
 - **光速并行：**矩阵乘一次光程完成（皮秒级），高并行。
 - **理论寿命：**无电子芯片"栅氧击穿/阈值漂移"等电学老化，材料稳定下核心寿命有望 >10 年（优于 CMOS 5–10 年）。
- **题目目标：**把 CNN 迁移到 Gazelle **8×2 光学矩阵乘法器**，最大化光计算占比，量化精度可控。

⚠ 严谨边界（上屏/口述都注意）：不要说"光计算完全免疫辐射"。准确表述："光计算**核心**对单粒子翻转不敏感，大幅降低系统抗辐射成本；但 DAC/ADC/FPGA 等**外围电子**仍需常规加固。"详见[附录 C](#)。

图表/视觉 (NEW 建议新建，见附录 B-图1)

- 左：星上推理链路图（光学相机 → 光子芯片 → 地物分类结果 → 仅下传标签）
- 右：电子 vs 光子计算对比小表（功耗 / 并行度 / 抗辐射 / 重量 四项）

口述讲稿

"卫星每圈过境产生海量遥感图像，全部下传不现实，必须在星上就地分类，只把结果传回地面。传统电子算力功耗、重量、散热都太大，还怕空间辐射；而光子计算用光做矩阵乘，低功耗、高并行、还天然抗辐射，是卫星在轨场景的结构解。题目要求我们把 CNN 跑在曦智 Gazelle 光计算芯片上，光计算占比越高越好——这正是我们工作的核心。"

第 2.5 页 · 数据集与分类任务（推荐插入页，约 35 秒）【项目内容 / 应用价值】

核心信息：任务是卫星遥感图像的 **10 类地物分类**——用的就是真实卫星数据（EuroSAT / Sentinel-2），与"在轨遥感"场景天然对口；数据划分严格、无泄漏。

版面内容

- **数据集：EuroSAT（RGB 版）** —— 基于 **Sentinel-2 卫星** 遥感图像，**27000 张、64×64 RGB**，10 类地物覆盖；本身就是卫星数据，直接对应在轨遥感分类场景。
- **分类任务**：10 类单标签地物分类 → 直接对应土地监测、灾害评估、目标识别等在轨应用。
- **10 类及样本量（含类别不平衡）**：

类别	样本	类别	样本
AnnualCrop（农田）	3000	Pasture（牧场）	2000
Forest（森林）	3000	PermanentCrop（常年作物）	2500
HerbaceousVegetation（草本）	3000	Residential（住宅区）	3000
Highway（公路）	2500	River（河流）	2500
Industrial（工业区）	2500	SeaLake（海/湖）	3000

- 总计 **27000**；6 类各 3000、其余 2000–2500（Pasture 最少 2000）→ 轻度类别不平衡，训练用增广 + label smoothing 缓解。
- **三分划分**：train **16200** / val **5400** / test **5400**（seed=42），三者**严格互斥 + 覆盖全集**（统一数据源 eurosat_split.py 强制断言）→ 修复了早期 test⊂train 泄漏（Bug #11）。
- **预处理**：训练增广（随机水平翻转 + ±10° 旋转）+ ImageNet 归一化（mean/std=[0.485,0.456,0.406]/[0.229,0.224,0.225]）；验证/测试仅归一化（无增广，保证可复现）。

图表/视觉 (NEW 建议新建，见附录 B-图8)

- **图 EuroSAT 10 类样例拼图** (2×5 网格, 每类一张真实样本 + 类名) ——直接用 `data/EuroSAT_RGB/` 里你自己的图, 无需 AI 生成。

口述讲稿

"我们用的数据集是 EuroSAT, 基于 Sentinel-2 卫星遥感图像, 两万七千张、六十四乘六十四的 RGB 图, 十个地物类别——它本身就是卫星数据, 和我们'在轨遥感分类'的场景完全对口。任务是每张图分到农田、森林、河流等十类之一, 直接对应土地监测、灾害评估这些应用。数据上我们做了严格的三分划分: 训练一万六、验证和测试各五千四, 三份完全互斥——这一步我们专门修过一个测试集泄漏的 bug, 现在所有数字都是干净的。预处理上训练集做了翻转和旋转增广加 ImageNet 归一化, 验证测试只归一化保证可复现。"

🕒 **时间提示:** 插入此页后全篇变为 13 页 / ≈10.5 分钟; 建议从第 7 页工具链细节匀出约 35 秒, 或将其作为机动页 (评委问数据时切出)。

第 3 页 · 硬件平台 Gazelle——逆向分析 (1:15–2:00, 约 45 秒) 【平台使用 5 分】

核心信息: 我们不是"拿来就用", 而是**逆向吃透硬件**——关键结论: 硬件近乎理想 (线性度 99.4%), 量化与噪声是唯一精度瓶颈, 这决定了后续所有策略。

版面内容

- 物理 tile **8×2** ($k=8, n=2$) → 卷积 im2col 展平长度须被 **8 整除**
- 原生精度 **8a8w12o**: 8-bit 激活 / 8-bit 权重 / 12-bit 输出 → 硬件原生支持 int8, 无需退守 int4
- 关键物理量 (逆向自 `GAZELLE_ARCHITECTURE.md` + `calibration_params.json`):
 - 硬件线性度 **99.4%** (相对误差 0.6%, MAE 4.18 LSB, 2000 组随机 GEMM 实测)
 - DAC ENOB **7.5 bits**、TIA 噪声 $\sigma \approx 5.34e-4$ (MSE $2.85e-7$)、ADC LSB 0.001465
 - 单次 GEMM 延迟约 **16.6 μs** (`entrance.gazelle_latency`)
- **逆向方法:** 从模型目录名解码 `8X2_8a8w12o_dacenob7.5_power0.015_noise9e-11_..._std5.31`, 并用 `pycdc` 反编译 11 个 `.pyc` + 读取 `behavioral_char.json` 校准
- **关键判断:** 硬件几乎理想 → **所有精度损失来自量化与噪声建模, 而非硬件缺陷**

图表/视觉 (NEW 建议新建, 见附录 B-图2)

- 上: 8×2 光学 tile 结构示意 (输入光 → DAC 调制 → 光学 MAC 阵列 → TIA 探测 → ADC)
- 下: 硬件参数表 (含"逆向来源"一列, 体现工程深度)

口述讲稿

"我们第一步不是写模型，而是逆向吃透 Gazelle 硬件。它的物理计算单元是 8×2 tile，要求卷积展平后被 8 整除；原生支持 int8 权重。我们甚至从芯片的模型目录名里解码出了 DAC 精度、噪声等级这些参数，并用反编译和校准文件做了交叉验证。最关键的发现是——硬件线性度高达 99.4%，相对误差只有 0.6%，几乎理想。这意味着所有精度损失都来自量化，而不是硬件缺陷。这个判断，决定了我们后续全部的训练策略。"

第 4 页 · 三模型设计——硬件感知架构（2:00–3:00，约 60 秒）

【方案设计 / 创新】

核心信息：Model 1 是大而精的通用基线（算力 150×，不可在轨）；Model 2/3 为 8×2 tile 量身定制，用约 1/9 参数换约 1/150 算力。

版面内容

- **Model 1 Baseline VGG：**6×Conv(3×3, 通道 32/32/64/64/128/128) + 2×FC(8192→256→10)，**2.39M 参数，156.6M MOPs/张**。其首层 conv1_1 展平长度=27 (3×3×3)，对齐率 84.4%；**整体对齐率仍达 99.8%**——它的硬伤不是对齐，而是**算力体积**（是 M2/3 的 150×），在轨不可行。
- **Model 2 Optic-SpaceNet V1：**硬件对齐设计（stem 1×1 → stage1/2 用 **2×2 卷积** 让展平长度=32/64，完美被 8 整除；stage3 1×1），**268K 参数，1.05M MOPs**。
- **Model 3 Optic-SpaceNet V2：**与 M2 同架构 + ResNet-18 知识蒸馏（教师 97.83%，T=4.0，α=0.7）。
- 设计哲学：全层 **bias=False** 匹配光硬件（不支持 bias 加法）、BN 保留 FP32；用 2×2 卷积让每一层展平长度精确对齐 8×2 tile。

图表/视觉（已有数据，直接做表）

- 三模型架构对比表：

维度	Model 1 (VGG)	Model 2 (SpaceNet V...	Model 3 (SpaceNet V...
结构	6×Conv(3×3)+2×FC	4×Conv(1×1/2×2)+2×FC	同 Model 2
参数量	2.39M	268K	268K
综合对齐率	99.8%	99.6%	99.6%
首层展平/对齐	27 / 84.4%	3 / 37.5%→留电计算	3 / 37.5%→留电计算
总 MOPs/张	156.6M	1.05M	1.05M
训练方式	标准分类	标准分类	标准分类 + KD

口述讲稿

"我们设计了三个模型做对比。Model 1 是标准 VGG，精度高，但它有 239 万参数、每张图 1.56 亿次运算，是另外两个模型的 150 倍——在卫星上根本跑不动。需要澄清一点：Model 1 的硬件对齐率其实也很高（99.8%），它的硬伤不是对齐，而是纯粹的算力体积。Model 2、3 则是为硬件量身定制的：我们用 2×2 卷积让每一层的展平长度都完美被 8 整除，只用 26.8 万参数、105 万次运算。Model 3 在此基础上加了知识蒸馏。核心思路是：用九分之一的参数，换一百五十分之一的算力。"

第 5 页 · 方法演进路线——六阶段量化迭代（3:00–4:00，约 60 秒）【AI 工具链 / 技术复杂度】

核心信息：量化迁移我们迭代了 **6 个阶段**，从"全员崩盘"到"反超 FP32"——核心方法论是**硬件先于模型**。

版面内容（六阶段演进，三模型精度对照）

- **Phase 1** QAT 微调（FP32→低比特）：**全员失败**（M1 -11.3%、M2 -16.5%、M3 -18.2%）
→ 根因：FP32 权重依赖精细精度，突变量化破坏特征，低 lr 逃不出坏局部最小
- **Phase 2** 从零 QAT：有效但仍差 6–9%（动态 scale 不稳、首末层信息损失）
- **Phase 4** STE + 噪声注入：M1 int4 达 **96.46%**（损失仅 0.71%）；期间发现并修复"QAT Conv 全关"bug
- **Phase 5** Mixed 精度（Conv int4 / Linear FP32）：**反超 FP32 基准**（M1 +1.09%）
- **Phase 6 定型配方**：int8 权重 + Gazelle 物理噪声训练 + stem 首层 FP32
 - int8 匹配硬件原生 8a8w → 量化噪声比 int4 低 **16 倍**
 - 训练噪声从 0.02×scale（拍脑袋）校准为匹配 DAC ENOB 7.5 的 **0.0016×scale**（低 12 倍）
- **方法论：硬件先于模型**——训练时就匹配硬件，而非训练后再迁就

图表/视觉（ 建议新建，见附录 B-图3，附完整数据）

-  **精度演进折线图**：三模型准确率随 Phase 1→2→4→5→6 爬升，标注失败拐点与"反超 FP32"

口述讲稿

"量化这条路我们迭代了六个阶段。最早想用 FP32 模型直接微调到低比特，三个模型全部崩盘，掉 11 到 18 个点——根因是 FP32 权重依赖精细精度，突变量化直接破坏了学到的特征。后来改成从零训练量化、引入 STE 和噪声注入，逐步把损失压到 1 个点以内。最终在第六阶段定型：用 int8 权重匹配硬件原生精度（量化噪声比 int4 低 16 倍），训练时注入

Gazelle 真实物理噪声（我们还把噪声强度从拍脑袋的值校准到了真实硬件水平），首层保留 FP32。这条演进线背后是一个核心方法论——硬件先于模型，训练阶段就让模型适应硬件。”

第 6 页 · 核心创新点（4:00–4:45，约 45 秒）【创新性 5 分】

核心信息：四大创新，最核心是“硬件匹配训练”——别人训练完再量化部署（精度必掉），我们训练时就匹配硬件（真机近无损）。

版面内容（四大创新）

1. **硬件匹配训练：**训练期注入 Gazelle 真实噪声（DAC ENOB 7.5 + TIA $\sigma=5.34e-4$ ）→ 真机精度 gap 仅 **~1.6 点**（业界常见 5–10 点）。
2. **stem 首层 FP32 电计算策略：**首层对齐率仅 37.5%，保留电计算——既高效，又消除 BN 训练/推理分布偏移。
3. **int8 全流程对齐：**训练权重 = 硬件原生 8a8w，从根上避免 int4→int8 **网格不对齐**损失（scale max/7 vs max/127，实测不可消除 ~6%）。
4. **硬件感知架构：**2×2 卷积让展平长度完美对齐 8×2 tile，综合对齐率 **99.6%**，补零浪费为 0。

差异化：多数队伍“训练完再量化部署”；我们“训练时就匹配硬件”——这是真机近无损的关键。

图表/视觉 (NEW 建议新建，见附录 B-图4)

- 四宫格 icon 图（每个创新点一个图标 + 一句话）；或训练↔推理一致性 checklist（stem / int8 / 噪声 三项对勾 ✓）

口述讲稿

“我们的创新可以总结为四点。最核心的是硬件匹配训练——一般做法是训练完再量化部署，精度必然掉；我们在训练时就注入芯片的真实物理噪声，让模型提前适应，最终真机精度只比训练低 1.6 个点，远好于业界常见的 5 到 10 个点。第二，首层因为对齐率只有 37.5%，我们保留在电计算，既高效又消除了 BN 的训练推理偏移。第三，我们坚持 int8 全流程对齐——因为 int4 训练的权重放到 int8 硬件上会有不可消除的网格不对齐损失，大约 6 个点。第四是硬件感知的 2×2 卷积架构，对齐率 99.6%。这四点共同保证了高光计算占比下的高精度。”

第 7 页 · 训练与量化工具链——全闭环（4:45–5:30，约 45 秒） 【AI 工具链 10 分】

核心信息：从数据到光计算部署，**五阶段全自动闭环**，且每阶段产出可追溯。

版面内容（完整闭环，含具体产出物）

- ① **数据**：EuroSAT 27000 张 → 干净三分 split (train 16200 / val 5400 / test 5400)，统一数据源 eurosat_split.py (seed=42, 强制断言三者互斥+覆盖全集) → 产出：索引表
- ② **训练**：QAT (STE / LSQ+ 两套)，100 epoch，Warmup(5)+Cosine，AdamW，Gazelle 噪声注入，per-channel 量化 → 产出：*.pth 权重（共 25 个）
- ③ **量化**：int8 权重 + int8 激活，per-output-channel 量化 → 产出：整数化权重
- ④ **编译**：QAT 权重 → osimulator 8a8w 原生编译路径 → 产出：光计算图
- ⑤ **部署**：OpticConv2d / OpticLinear 封装 (im2col 展开 → 补零对齐 → 光学矩阵乘 → col2im 还原) → 产出：真机推理结果
- 工程规模：**47 个 Python 文件** (core/qat/data/training/scripts 分层)，25 个权重，修复 **11 个关键 bug**

图表/视觉 (NEW 建议新建，见附录 B-图5)

-  工具链横向流程图 (5 个阶段方框 + 箭头，标注每阶段产出物：索引表 → .pth → int8 权重 → 光计算图 → 真机结果)

口述讲稿

"工具链是完整闭环。数据处理上我们用 EuroSAT 两万七千张图，做了严格的三分划分，统一数据源，并强制断言三份互斥——这一步后来被证明至关重要。训练采用量化感知训练 QAT，一百个 epoch，配合余弦退火和 Gazelle 噪声，量化成 int8 后，经过 osimulator 的原生编译，直接部署到光计算路径推理。整个链路从数据到光计算部署全自动打通，四十七个脚本、二十五个权重，全程可追溯。"

第 8 页 · 精度结果 (5:30–6:30，约 60 秒)【功能及性能 10 分】

核心信息：三模型 int8 全部达标且**量化无损甚至反超 FP32**；更重要的是 osimulator 真机全量验证——Model 2 真机**反超原 FP32 基准 +0.28%**。

版面内容（数字均为 Bug #11 修复后的**干净 split**真值）

- 三模型 int8 干净 val：**M1 97.87/98.02% · M2 92.06% · M3 91.83%**，全部达成 int8 目标 (≥96/≥90/≥91%)
- **量化无损甚至反超**：M2 vs FP32 基准 **+1.91%**，M3 **+0.39%**，M1 **+0.70%/+0.85%**
- **osimulator 真机全量 5400 张**：M2 **90.43%** · M3 **90.28%**
- **Model 2 真机反超原 FP32 基准 +0.28%** (90.43% vs 90.15%) ——量化模型在真实光子硬件上真正可用

图表/视觉 (NEW 建议新建, 见附录 B-图6)

-  **精度对比柱状图**: 每模型三根柱 = FP32 基准 / int8 val / osim 真机 (全量)
- 或复用 docs/figures/compute_vs_accuracy_final.png (见附录 A 注意事项, 需更新数据)

口述讲稿

"这是精度结果。三个模型在干净验证集上 int8 精度分别达到 98%、92%、92%，全部超过目标，而且量化几乎无损——Model 2 甚至比 FP32 基准还高近两个点。更重要的是真机验证：在 osimulator 真实光计算硬件上跑完全部 5400 张测试图，Model 2 达到 90.43%，反超了原始 FP32 模型。请注意，这里所有数字都是我们主动修复数据泄漏 bug 之后、干净重训复测的真值。这说明我们的量化模型在真实光子硬件上是真正可用的。"

第 9 页 · 光计算占比 (重点) (6:30–7:20, 约 50 秒) 【★ 基础要求 20 分——最大单项】

核心信息：光计算占比 **90.65%**，超 90% 部署阈值；靠的是 2×2 卷积让每层完美对齐 8×2 tile，补零浪费为 **0**，6 层中 5 层走光计算。

版面内容 (含逐层 MOPs, 这是评委最可能追问的"怎么算出来的")

- **光计算占比**: Model 1 (A) **97.74%** · Model 2 **90.65%** · Model 3 **90.65%** (均 ≥ 90% 部署阈值)
- **算法口径**: 光计算占比 = 光计算层有效 MOPs / (光计算 + 电计算 MOPs), 已含补零对齐开销 (非名义值)
- **逐层分布 (Model 2/3, 单张 64×64)**:

层	类型	展平长度	对齐率	MOPs	占比	位置
stem	Conv 3→8, 1×1	3	37.5%	0.098M	9.3%	电计算 (FP32)
stage1	Conv 8→16, 2×2	32	100%	0.524M	49.9%	光计算 int8
stage2	Conv 16→32, 2×2	64	100%	0.131M	12.5%	光计算 int8
stage3	Conv 32→16, 1×1	32	100%	0.033M	3.1%	光计算 int8
fc1	Linear 1024→256	1024	100%	0.262M	24.9%	光计算 int8

层	类型	展平长度	对齐率	MOPs	占比	位置
fc2	Linear 256→10	256	100%	0.003M	0.2%	光计算 int8
合计			99.6%	1.051M	100%	光计算 0.953M / 电计算 0.098M

- 6 层中 **5 层走光计算**，仅 stem 首层电计算；光计算层展平长度全部为 8 的倍数 → **零补零浪费**

图表/视觉 (NEW 建议新建，见附录 B-图7)

- 🍩 光计算占比甜甜圈图 (90.65% 光 / 9.35% 电) + 逐层 MOPs 堆叠条形图 (光/电拆分)

口述讲稿

"这一页是评分最看重的光计算占比。我们三个模型分别是 97.7%、90.65%、90.65%，全部超过 90% 的部署阈值。怎么算的？按每层乘加运算量加权：光计算层的运算量除以总运算量。能做到这么高，是因为我们用 2×2 卷积让每一层的展平长度都完美被 8 整除，硬件对齐率 99.6%，几乎没有补零浪费——这是有效运算量，不是名义值。六层网络里五层完全在光计算上跑，只有对齐率只有 37.5% 的首层保留在电计算。也就是说，超过九成的乘加运算真正交给了光子完成。"

第 10 页 · 计算效率与在轨部署 (7:20–8:20, 约 60 秒) 【实用性 5 分 + 功能性能】

核心信息：Model 2/3 落在"低算力高精度"的最优象限（左上角），是在轨轻量部署首选；Model 1 算力过高不可用。

版面内容

- Model 2/3**：1.05M MOPs/张、268K 参数、全量 5400 张 ~**3.7h 跑完** (13357s/13370s) → **在轨轻量部署首选**
- Model 1**：156M MOPs (**150×**)、单张 ~150s → 全量需 ~9 天，**算力/功耗过高，不适合卫星** (仅抽样验证)
- 真机统计** (Model 2/3)：引擎各调用 **27000 次** (5 光计算层 × 5400 张)，总运算量 **5.15e+09 MACs**，对齐率 99.6%
- 部署推荐**：Model 2 v3 int8 (真机 90.43%、反超 FP32、268K 轻量)

图表/视觉 (✅ 已有核心图，需更新数据，见附录 A 注意事项)

-  docs/figures/compute_vs_accuracy_final.png：横轴计算量（对数）、纵轴精度，三模型散点，Model 2/3 在左上角（低算力高精度）

口述讲稿

"回到在轨场景的核心诉求——低功耗、低延迟。这张图横轴是计算量、纵轴是精度。Model 1 虽然精度最高，但计算量是 Model 2、3 的 150 倍，单张图要跑两分多钟，全量要九天，卫星上根本用不了。Model 2、3 只用 105 万运算量、26.8 万参数，全量 5400 张三个半小时跑完，却能达到 90% 以上精度，落点在图的左上角——低算力高精度，正是卫星在轨部署的最优解。"

第 11 页 · 鲁棒性、真机验证与科学诚信（8:20–9:10，约 50 秒） 【功能性能 / 进阶】

核心信息：两级验证体系（秒级 QAT 交叉验证 + 小时级真机全量）；**主动发现并修复数据泄漏 bug**（科学诚信加分项）；并得到一个诚实发现——KD 真机未显著优于 M2。

版面内容

- **噪声鲁棒性：**训练时注入 Gazelle 噪声 → 真机 gap 仅 ~1.6 点（M2 -1.63% / M3 -1.55%，基本相等）
- **两级验证体系：**QAT 秒级交叉验证（--qat，不需 osim）+ osimulator 真机全量 5400（小时级）
- **科学诚信（亮点）：**主动发现并修复 **Bug #11**（test $\subset$ train 100% 泄漏）——旧 osim 虚高至 93.28%/93.26%，已**全部作废**；干净重训 + 真机复测，现 test $\approx$ val（M2 差 0.14%），证明无泄漏、泛化良好
- **诚实发现：**KD（Model 3）真机 90.28% vs Model 2 90.43%，**统计打平**（差 0.15%， $n=5400\times 2$ ， $z\approx 0.27$ 不显著）→ 真机鲁棒性**主要来自 Gazelle 噪声训练**，而非蒸馏

图表/视觉

-  docs/figures/noise_robustness_v2.png（ 已有，噪声扫描曲线）
- 小表：真机 vs val gap（M2 -1.63% / M3 -1.55%，基本相等）

口述讲稿

"为验证可靠性，我们做了两级验证：秒级的 QAT 交叉验证，加上小时级的 osimulator 真机全量测试。真机精度只比训练低 1.6 个点，说明我们的噪声匹配训练有效。这里特别讲一点科学诚信：我们主动发现并修复了一个严重 bug——测试集整段落在了训练集里，导致旧的真机数字虚高到 93%，我们已经把这些数字全部作废，重训复测，现在所有数字都是干净

的。还有一个诚实的发现：加了知识蒸馏的 Model 3 真机并不比 Model 2 强，说明真机鲁棒性主要来自噪声训练，而不是蒸馏——我们不回避这个负结果。"

第 12 页 · 总结与展望（9:10–10:00，约 50 秒）【总结 / 进阶 20 分】

核心信息：三模型全部完成光计算迁移（光计算占比 ≥90%、真机 90%+、量化无损）；方法论"硬件先于模型"+ 真机验证闭环；展望光电混合提速与在轨实测。

版面内容

- **成果总览（一页纸 KPI）：**

指标	Model 1	Model 2	Model 3
光计算占比	97.74%	90.65%	90.65%
真机精度（全量5400）	98/100%（q50 抽样）	90.43%	90.28%
参数量	2.39M	268K	268K
总 MOPs/张	156.6M	1.05M	1.05M

- **进阶贡献：**① int8 全流程真机部署（osim 全量验证）② Gazelle 噪声匹配训练（近无损真机，gap ~1.6 点）③ 三模型 × 多量化方案完整消融 ④ 在轨遥感应用闭环
- **方法论：**硬件先于模型 → 硬件匹配训练 → 真机验证闭环
- **展望：**
 - **光电混合提速**（已搭脚本 `optic_inference_h{1,2,3}.py`）：H1 Conv光/Linear电（65.5%）、H2 砍最慢层（78.2%）、H3 极致切分（53.3%）——在保住 >50% 光计算下换吞吐
 - 更大模型补偿精度、**端到端硬件在环训练**（osim 真实输出作训练信号）、**真实卫星在轨验证**

图表/视觉

- 成果 KPI 总表 + 路线图（当前 → 光电混合 → 在轨验证）

口述讲稿

"总结一下：我们把三种 CNN 全部迁移到光计算，光计算占比超过 90%，真机精度 90% 以上，量化几乎无损。进阶方面，我们实现了 int8 全流程真机部署、用噪声匹配训练做到近无损真机推理、并完成了三模型多量化的完整消融。方法论上始终坚持'硬件先于模型'。下一步

我们计划做光电混合加速——已经搭好了三种切分方案的脚本——并推动真实卫星在轨验证。以上是我们的汇报，感谢各位评委，请提问。"

附录 A：配图总表

图表	用途	状态	制作方式
计算量-精度散点图	第 10 页核心图	⚠️ 已有但需更新数据	见下方"注意事项"，改 2 个数即可
int4 噪声鲁棒性曲线	第 11 页	✅ 已有 docs/figures/noise_robustness_v2.png	直接用
星上推理链路 + 电子/光子对比	第 2 页	NEW 新建	附录 B-图1（PPT 绘制 / AI 配图）
8×2 tile 结构 + 硬件参数表	第 3 页	NEW 新建	附录 B-图2（PPT 绘制）
精度演进折线图（Phase 1→6）	第 5 页	NEW 新建	附录 B-图3（matplotlib，含数据+代码）
四宫格创新 / 一致性 checklist	第 6 页	NEW 新建	附录 B-图4（PPT 绘制）
工具链五阶段流程图	第 7 页	NEW 新建	附录 B-图5（PPT / draw.io 绘制）
三模型精度对比柱状图	第 8 页	NEW 新建	附录 B-图6（matplotlib，含数据+代码）
光计算占比甜甜圈 + 逐层堆叠条	第 9 页	NEW 新建	附录 B-图7（matplotlib，含数据+代码）
EuroSAT 10 类样例拼图	第 2.5 页	NEW 新建	附录 B-图8（用自有数据，含脚本）

⚠️ 重要：现有散点图需更新（credibility 关键）

docs/figures/compute_vs_accuracy_final.png 当前的 osim 点用的是 q500 抽样值（M2=89.00%、M3=90.80%），与讲稿/正文引用的**全量 5400 真值**（M2=90.43%、

M3=90.28%) 不一致——评委若对照会质疑数据自治。
修复 (改 src/scripts/plot_compute_vs_accuracy.py 两行即可):

```
# Model 2: 'y_osim': 89.00  →  90.43
'y_osim': 90.43,
# Model 3: 'y_osim': 90.80  →  90.28
'y_osim': 90.28,
```

并把页脚 "Model 2/3 n=500" 改为 "Model 2/3 n=5400 (full test set)"，重跑 python src/scripts/plot_compute_vs_accuracy.py。

附录 B：配图提示词与数据

全局视觉规范（保持与现有 compute_vs_accuracy_final.png 一体化）：

- 配色用 Okabe-Ito 色盲友好色板：Model 2 橙 #E69F00、Model 3 绿 #009E73、Model 1 深蓝 #0072B2、Model 1-B 浅蓝 #56B4E9；电计算用灰 #999999。
- 字体 DejaVu Sans / Arial；网格虚线 #999999 alpha 0.25；dpi ≥ 300。
- 数据图统一输出到 docs/figures/，存 .png + .pdf（论文/打印用矢量）。
- 下方 4 个 matplotlib 脚本均已配置中文字体（Microsoft YaHei），在 Windows 上可直接运行：python src/scripts/<脚本名>.py。

图1 · 星上推理链路 + 电子/光子对比（第 2 页）

- 推荐方式：PPT 原生绘制（矢量、可控）。
- 提示词 (AI 配图备选)： "A clean flat-style infographic, left side: a satellite in orbit beaming down to a photonic chip processing Earth remote-sensing images and outputting land-cover class labels; right side: a two-column comparison table 'Electronic vs Photonic' with rows Power / Parallelism / Radiation / Weight. Minimal, technical, blue and orange accent, white background, no text garbling."
- 电子 vs 光子对比数据：

维度	电子计算 (GPU/ASIC)	光子计算 (Gazelle 核心)
功耗/散热	高 (数百瓦)；太空仅能辐射散热	低、发热小
并行度	受限 (随规模 $O(N^2)\uparrow$)	光速并行矩阵乘

维度	电子计算（GPU/ASIC）	光子计算（Gazelle 核心）
抗辐射	差（易 SEU，需冗余/加固）	模拟量计算、无数字逻辑 → 核心免疫 SEU （外围仍需加固）
寿命	栅氧击穿/阈值漂移，5–10 年	无电学老化，核心寿命有望 >10 年

图2 · 8×2 光学 tile 结构 + 硬件参数表（第 3 页）

- 推荐方式：PPT 绘制结构示意图 + 参数表。
- 提示词： "Schematic of an 8x2 optical compute tile: input light → DAC modulator (ENOB 7.5) → 8x2 photonic MAC array (interferometric/diffraction) → TIA detector ($\sigma=5.3e-4$) → ADC (12-bit). Horizontal signal flow, labeled stages, clean line art, white background."
- 硬件参数表数据（含逆向来源）：

参数	值	逆向来源
物理 tile	8×2 (k=8, n=2)	模型目录名 + calibration_params.json
原生精度	8a8w12o	模型目录名 8X2_8a8w12o_...
线性度	99.4% (rel err 0.6%)	behavioral_char.json (2000 组 GEMM)
DAC ENOB	7.5 bits	目录名 dacenob7.5
TIA 噪声 σ	$\approx 5.34e-4$ (MSE 2.85e-7)	calibration_params.json
ADC LSB	0.001465	calibration_params.json
单次 GEMM 延迟	$\sim 16.6 \mu s$	entrance.gazelle_latency

图3 · 精度演进折线图（第 5 页） — matplotlib 可直接生成

- 数据（Phase 1→2→4→5→6 的干净/可对比 int 精度，%）：

Phase	Model 1	Model 2	Model 3
P1 微调 (int4)	85.91	73.63	73.22
P2 从零 (int4)	91.17	81.20	83.26
P4 STE+噪声 (int4)	96.46	74.35*	78.26*
P5 Mixed	98.26	91.26	91.13

Phase	Model 1	Model 2	Model 3
P6 Gazelle int8	97.87	92.06	91.83
FP32 基准（参考线）	97.17	90.15	91.44

*M2/M3 的 P4 因"QAT Conv 全关"bug 异常偏低（bug 修复后即恢复），图中可加注"P4 bug"。

- 提示词： "Line chart, accuracy vs quantization phase (P1→P6), 3 colored lines (orange/green/blue) for 3 models, dashed horizontal reference lines for each FP32 baseline, annotate the P1 failure dip and the P5/P6 breakthrough above FP32. Chinese labels, Okabe-Ito colors."
-  点击展开：ready-to-run matplotlib 代码（保存为 src/scripts/plot_phase_evolution.py）

图4 · 四宫格创新 / 训练-推理一致性 checklist（第 6 页）

- 推荐方式：PPT 绘制四宫格，每格一个创新点。
- 提示词： "A 2×2 grid of icon cards: (1) chip-with-noise-waves 'hardware-matched training'; (2) lightning-bolt-first-layer 'stem FP32 electronic'; (3) aligned-grid 'int8 end-to-end alignment'; (4) puzzle-piece-fits-tile 'hardware-aware 2×2 architecture'. Flat icons, blue/green/orange, white background."
- 一致性 checklist 数据（训练 ↔ 推理三项对勾）：

维度	训练配置	推理（osim）配置	一致
首层	first_conv_fp32=True	keep_first_conv_electronic=True	✓
权重	int8（8a8w）	int8（osim 原生）	✓
噪声	Gazelle 噪声（DAC 7.5 + TIA）	osim 物理噪声	✓

图5 · 工具链五阶段流程图（第 7 页）

- 推荐方式：PPT / draw.io 矢量绘制。
- 布局规格（五个方框横向排列，箭头连接，每框标注产出物）：



OpticConv2d/Linear				
三分 split	100 ep+Gazelle	per-channel	原生编译	im2col→光
MAC→col2im				
[索引表]	[.pth×25]	[整数权重]	[光计算图]	[真机结果]

- 提示词: "Horizontal 5-stage pipeline flowchart with arrows: Data → Training → Quantization → Compile → Deploy, each box labeled with its artifact, blue gradient boxes, clean infographic."

图6 · 三模型精度对比柱状图（第 8 页） — matplotlib 可直接生成

- 数据 (FP32 基准 / int8 val 干净 / osim 真机, %):

模型	FP32 基准	int8 val (干净)	osim 真机
Model 1 (A)	97.17	97.87	98.00 (q50 抽样)
Model 2	90.15	92.06	90.43 (全量5400)
Model 3	91.44	91.83	90.28 (全量5400)

- 提示词: "Grouped bar chart, 3 model groups × 3 bars each (FP32 baseline / int8 val / osim real-hardware), highlight M2 osim bar that exceeds its FP32 baseline, Chinese labels, Okabe-Ito colors."

►  点击展开: ready-to-run matplotlib 代码 (保存为 src/scripts/plot_accuracyBars.py)

图7 · 光计算占比甜甜圈 + 逐层 MOPs 堆叠条（第 9 页，★ 核心图） — matplotlib 可直接生成

- 数据 (Model 2/3 逐层 MOPs, M):

层	光计算 MOPs	电计算 MOPs
stem (1×1, 电)	0	0.098
stage1 (2×2)	0.524	0
stage2 (2×2)	0.131	0
stage3 (1×1)	0.033	0

层	光计算 MOPs	电计算 MOPs
fc1 (Linear)	0.262	0
fc2 (Linear)	0.003	0

- **甜甜圈数据：**光计算 0.953M (90.65%) / 电计算 0.098M (9.35%)。
- **提示词：** "Two-panel figure: left donut chart 'Optical 90.65% / Electronic 9.35%'; right horizontal stacked bar chart per-layer MOPs (stem/stage1/stage2/stage3/fc1/fc2) split into optical (orange) vs electronic (gray), Chinese labels."

►  点击展开：ready-to-run matplotlib 代码（保存为 src/scripts/plot_optical_ratio.py）

图8 · EuroSAT 10 类样例拼图（第 2.5 页） — matplotlib 可直接生成

- **数据：**直接读取 data/EuroSAT_RGB/<类名>/ （每类随机抽 1 张，seed=42 可复现）。10 类见第 2.5 页表格。
- **提示词：** "2×5 grid of 10 EuroSAT land-cover satellite image samples (AnnualCrop, Forest, HerbaceousVegetation, Highway, Industrial, Pasture, PermanentCrop, Residential, River, SeaLake), each labeled with English+Chinese class name, 64×64 RGB, clean white background, supitle."

►  点击展开：ready-to-run matplotlib 代码（保存为 src/scripts/plot_eurosat_samples.py）

附录 C：应用价值纵深与高频质疑应对（答辩话术）

评委常从"应用价值"和"现实可行性"两个角度追问。下面把"空间 AI"定位与最可能被挑战的"能效比 (TOPS/W)"问题整理成可直接背诵的应对话术。原则与正文一致：**先结论后数据、把局限说成边界、不自夸、不回避。**

C1. 应用定位：面向空间智能卫星的"抗辐射 + 低功耗"光子加速器

把作品定位为"面向空间智能卫星的抗辐射、低功耗光子神经网络加速器"。技术组合 = 光子矩阵乘 (抗辐射/低功耗) × INT8 量化 × 轻量 CNN (268K) × Gazelle 噪声鲁棒训练，构成完整的边缘侧空间 AI 方案。

光计算天然契合空间 AI 的三大挑战：

挑战	传统电子芯片	光计算（核心）	严谨边界
辐射（SEU/比特翻转）	极易受宇宙射线撞击 → 0↔1 翻转，需冗余/加固	模拟量（光强/相位）计算，无数字逻辑 → 核心免疫 SEU	外围 DAC/ADC/FPGA 仍需常规加固
功耗/散热	GPU 数百瓦，太空无空气仅能辐射散热	低功耗、发热小	—
寿命	栅氧击穿/阈值漂移，5–10 年	无电学老化，材料稳定 下核心寿命有望 >10 年	长期辐射可能使波导吸收↑、探测器暗电流↑

⚠️ **避坑（严谨性）：**答辩时**不要说**"光计算完全免疫辐射"。准确表述："光计算核心对单粒子翻转不敏感，大幅降低系统抗辐射成本，但外围电子模块仍需常规加固。"——客观且落地，反而加分。

C2. 最可能被挑战的硬伤：能效比（TOPS/W）——攻防预案

评委可能的发难：评估板级光计算系统"系统功耗高、算力低"，能效比（TOPS/W）远低于 Jetson Orin (~1.6 TOPS/W) 等 GPU，"上天有什么意义？"

先懂本质再答：

- 评估板（Proof of Concept）光阵列规模极小（本项目 8×2 tile），算力天然低；
- **"光电墙（I/O Wall）"**：系统功耗绝大部分（>99%）消耗在外围 **ADC/DAC、TIA、激光器温控、控制 FPGA** 的光电转换（O-E-O）上；真正"光穿过波导做矩阵乘"的功耗仅毫/微瓦级。

三段式应对话术：

① 降维：商业级 vs 航天级的不对等

"Jetson Orin 的高能效是地面商业芯片。直接上天，宇宙射线极易导致死机或逻辑错误；要做航天级抗辐射加固，其体积、重量、功耗都会大幅膨胀，能效大打折扣。而光计算核心天然抗 SEU。评估空间 AI 芯片，不能只看绝对算力，更要看**'抗辐射成本下的综合能效'**。"

② 承认现状 + 打"规模效应"牌（O(1) 复杂度）

"当前低能效源于第一代评估板光阵列规模小、加上高昂的光电转换开销。但关键差异在于：电子算 $N \times N$ 矩阵乘，功耗/时延随规模 $O(N^2) \sim O(N^3)$ 增长；而**光计算无论 16×16 还是 1024×1024，光穿过芯片都是光速（皮秒级），计算本身功耗几乎不增（O(1)）**。随着硅光集成（如共封装光学 CPO）成熟、阵列扩到千级规模，光电转换开销被摊薄，理论能效可反超 GPU。我们做的是面向未来 5–10 年的前沿探索。"

③ 特定任务优势

"通用计算上纯光方案目前打不过 GPU；但在模拟域线性运算（矩阵乘、卷积、FFT、线性滤波）上，光计算可省去部分 ADC、实现极低延迟，是 GPU 难以替代的赛道——而这恰好是 CNN 推理的核心算子，也是本项目的切入点。"

一句话底线：不在绝对算力/能效上与 GPU 硬刚（必输），把重心放在 **抗辐射特殊优势 + O(1) 规模潜力 + 线性任务低延迟**——立意既懂现实、又有前瞻性。

💡 可与正文 **第 3 页（硬件逆向） + 第 10 页（计算效率） + 第 11 页（真机验证）** 联动：把"评估板规模小"自圆其说为我们选择 **268K 轻量模型、追求高光计算占比而非绝对 TOPS** 的前提，化被动为主动。

讲解节奏提示

1. **高分项讲透：**第 3 页（平台使用）、第 9 页（光计算占比，20 分）务必充分，配逐层 MOPs 表。
2. **技术复杂度与创新：**第 5 页（六阶段演进）、第 6 页（四创新）是体现深度的关键，用数据与"方法论"支撑。
3. **数据说话：**第 8、10 页用图表；关键数字背熟——**光计算占比 90.65%、对齐率 99.6%、真机 90.43%/90.28%、MOPs 1.05M vs 156M (150×)、真机 gap ~1.6 点、参数 268K。**
4. **主动亮诚信：**第 11 页主动讲 Bug #11 数据泄漏与负结果（KD 未增益），把局限讲成科学发现。
5. **时间控制：**10 分钟内讲完 12 页，留 5 分钟答辩；每页核心信息若被追问，先给结论再给数据。
6. **数据自洽检查：**务必按附录 A 更新散点图，确保台上数字与图一致。